

Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»

Научно-учебный комплекс «Информатика и системы управления» МГТУ им. Н.Э. Баумана
Научно-образовательный центр «Технологии искусственного интеллекта» МГТУ им. Н.Э. Баумана

КЛЮЧЕВЫЕ ТРЕНДЫ РАЗВИТИЯ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА: НАУКА И ТЕХНОЛОГИИ

Международная ИТ-конференция

(Москва, 21 апреля 2023 г.)

Сборник трудов



Москва

ИЗДАТЕЛЬСТВО

МГТУ им. Н. Э. Баумана

2023

УДК 004.8
ББК 32.813
K52

Издание доступно в электронном виде по адресу
<https://press.bmstu.ru/catalog/item/81067/>

K52 **Ключевые тренды развития искусственного интеллекта: наука и технологии** : Международная ИТ-конференция (Москва, 21 апреля 2023 г.) : сборник трудов / Федеральное государственное бюджетное образовательное учреждение высшего образования «Московский государственный технический университет имени Н. Э. Баумана (национальный исследовательский университет)»; Научно-учебный комплекс «Информатика и системы управления» МГТУ им. Н. Э. Баумана; Научно-образовательный центр «Технологии искусственного интеллекта» МГТУ им. Н. Э. Баумана. — Москва : Издательство МГТУ им. Н. Э. Баумана, 2023. — 161, [1] с. : ил.

ISBN 978-5-7038-6203-2

Представлены труды Международной ИТ-конференции «Ключевые тренды развития искусственного интеллекта: наука и технологии», проходившей в Московском государственном техническом университете имени Н.Э. Баумана 21 апреля 2023 года. Работа конференции была организована по трем секциям: «Baum AI: передовые решения в области искусственного интеллекта», «Искусственный интеллект: от науки к инфраструктуре и практике», «Искусственный интеллект как объект изучения в инженерном образовании».

УДК 004.8
ББК 32.813

Издается в авторской редакции.

ISBN 978-5-7038-6203-2

© МГТУ им. Н.Э. Баумана, 2023
© Оформление. Издательство
МГТУ им. Н.Э. Баумана, 2023

Baum AI: передовые решения в области искусственного интеллекта

УДК 004.89

Концепция фреймворка реализации генетического алгоритма многопараметрической оптимизации

© Агеев Даниэль Алиханович ¹	d.ageev@emtc.ru
Суханов Денис Александрович ¹	den829@mail.ru
Кудрявцев Алексей Александрович ¹	vatutu@gmail.com
Тынченко Ядвига Александровна ²	080801@yandex.ru

¹ МГТУ им. Н.Э. Баумана, НОЦ «Технологии искусственного интеллекта»,
Москва, 105005, Россия

² СибГУ им. М.Ф. Решетнева, кафедра системного анализа и исследования операций,
Красноярск, 660037, Россия

Данная статья описывает концепцию фреймворка реализации генетического алгоритма для решения задач в области многопараметрической оптимизации. Рассмотрены теоретические основы генетических алгоритмов, а также представлен анализ архитектуры и компонентов фреймворка. Рассмотрены существующие фреймворки для работы с генетическими алгоритмами.

Ключевые слова: оптимизация, генетический алгоритм, фреймворк, PyGAD, DEAP, GALib

Введение. Многопараметрическая оптимизация является важным аспектом во многих областях науки и техники, таких как инженерия, биоинформатика, физика и экономика. Генетические алгоритмы являются распространенными методами оптимизации, которые позволяют решать сложные задачи многопараметрической оптимизации [1].

В настоящей статье описывается концепция фреймворка реализации генетического алгоритма многопараметрической оптимизации. Фреймворк представляет собой подключаемую библиотеку, которая упрощает реализацию генетического алгоритма для решения практических задач.

Ожидается, что результаты данной работы будут полезны для исследователей, занимающихся задачами многопараметрической оптимизации, а также для программистов и инженеров, работающих над созданием эффективных алгоритмов оптимизации.

Теоретические основы генетических алгоритмов. Генетические алгоритмы (ГА) представляют собой эволюционный метод оптимизации, который использует механизмы природного отбора и генетической мутации. Они являются итеративными алгоритмами, которые постепенно улучшают решение путем генерации и выбора новых кандидатов на каждой итерации. Общая модель стандартного генетического алгоритма приведена на рис. 1 [1, 2].

Генетические алгоритмы имеют три основных операции: селекция, скрещивание и мутация. Селекция — оператор выбора одного индивида из популяции, основываясь на значениях функции пригодности всех индивидов теч-

кушней популяции, для использования его в операторе скрещивания. Операция скрещивания (крессовер) формирует нового индивида из двух выбранных родителей с сохранением признаков обоих родителей. Операция мутации вносит случайные изменения в гены потомства для создания новых комбинаций характеристик. Обычно мутация предполагает незначительное изменение потомков [2].

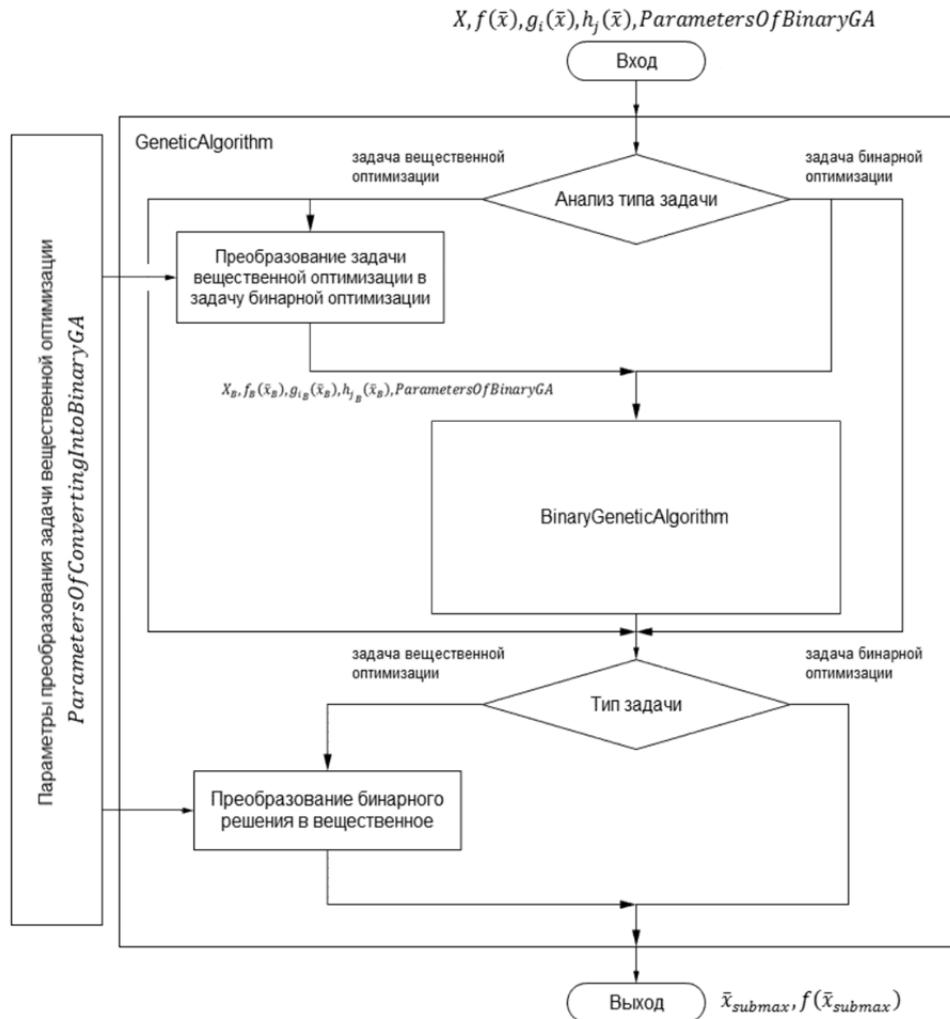


Рис. 1. Общая модель стандартного генетического алгоритма

В генетических алгоритмах для определения приспособленности решения используется функция приспособленности (fitness function). Функция приспособленности оценивает качество решения и выдает числовое значение, которое используется для сравнения решений в популяции.

Выбор индивидов для скрещивания зачастую осуществляется на основе их приспособленности. Индивиды с более высокими значениями функции приспособленности имеют больший шанс быть выбранными оператором селекции, чем хромосомы с более низкими значениями.

Генетические алгоритмы имеют несколько преимуществ по сравнению с другими методами оптимизации. Они могут работать с широким диапазоном типов задач, концептуально просты и имеют менее жесткие требования к целевой функции [1].

Обзор существующих фреймворков. Существует несколько библиотек и фреймворков для работы с генетическими алгоритмами.

DEAP (Distributed Evolutionary Algorithms in Python) — библиотека на языке Python, которая предоставляет широкий спектр инструментов для создания и оптимизации моделей на основе ГА. Она содержит множество предопределенных операторов мутации, скрещивания и селекции, а также предоставляет возможность создания пользовательских операторов. DEAP поддерживает распараллеливание вычислений, что позволяет использовать мощности нескольких процессоров или компьютеров. Однако, у DEAP может быть высокий порог входа для новичков, и библиотека не всегда является легко настраиваемой [3].

GAlib — библиотека на языке C++, которая предоставляет инструменты для создания и оптимизации моделей на основе ГА. Она содержит множество предопределенных операторов мутации, скрещивания и селекции, а также предоставляет возможность создания пользовательских операторов. GAlib поддерживает распараллеливание вычислений, что позволяет использовать мощности нескольких процессоров или компьютеров. Однако, библиотека не обновлялась с 2003 года, что может привести к проблемам совместимости и использования в новых проектах [4].

PyGAD — это библиотека на языке Python, которая предоставляет простой и удобный интерфейс для создания и оптимизации моделей на основе генетических алгоритмов. Она поддерживает различные типы задач оптимизации, включая многопараметрические задачи и задачи оптимизации с ограничениями. PyGAD содержит реализацию стандартных операторов генетического алгоритма, таких как оператор скрещивания, мутации и селекции, а также предоставляет возможность создания пользовательских операторов. Кроме того, PyGAD имеет ряд дополнительных функций, таких как механизм сохранения и загрузки популяции, возможность отслеживания прогресса оптимизации в режиме реального времени и возможность визуализации результатов. Однако PyGAD не работает с бинарными строками, поэтому может работать медленнее других библиотек и неприменим к некоторым видам задач [5].

Концепция фреймворка. Фреймворк разрабатывается с учетом создания универсального и эффективного инструмента для решения задач оптимизации. Особенности фреймворка:

- реализация генетического алгоритма для поиска оптимальных значений параметров на основе набора критерииев оптимизации;

- поддержка различных типов задач оптимизации, включая задачи многопараметрической оптимизации и задачи с ограничениями.

- учит недостатков существующих решений, таких как ограничения на типы задач оптимизации, неэффективность при работе с большими популяциями, отсутствие возможности работы с бинарными строками, отсутствие графического интерфейса и сложность в использовании.

Фреймворк будет состоять из нескольких компонентов, которые будут взаимодействовать между собой для решения задач оптимизации. Компоненты будут реализованы на языке Python.

Основными компонентами фреймворка будут являться:

- генетический алгоритм:** реализация стандартных операторов генетического алгоритма, таких как оператор скрещивания, мутации и отбора, а также возможность создания пользовательских операторов.

- функция пригодности:** самоконфигурирующаяся функция оценки, которая будет использоваться для оценки качества каждой популяции и выбора лучших решений.

- визуализация:** возможность визуализации результатов оптимизации в виде графиков и диаграмм.

Концептуальная схема фреймворка реализации генетического алгоритма представлена на рис. 2.

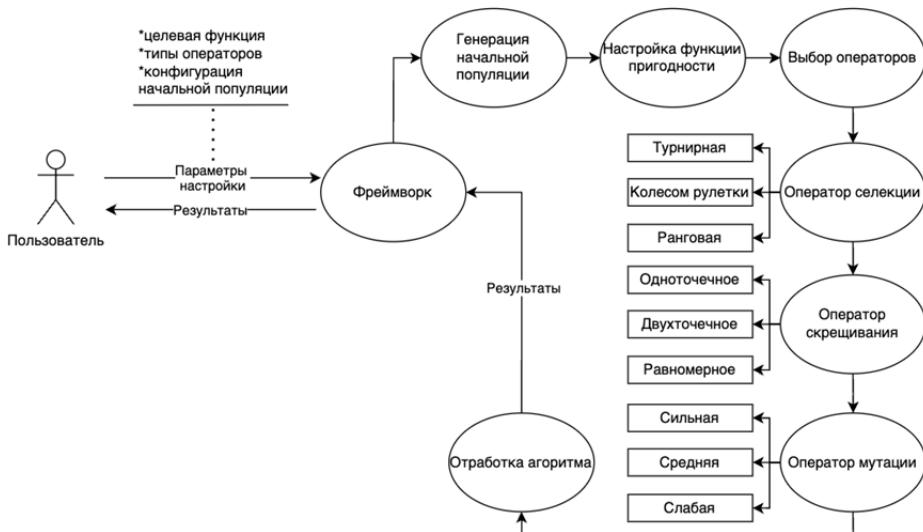


Рис. 2. Концептуальная схема фреймворка

Выводы. В данной работе была представлена концепция фреймворка реализации генетического алгоритма многопараметрической оптимизации. На основе анализа существующих решений были определены их недостатки и сформулированы требования к разрабатываемому фреймворку.

Была разработана архитектура фреймворка, состоящая из основных компонентов, таких как генератор популяции, операции селекции, скрещивания, мутации, функция пригодности и другие. Важным элементом разработки фреймворка является учет особенностей оптимизации многопараметрических задач, что позволяет эффективно решать такие задачи.

Была разработана графическая схема фреймворка, которая позволяет лучше понимать его компоненты и взаимосвязи между ними. Также были описаны основные преимущества разработанного фреймворка по сравнению с существующими решениями.

Литература

- [1] Гладков Л., Курейчик В., Курейчик В. Генетические алгоритмы. М.: ФИЗМАТЛИТ, 2010. 368 с.
- [2] Сергиенко А.Б., Галушин П.В., Бухтояров В.В., Сергиенко Р.Б., Сопов Е.А., Сопов С.А. Генетический алгоритм. Стандарт. Красноярск: Сибирский юридический институт ФСКН России, 2010. 40 с.
- [3] DEAP documentation. Available at: <https://deap.readthedocs.io/en/master/> (accessed March 12, 2023).
- [4] Glib A C++ Library of Genetic Algorithm Components. Available at: <http://lancet.mit.edu/ga/> (accessed March 12, 2023).
- [5] PyGAD — Python Genetic Algorithm. Available at: <https://pygad.readthedocs.io/en/latest/> (accessed March 12, 2023)..

Concept of a Framework for the Implementation of a Genetic Algorithm for Multiparametric Optimization

✉	Ageev D.A. ¹ Sukhanov D.A. ¹ Kudryavtsev A.A. ¹ Tynchenko Ya.A. ²	d.ageev@emtc.ru den829@mail.ru vatutu@gmail.com 080801@yandex.ru
---	------------------------------------------------------------------------------------------------------------------------	---------------------------------------------------------------------------

¹ BMSTU, SEC “AI Technologies”, Moscow, 105005, Russia

² Reshetnev Siberian State University of Science and Technology, Systems analysis and operations research department, Krasnoyarsk, 660037, Russia

Paper describes the concept of genetic algorithm implementation framework for solving multi-parameter optimization problems. The theoretical foundations of genetic algorithms are discussed and the analysis of the architecture and components of the framework is presented. Existing frameworks for working with genetic algorithms are considered.

Keywords: optimization, genetic algorithm, framework, PyGAD, DEAP, GAlib

УДК 004.9, 303.7

Интеллектуальный анализ данных по материалам, полученным по технологии SLM

©	Евсюков Дмитрий Юрьевич ¹	evsjob@yandex.ru
	Бухтояров Владимир Викторович ¹	bukhtoyarov@emtc.ru
	Бородулин Алексей Сергеевич ¹	borodulin@emtc.ru
	Ломазов Вадим Александрович ^{2,3}	vlomazov@yandex.ru

¹ МГТУ им. Н.Э. Баумана, НОЦ «Технологии искусственного интеллекта», Москва, 105005, Россия

² НИУ БелГУ, Белгород, 308015, Россия

³ ФГБОУ ВО Белгородский ГАУ, Белгород, 308503, Россия

Представлено программное обеспечение (набор инструментов), использующий подходы Data Science и алгоритмы машинного обучения (МО) для интеллектуального анализа данных и предсказания механических свойств материалов, полученных с помощью технологии селективного лазерного плавления (SLM), на основе созданной многомерной цифровой модели процессов. Решение показало точность прогноза в 98,9 % по критерию среднего размера частиц для сплава Ti-6Al-4V, которая достигается применением ансамбля методов кристаллической пластичности и конечных элементов (CPFEM). Также решение позволяет предсказывать такие механические свойства, как предел текучести, пластичность и прочность на разрыв, для структур из сплавов Ti-6Al-4V и AlSi10Mg. Благодаря разработке, специалисты могут сократить затраты на технологические этапы производства и внедрения решений с применением технологий SLM до 1,2 раз.

Ключевые слова: аддитивные технологии, селективное лазерное плавление, SLM, поддержка принятия решений, интеллектуальный анализ данных, машинное обучение, Data Science, системный анализ, оптимизация процессов, SLM DS framework

Введение. Цель данной работы заключается в исследовании возможностей интеллектуального анализа данных (ИАД) по материалам, полученным по технологии SLM, с использованием разработанного программного решения, и оценке его эффективности.

Гипотезой исследования является предположение о том, что разработанное программное решение позволит значительно повысить качество, соответствие образца заданным характеристикам и сократить этапы технологического процесса [1], за счет внедрения прогнозирования свойств полученного материала [2], что, в свою очередь, может привести к улучшению процесса проектирования [3] и производства изделий, изготавливаемых по технологии SLM [4].

Для достижения поставленной цели в работе были решены следующие задачи:

– разработка программного решения для сбора, хранения и обработки данных по материалам, полученным по технологии SLM, с использованием алгоритмов искусственного интеллекта [5];

– анализ эффективности разработанного программного решения на основе данных, полученных в процессе экспериментов с материалами, полученными по технологии SLM [6].

Данная работа может быть полезна как исследователям, занимающимся проблемами производства и прогнозирования свойств материалов, полученных по технологии SLM, так и специалистам в области проектирования и производства изделий, изготавливаемых по данной технологии.

Материалы и методы. В данном исследовании основным методом анализа данных является МО и использование искусственных нейронных сетей (ИНС). Эти методы позволяют создавать и использовать предобученные модели МО для предиктивного анализа технологических параметров, с целью получения образца с заданными характеристиками. Таким образом применяются различные подходы и методы МО, такие как алгоритмы классификации, регрессии и кластеризации [7], в зависимости от рассматриваемых задач. Например, для изучения изменения свойств материалов, полученных по технологии SLM, в привязке к времени и прогнозирования их будущих значений, используется анализ временных рядов [8]. Для определения степени взаимосвязи между различными характеристиками композиционных материалов и выявления факторов, оказывающих наибольшее влияние на их свойства, применяется корреляционный анализ [9]. Для изучения отдельных групп материалов на основе их характеристик и определения, какие свойства характерны для каждой группы, используются алгоритмы классификации.

Для проведения исследования была сформирована выборка из 100 статических испытаний образцов, полученных по технологии SLM из четырех материалов: полиамид P2200, сталь 316L, сплав титана Ti6Al4V и алюминиевый сплав AlSi10Mg. Образцы изготавливались с разными параметрами, включая температуру плавления, скорость печати, размер и форму образца. Каждый образец характеризуется свойствами материалов, такими как прочность, растяжение, упругость, изгиб min-max, термальные свойства и др. [10].

Образцы были изготовлены из различных материалов с разными параметрами. Для прогнозирования характеристик материалов использовались данные о технологических параметрах и качественные компоненты. Использовались стандартные методы испытаний для измерения механических характеристик, методы дифференциальной сканирующей калориметрии (DSC) и термогравиметрии (TGA) для измерения термальных свойств, а также методы рентгеновской дифрактометрии (XRD) и электронной микроскопии (SEM) для изучения физических характеристик. Данные были записаны на всех этапах, включая методы/методики испытаний и получаемые характеристики [11, 12].

Результаты. Решение использует данные из БД свойств материалов для улучшения производства и разработки новых материалов, используя МО для

изучения взаимосвязи между структурой и свойствами материалов. Методы МО включают обучение с учителем, без учителя и с подкреплением, что позволяет определить, прогнозировать и управлять свойствами материалов. Данные выводятся в различных форматах, включая электронный и печатный вид.

Использование прогнозирующего аспекта МО позволяет делать это без предварительных гипотез, исключительно на основе существующих данных.

Такой подход играет ключевую роль в изучении новых инженерных материалов, так как позволяет быстро и точно оценить, как изменение структуры может повлиять на физические свойства материала. Более того, на основе полученных данных можно оптимизировать структуру материала с целью достижения определенных физических характеристик.

Пользовательский интерфейс предоставляет инструменты для настройки пайплайна МО, включая коннекторы, визуализации, предобработку, модели и оценщики. Количество шагов пайплайна неограниченно, а инструменты хранятся в базе данных вместе с их описанием и скриптами Python. Все шаги сохраняются в таблицу пайплайна и могут быть легко масштабированы. Модель можно зафиксировать и использовать для быстрого прогнозирования (рис. 1).

SLM materials DS framework

The screenshot shows the 'Working area of the pipeline, name:' section with the input 'Название модели' (Model name). Below it is the 'Pipeline tools panel' with tabs for 'Моделирование ML' (Machine Learning Modeling) and 'Доступные гиперпараметры метода' (Available method hyperparameters). Under 'Моделирование ML', there are three tabs: 'Линейная регрессия (LinearRegression)', 'Случайный лес (RandomForestRegressor)', and 'Catboost regressor'. The 'Случайный лес (RandomForestRegressor)' tab is selected. It displays parameters like 'Количество деревьев' (Number of trees) set to 10, 'Критерий' (Criterion) set to 'squared_error', and 'Максимальная глубина дерева' (Max depth) set to 11. The 'Доступные гиперпараметры метода' panel shows 'Целевая переменная' (Target variable) and 'Средний размер частиц' (Average particle size). The 'Предобработка данных' (Data preprocessing) section includes 'Корреляционная матрица' (Correlation matrix) and 'Доля тестовой выборки, %' (Test set ratio, %) set to 20. The 'Стандартизация (StandardScaler)' section has a checked checkbox 'Перемешивать записи датасета' (Shuffle dataset rows). The 'Результаты' (Results) section contains a 'Scatter' plot and a link to a scatter plot image: '9ae813ee534542969111a3899d0c26a6.png'. The bottom right corner shows the 'Available fields of the dataset' panel with checkboxes for 'Шероховатость поверхности Rz макс' (Maximum surface roughness Rz), 'Разница значение осей' (Axis value difference), 'Площадь поверхности гранулы' (Granule surface area), 'Площадь проекции гранулы' (Granule projection area), and 'Мин рекомендуемая толщина слоя' (Recommended minimum layer thickness).

Рис. 1. Рабочая область пайплайна интеллектуального анализа материалов LSM

С помощью разработанного инструментария мы исследовали объемную эластичность SLM металлов, которая зависит от многих факторов, таких как

электронные структуры, химические связи и термическая обработка. Наш эксперимент использовал нейронную сеть для оценки механических свойств алюминиевых сплавов, стали и сплава Ti-6Al-4V при различных условиях, при которых были изучены предел текучести, твердость, пластичность, усталость и вязкость разрушения. Алгоритм деревьев с градиентным усилением был настроен на основе эмпирических измерений и соответствующих параметров.

Мы также проводили исследования в области аморфных металлов и моделировали зависимость предела текучести от состава (рис. 2).

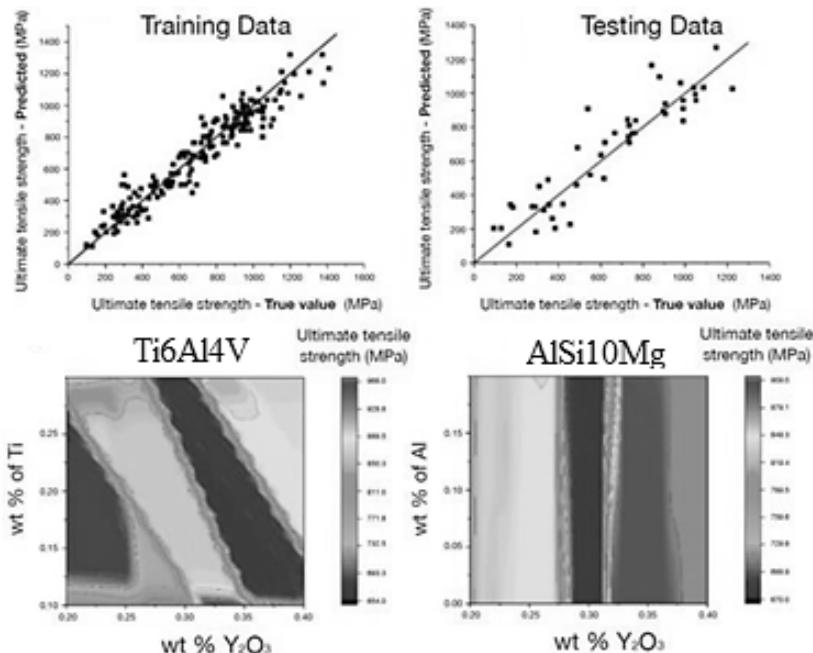


Рис. 2. График моделирования и оценки предела текучести состава Ti-6Al-4V и AlSi10Mg

Также наше решение позволяет исследовать методы деформационной кинематики (DIC) и многомасштабного моделирования материалов (MI) в контексте деформации кристаллов в поликристаллических металлах и сплавах. Исследование в отношении Ti-6Al-4V было проведено с использованием комбинации методов кристаллопластичности и CPFEM, а также трех экспериментальных методик, включая дифракцию обратного рассеяния электронов (EBSD) и профилометрию поверхности. Была изучена взаимосвязь с пластичностью сплава Ti-6Al-4V, в результате чего поля деформации, предсказанные методами CPFEM, были напрямую сопоставлены с выполненными измерениями. Таким образом, были получены очень хорошие соответствия, демонстрирующие применение методов CPFEM для изучения пластичности и деформаций в сплаве Ti-6Al-4V с применением МО (рис. 3).

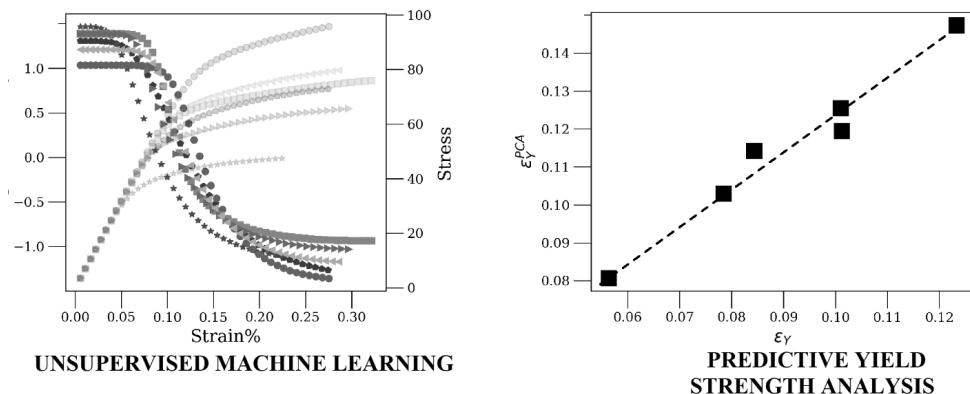


Рис. 3. Исследования и прогнозирование предела текучести Ti-6Al-4V с применением методов ML

Использование различных методов анализа данных с помощью программного решения позволило получить более полное представление о свойствах материалов, изготовленных по технологии SLM, и определить оптимальные параметры изготовления для достижения необходимых характеристик. Это значительно повышает эффективность и точность проектирования новых SLM материалов и изделий из них.

Выводы. В данной статье было разработано программное решение для ИАД, полученных по технологии SLM. Это решение позволило увеличить точность и эффективность анализа, а также выявить новые закономерности в данных. Были проведены эксперименты на наборе данных, полученных из исследований сплавов Ti-6Al-4V и AlSi10Mg, и применены методы машинного обучения и анализа данных для определения оптимальных параметров предела текучести процесса SLM. Результаты показали, что программное решение позволило достичь точности прогнозирования механических свойств материалов на уровне 98,9%, что превосходит точность предыдущих исследований в этой области [10-12]. Кроме того, решение позволяет сократить время анализа данных до 1,2 раз, что значительно упрощает процесс анализа и повышает эффективность использования SLM-материалов.

Несмотря на значительные достижения, в нашем исследовании имеются некоторые ограничения, такие как использование данных только из одного источника <https://viam.ru/review/5942> и отсутствие учета влияния на свойства материалов, таких внешних факторов, как температура окружающей среды и влажность. Для более полного понимания взаимодействия между параметрами процесса SLM и свойствами материалов, необходимы дальнейшие исследования в данной области.

Литература

- [1] Qi X., Chen G., Li Y., Cheng X., Li C. Applying neural-network-based machine learning to additive manufacturing: current applications, challenges, and future perspectives // Journal Engineering. 2019. Vol. 5 (4). Pp. 721–729.
- [2] Wang Y., Chen X., Jayalakshmi S., Singh R.A., Sergey K., Gupta, M. Process parameters, product quality monitoring, and control of powder bed fusion // Chen S., Zhang Y., Feng Z. (eds.) International Workshop on Intelligentized Welding Manufacturing (TRINWM). 2019. Vol. 3. Pp. 89–108. https://doi.org/10.1007/978-981-13-8192-8_4
- [3] Chen Y., Wang H., Wu Y., Wang H. Predicting the printability in selective laser melting with a supervised machine learning method // Materials (Basel). 2020. Vol. 13 (22). Art. 5063. <https://doi.org/10.3390/ma13225063>
- [4] Barantsov I.A., Pnev A.B., Koshelev K.I., Tynchenko V.S., Nelyub V.A., Borodulin A.S. Classification of acoustic influences registered with phase-sensitive OTDR using pattern recognition methods // Sensors. 2023. Vol. 23 (2). Pp. 582–594.
- [5] Bukhtoyarov V.V., Tynchenko V.S., Nelyub V.A., Masich I.S., Borodulin A.S., Gantimurov A.P. A Study on a probabilistic method for designing artificial neural networks for the formation of intelligent technology assemblies with high variability // Electronics. 2023. Vol. 12 (1). Pp. 215–229.
- [6] Lomazov V.A., Evsyukov Yu.D., Lomazova V.A., Prokushev Yu.E., Nesterova E.V. Intellectual assessment of staff sufficiency for innovative development of the sustainable regional agro-industrial complex // IOP Conference Series: Earth and Environmental Science. 2022. Vol. 981 (2). Pp. 22064–22076.
- [7] Masich I.S., Tynchenko V.S., Nelyub V.A., Bukhtoyarov V.V., Kurashkin S.O., Gantimurov A.P., Borodulin A.S. Prediction of critical filling of a storage area network by machine learning methods // Electronics. 2022. Vol. 11 (24). Pp. 4150–4162.
- [8] Mikhalev A.S., Tynchenko V.S., Nelyub V.A., Lugovaya N.M., Baranov V.A., Kukartsev V.V., Sergienko R.B., Kurashkin S.O. The orb-weaving spider algorithm for training of recurrent neural networks // Symmetry. 2022. Vol. 14 (10). Pp. 2036–2048.
- [9] Masich I.S., Tynchenko V.S., Nelyub V.A., Bukhtoyarov V.V., Kurashkin S.O., Borodulin A.S. Paired patterns in logical analysis of data for decision support in recognition // Computation. 2022. Vol. 10 (10). Pp. 185–197.
- [10] Franczyk E., Machno M., Zębala. WInvestigation and optimization of the SLM and WEDM processes' parameters for the AlSi10Mg-sintered part // Materials. 2021. Vol. 14 (2). Pp. 410–424.
- [11] Papazoglou E.L., Karkalos N.E., Karmiris-Obratański P., Markopoulos A.P. On the modeling and simulation of SLM and SLS for metal and polymer powders // Archives of Computational Methods in Engineering. 2021. Vol. 1 (3). Pp. 1–33.
- [12] Cao L., Yuan X. Study on the numerical simulation of the SLM molten pool dynamic behavior of a nickel-based superalloy on the workpiece scale // Materials. 2019. Vol. 12 (14). Pp. 2272–2284.

Intelligent Data Analysis for Materials Obtained Using SLM Technology

© Dmitry Yu.E.¹

evsjob@yandex.ru

Vladimir V.B.¹

bukhtyarov@emtc.ru

Aleksey S.B.¹

borodulin@emtc.ru

Lomazov V.A.^{2,3}

vломазов@yandex.ru

¹ BMSTU, SEC "AI Technologies", Moscow, 105005, Russia

² Belgorod State National Research University, Belgorod, 308015, Russia

³ Belgorod State Agricultural University named after V. Gorin, Belgorod, 308503, Russia

In this article, we present software (a toolkit) that utilizes Data Science approaches and machine learning (ML) algorithms for intelligent data analysis and prediction of the mechanical properties of materials obtained using the selective laser melting (SLM) technology, based on a created multidimensional digital model of processes. The solution has shown a 98.9 % accuracy in predicting the average particle size for the Ti-6Al-4V alloy, achieved by applying a combination of crystal plasticity and finite element methods (CPFEM). It also enables the prediction of mechanical properties such as yield strength, ductility, and fracture toughness for structures made of Ti-6Al-4V and AlSi10Mg alloys. Thanks to this development, specialists can minimize production and implementation costs for SLM technologies by up to 1.2 times.

Keywords: Additive technologies, SLM, decision support, data mining, machine learning, Data Science, systems analysis, process optimization, SLM DS framework

УДК 004.08

Оптимизация моделей сверточных нейронных сетей для решения задач распознавания объектов в контексте образовательной робототехники

© Загитов Артур Александрович
Чеботарева Эльвира Валерьевна
Магид Евгений Аркадьевич

artazagitov@gmail.com
elvira.chebotareva@kpfu.ru
magid@it.kfu.ru

Казанский федеральный университет, Казань, 42008, Россия

Машинное зрение является важной составляющей для решения ряда задач при помощи искусственного интеллекта. Задачи обнаружения и распознавания объектов относятся к ключевым задачам машинного зрения. На практике реализация распознавания объектов широко используется в промышленной и сервисной робототехнике. Для решения задач распознавания объектов в робототехнике используются как традиционные алгоритмы машинного зрения, так и методы, основанные на применении глубокого обучения. В контексте образовательной робототехники задача распознавания объектов тесно связана с проблемой эффективной реализации существующих решений на маломощных устройствах. Целью данной работы является исследование эффективности методов оптимизации модели нейронной сети YOLOv5, с помощью квантизации после обучения и обучения с учетом квантизации.

Ключевые слова: компьютерное зрение, обнаружение объектов, глубокое обучение, методы оптимизации, образовательная робототехника

Введение. Машинное зрение играет важную роль в современных интеллектуальных системах, в том числе в промышленной и сервисной робототехнике [1–3]. Обнаружение и распознавание объектов являются ключевыми задачами машинного зрения для робототехнических систем [4]. В настоящее время методы распознавания объектов на основе глубокого обучения показывают высокую эффективность и широко используются на практике не только в профессиональных робототехнических комплексах, но и в образовательной робототехнике. Однако использование глубокого обучения в образовательных робототехнических системах предъявляет ряд специфических требований к нейросетевым моделям. В данной работе мы представляем сравнительный анализ эффективности трех нейросетевых моделей на основе архитектуры YOLOv5 в контексте их применимости в образовательной робототехнике.

Проблемы машинного обучения в образовательной робототехнике. Опыт последнего десятилетия, накопленный высшими учебными заведениями мира, демонстрирует эффективность внедрения элементов образовательной робототехники в инженерное образование [5–7]. Все большее внимание уделяется применению элементов компьютерного и машинного зрения в образовательных робототехнических платформах [8, 9].

Машинное зрение позволяет роботам взаимодействовать с окружающей средой и более эффективно выполнять задачи. Задачи распознавания объектов в образовательной робототехнике могут использоваться, например, при манипулировании объектами [10], автономной навигации [11] и реализации взаимодействия робота и человека [12]. Несмотря на признанную эффективность [13], использование глубоких нейронных сетей для распознавания объектов в образовательной робототехнике связано с рядом проблем.

Во-первых, следует отметить, что образовательные робототехнические платформы обычно не отличаются высокой производительностью [14]. Этот фактор следует учитывать в первую очередь при выборе образовательных решений, основанных на глубоком обучении.

Во-вторых, известно, что точность распознавания объектов зависит от качества и размера наборов данных, используемых при обучении [15]. В то же время подготовка таких наборов данных является достаточно трудоемкой задачей и не всегда в полной мере может быть реализована в ходе учебного процесса.

В-третьих, обучение нейросетей распознаванию конкретных объектов требует значительных временных затрат [16], что часто препятствует включению практических задач машинного обучения в учебный процесс.

Таким образом, для реализации распознавания объектов в образовательной робототехнике необходимы модели нейронных сетей, отвечающие следующим требованиям:

- нетребовательность к вычислительным ресурсам;
- поддержка трансферного обучения [17];
- достаточная для учебного процесса точность при обучении на небольших наборах данных.

В этой работе мы проводим бенчмаркинг предварительно обученной модели YOLOv5 [18] до и после оптимизации с использованием квантизации после обучения и обучения с учетом квантизации [19, 20]. Для тестирования мы используем маломощный микрокомпьютер Raspberry Pi 4B, который часто используется в образовательной робототехнике.

Инструменты и методы. В экспериментах использовалась модель архитектуры YOLOv5 и ее оптимизация, основанные на квантизации после обучения и обучении с учетом квантизации. Все модели были предварительно обучены на наборе данных Microsoft COCO (Common Object in Context) [21], а затем дообучены на пользовательском наборе данных. Пользовательский набор данных состоял из 83 изображений размером 320×320 пикселей, разделенных на 3 класса. Кроме того, в набор данных были включены изображения, не содержащие каких-либо объектов (так называемый фон). Набор обучающих данных включал 70 % изображений, 20 % изображений были включены в набор для валидации, 10 % изображений были включены в набор тестовых данных. Для тестирования обученных моделей был использован 8-ядерный процессор AMD Ryzen 7 3700X, 32 ГБ оперативной памяти, графический процессор NVIDIA GeForce RTX 3060 12 ГБ для обучения моделей и микрокомпьютер Raspberry Pi 4B.

Результаты экспериментов. В табл. 1 приведены полученные в ходе бенчмаркинга оценки производительности с помощью метрики mAP (mean Average Precision) для трех моделей:

- 1) модель YOLOv5 без оптимизации («FP16»),
- 2) модель YOLOv5 с квантизацией после обучения («PTQ»),
- 3) оптимизация модели YOLOv5 посредством обучения с учетом квантизации (QAT).

В табл. 2 представлено среднее время обработки одного изображения для каждой модели в миллисекундах. Среднее время обработки определялось при использовании выборки из 1000 случайно выбранных изображений. Также в табл. 2 представлена средняя ожидаемая частота кадров (FPS) для каждой модели при тестировании на устройстве Raspberry Pi 4B.

Таблица 1. Оценка производительности моделей

Модель	Точность	
	mAP:0.5-0.95	mAP:0.5
YOLOv5 [FP16]	0,644	0,995
YOLOv5 [PTQ]	0,591	0,995
YOLOv5 [QAT]	0,624	0,995

Таблица 2. Оценка скорости вывода

Модель	Задержка (мс)	FPS
YOLOv5 [FP16]	382	2,6
YOLOv5 [PTQ]	140	7,0
YOLOv5 [QAT]	153	6,5

Выводы. Результаты экспериментов позволяют сделать выводы об эффективности оптимизации модели YOLOv5 для обнаружения объектов на изображениях размером 320x320 пикселей с использованием квантизации после обучения и обучения с учетом квантизации. С точки зрения производительности обучение с учетом квантизации дает лучшие результаты по сравнению с квантизацией после обучения. С точки зрения скорости логического вывода квантизация после обучения показывает лучшие результаты, хотя преимущество перед обучением с учетом квантизации не является столь значительным. В целом, оба метода значительно улучшают скоростные характеристики модели. Результаты проведенного эмпирического исследования свидетельствуют о том, что оба рассмотренных метода оптимизации модели YOLOv5 могут быть рекомендованы для использования в образовательных робототехнических решениях на базе микрокомпьютера Raspberry Pi 4B.

Публикация осуществлена при финансовой поддержке РНФ и Кабинета министров Республики Татарстан в рамках научного проекта № 22-21-20033.

Литература

- [1] Myrzin V., Tsoy T., Bai Y., Svinin M., Magid E. Visual data processing framework for a skin-based human detection // Ronzhin A., Rigoll G., Meshcheryakov R. (eds). Interactive Collaborative Robotics. 2021. LNCS. Vol. 12998. Pp. 138–149.
- [2] Buyval A., Gavrilenkov M., Magid E. A multithreaded algorithm of UAV visual localization based on a 3D model of environment: implementation with CUDA technology and CNN filtering of minor importance objects // Proceedings of International Conference on Artificial Life and Robotics. 2017. Vol. 22. Pp. 356–359.
- [3] Abdulganeev R., Lavrenov R., Safin R., Bai Y., Magid E. Door handle detection modelling for servosila engineer robot in gazebo simulator // International Siberian Conference on Control and Communications (SIBCON). 2022. Pp. 1–4.
- [4] Zohdy B., Ramadan N., Mahmood M., Hefny H. Machine vision application on science and industry: machine vision trends // Optoelectronics in Machine Vision-Based Theories and Applications. IGI Global. 2019.
- [5] Valls Pou A., Canaleta X., Fonseca D. Computational thinking and educational robotics integrated into project-based learning // Sensors. 2022. Vol. 22 (10). Art. 3746. <https://doi.org/10.3390/s22103746>
- [6] Arocena I., Huegun-Burgos A., Rekalde I. Robotics and education: a systematic review // TEM Journal. 2022. Vol. 11. Pp. 379–387.
- [7] Tsoy T., Sabirova L., Magid E. Effective robotics education: Surveying experiences of master program students in introduction to robotics course // MATEC Web of Conferences. 2018. Vol. 220.
- [8] Sophokleous A., Christodoulou P., Doitsidis L., Chatzichristofis S.A. Computer vision meets educational robotics // Electronics. 2021. Vol. 10 (6). Art. 730.
- [9] Chebotareva E., Mustafin M. Android based educational mobile robot design and pilot evaluations // Proceedings of International Conference on Artificial Life and Robotics. 2023. Pp. 146–149.
- [10] del Toro C., Robles-Algarín C., Rodríguez-Álvarez O. Design and construction of a cost-effective didactic robotic arm for playing chess, using an Artificial vision system // Electronics. 2019. Vol. 8 (10). Art. 1154.
- [11] Lopez-Rodriguez F.M., Cuesta F. An android and arduino based low-cost educational robot with applied intelligent control and machine learning // Applied Sciences. 2011. Vol. 11 (1). Art. 48.
- [12] Vega J., Cañas J.M. Open vision system for low-cost robotics education // Electronics. 2019. Vol. 8 (11). Art. 1295.
- [13] Macaulay M.O., Shafee M. Machine learning techniques for robotic and autonomous inspection of mechanical systems and civil infrastructure // Auton Intell Syst. 2022. Vol. 2. Art. 8.
- [14] Evripidou S., Georgiou K., Doitsidis L., Amanatiadis A.A., Zinonos Z., Chatzichristofis S.A. Educational robotics: platforms, competitions and expected learning outcomes // IEEE Access. 2020. Vol. 8. Pp. 219534–219562.
- [15] Uchida S., Ide S., Iwana B.K., Zhu A. A further step to perfect accuracy by training CNN with larger data // International Conference on Frontiers in Handwriting Recognition (ICFHR). Shenzhen, China, 2016. Pp. 405–410.
- [16] Bryzgalov P., Maeda T., Shigeto Y. Predicting how CNN training time changes on various mini-batch sizes by considering convolution algorithms and non-GPU time // Proceedings of the 2021 on Performance EngineErIng, Modelling, Analysis, and Visualizati On STrategy (PERMA-VOST '21). New York, USA, 2021. Pp. 11–18.
- [17] Weiss K., Khoshgoftaar T.M., Wang D. A survey of transfer learning // J Big Data. 2016. Vol. 3. Art. 9.
- [18] Jocher G. et al. ultralytics/yolov5: v7.0 YOLOv5. Available at: <https://github.com/ultralytics/yolov5> (accessed March 13, 2023).

-
- [19] Jacob B. et al. Quantization and Training of neural networks for efficient integer-arithmetic-only inference // In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City, UT, USA, 2018. Pp. 2704–2713.
 - [20] Wu H., Judd P., Zhang X., Isaev M., Micikevicius P. Integer quantization for deep learning inference: principles and empirical evaluation. Available at: <http://arxiv.org/abs/2004.09602> (accessed March 13, 2023).
 - [21] Lin T.-Y. et al.: Microsoft COCO: Common objects in context // Computer Vision-ECCV 2014: 13th European Conference. Zurich, Switzerland, 2014. Pp. 740–755.

Optimization of Convolutional Neural Network Models for Object Recognition Problems Solution in the Educational Robotics Context

© Zagitov A.A.

artazagitov@gmail.com

Chebotareva E.V.

elvira.chebotareva@kpfu.ru

Magid E.A.

magid@it.kfu.ru

Kazan Federal University, Kazan, 42008 Russia

Machine vision is an important component for solving a range of tasks using artificial intelligence. Tasks such as object detection and recognition are key challenges in machine vision. In practice, the implementation of object recognition is widely used in industrial and service robotics. To solve object recognition tasks in robotics, both traditional machine vision algorithms and methods based on deep learning are employed. In the context of educational robotics, the problem of object recognition is closely related to the challenge of efficient implementation of existing solutions on low-powered devices. The aim of this study is to investigate the effectiveness of optimization methods for the YOLOv5 neural network model, using post-training quantization and training with quantization taken into account.

Keywords: computer vision, object detection, deep learning, optimization methods, educational robotics

УДК 543.421

Применение машинного обучения для медицинской диагностики заболеваний по инфракрасным спектрам выдыхаемого человеком воздуха

© Коноплева Алина Алексеевна
Анфимов Дмитрий Романович
Голяк Игорь Семенович
Фуфурин Игорь Леонидович

konopleva.lady@gmail.com
Dimananfimov97@gmail.com
igorgolyak@yandex.ru
igfil@mail.ru

МГТУ им. Н.Э. Баумана, Москва, 105005, Россия

Спектроскопия инфракрасного диапазона на основе квантово-каскадного лазера (ККЛ) представляет собой удобный и быстрый способ идентификации веществ. В среднем инфракрасном диапазоне возможно одновременно регистрировать характерные спектральные линии ряда химических соединений. Диапазон перестройки ККЛ от 5.3 до 12.8 мкм дает возможность применять ИК спектроскопию для обнаружения большего числа веществ, что может найти широкое применение в различных областях. В настоящее время машинное обучение широко используется в различных областях науки, техники, медицины. Данную популярность можно связать с простотой использования и высокой точностью получаемого результата. Представляется актуальным использовать сочетание ИК квантово-каскадной спектроскопии и машинное обучение для идентификации веществ в выдыхаемом воздухе. В данной работе показана возможность применения предложенных методов для анализа спектров выдыхаемого воздуха для диагностики некоторых социально значимых заболеваний.

Ключевые слова: инфракрасная спектроскопия, квантово-каскадный лазер, анализ выдыхаемого воздуха, биомаркер, машинное обучение

Хронические заболевания, такие как диабет, бронхиальная астма и пневмония, относятся к числу наиболее социально значимых заболеваний. Неинвазивная диагностика таких заболеваний является одним из важнейших направлений развития современной медицины. К таким методам относится анализ выдыхаемого воздуха. Выдыхаемый воздух представляет собой сложную газовую смесь, содержащую помимо атмосферных газов продукты основного обмена (CO_2 , H_2O), а также множество газообразных молекул в следовых количествах, некоторые из которых можно использовать в качестве биомаркеров [1, 2].

В данной работе использовалась установка на основе ИК спектроскопии с минимальными обнаружимыми концентрациями на уровне долей ppm, предназначенная для анализа как чистых веществ, так и газовых смесей [3, 4]. Оптическая схема установки представлена на рис. 1.

В качестве источника излучения используется ККЛ LaserTune (Block Engineering). Излучение перестраивается в спектральном диапазоне от 5,3 до

12,8 мкм с шагом перестройки 2 см⁻¹, что обеспечивает достаточно широкую спектральную развертку и позволяет в ИК-диапазоне идентифицировать наибольшее количество веществ. Лазер излучает в импульсном режиме с пиковой мощностью до 150 мВ и средней мощностью около 20 мВ. Длительность импульса составляет около 50 нс, а частота повторения — порядка 1 МГц. Лазер построен по схеме Литтрова В качестве фотоприемного устройства (ФПУ) использовался фотодетектор PVM1-4TE (Vigo System S.A.), состоящий из кадмий-ртуть-теллурового фотодиода с активной площадью 2×2 мм и охлаждаемый элементами Пельтье.

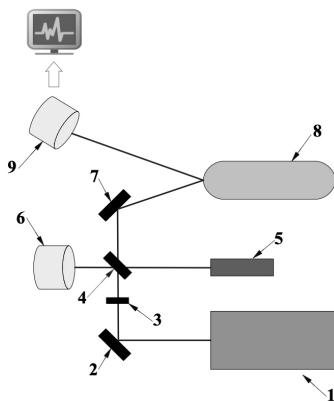


Рис. 1. Оптическая схема установка

ИК излучение от ККЛ 1 отражается на зеркале 2 и через фокусирующую линзу 3 попадает на светоделитель 4. Светоделитель делит ИК излучение на две части: первая часть излучения от светоделителя попадает на опорный фотоприемник 6, а вторая часть (80 %) отражается от зеркала 7 и попадает в газовую кювету Эриотта 8 под углом 30° и выходит под углом 60° относительно входного луча. В кювете при базе 0,32 м происходит до 238 переотражений, что соответствует оптическому пути до 76 м. После прохождения через кювету ИК регистрируется на ФПУ 9. Лазерная указка 5, излучающая в видимом диапазоне и расположенная соосно с ККЛ, использовалась для юстировки ИК-пучка в кювете.

В эксперименте всего приняли 168 волонтера. Волонтеры делились по группам: здоровые, волонтеры с диабетом, волонтеры с бронхиальной астмой и волонтеры с пневмонией.

Для каждого пакета с выдыхаемым воздухом записывалось 10 спектров сигнала и спектр фона. Все спектры были усреднены 100 раз. Для каждого спектра пропускания проводилась коррекция базовой линии путем деления сигнала на фон [5]. Было проведено масштабирование путем вычитания из каждого спектра его собственного среднего значения и деления его на его собственное стандартное отклонение для каждого спектра среднее значение приводилось к нулю, а стандартное отклонение — к единице.

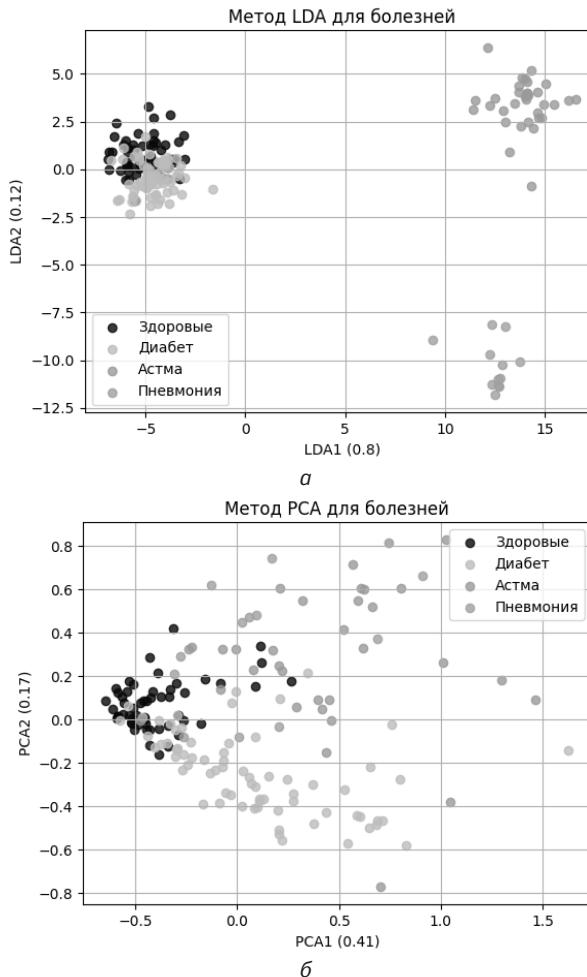


Рис. 2. Визуализация классификации данных с помощью методов:
a – LDA; *b* – PCA

В данной работе с целью уменьшения числа признаков для обеспечения той же точности большей производительностью проводилось понижение размерности. Были использованы такие методы понижения размерности, как метод главных компонент (PCA), линейный дискриминантный анализ (LDA) и стохастическое вложение соседей с *t*-распределением (*t*-SNE) [6]. Наличие избыточных и неинформативных (слабо информативных) признаков может понизить эффективность модели, а после такого преобразования она упрощается, и соответственно уменьшается размер набора данных в памяти и ускоряется работа алгоритмов ML. Количество значимых признаков сократилось до 13. На рис. 2, *a* показан результат применения метода РСА для понижения до двух размерностей с дисперсией 0,64. Для 13 размерностей дисперсия со-

ставляет 95 %, что является достаточным значением для надежной классификации. На рис. 2, б — результат применения метода LDA с дисперсией 0,92. Из рис. 2, б видно, что LDA хорошо кластеризует группы больных астмой и пневмонией, но плохо кластеризует группы здоровых и больных диабетом.

На рис. 3, а показаны результаты кластеризации методом LDA больных диабетом по группам с разными тяжестями заболевания. После чего в LDA подавались только данные больных диабетов после реанимации. На рис. 3, б показана принципиальная возможность кластеризации ИК спектров на группах больных и здоровых волонтеров.

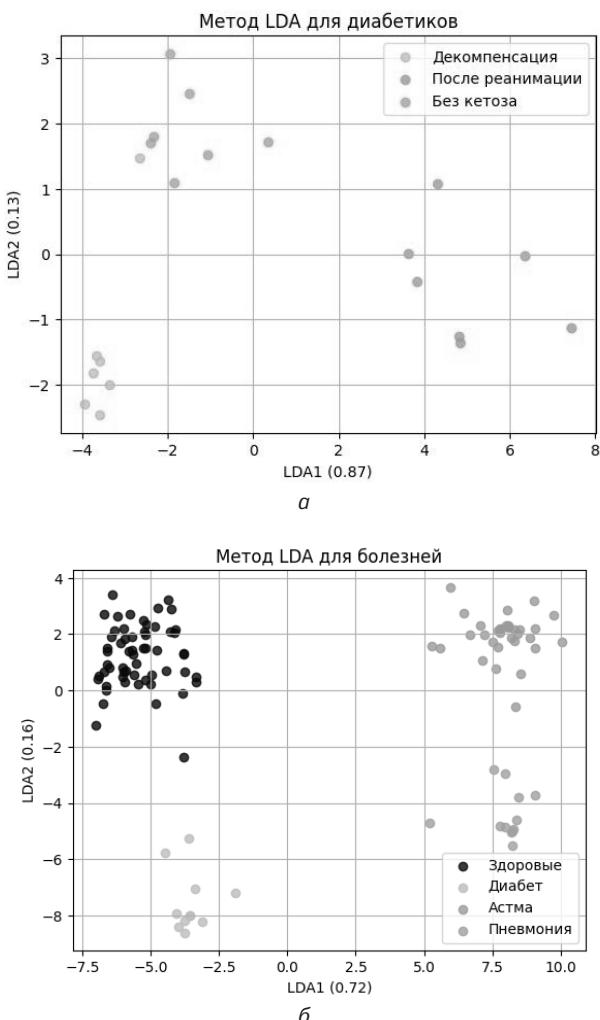


Рис. 3. Кластеризация методом LDA для различных групп:

а — больных диабетом разной тяжести;

б — здоровых, больных диабетом, астмой и пневмонией

В качестве методов машинного обучения были выбраны для сравнения три метода: методов опорных векторов, метод ближайших соседей, логистическая регрессия и метод случайного леса [7]. В таблице приведены результаты классификации экспериментальной выборки на основе данных пониженной размерности (13 признаков). Оценка точности проводилась по метрикам Recall (Чувствительность), Specificity (Специфичность), Precision (Точность). Из полученных результатов видно, что наиболее точным оказался метод логистической регрессии.

Результаты классификации

Методы	Метод опорных векторов (SVM)			Алгоритм случайного леса		
	Recall	Precision	Specificity	Recall	Precision	Specificity
Здоровые волонтеры	0,92	1,0	1,0	0,92	1,0	1,0
Волонтеры с диабетом	1,0	0,87	0,91	1,0	0,87	0,91
Волонтеры с астмой	0,71	0,83	0,96	0,86	0,86	0,96
Волонтеры с пневмонией	0,5	0,5	0,97	0,5	1,0	1,0
Методы	Метод k-ближайших соседей (k-NN)			Логистическая регрессия		
	1,0	0,72	0,77	0,92	1,0	1,0
Здоровые волонтеры	0,85	0,92	0,95	1,0	0,87	0,91
Волонтеры с диабетом	0,71	1,0	1,0	0,71	1,0	1,0
Волонтеры с астмой	0,0	0,0	1,0	1,0	0,67	0,97

Таким образом, в данной работе проведена классификация волонтеров по спектрам с применением методов машинного обучения с высокой степенью точности. Можно сделать вывод, что применение машинного обучения позволяет с высокой точностью определять наличие молекул-биомаркеров различных болезней, что может найти широкое применение в медицине.

Литература

- [1] A European Respiratory Society technical standard: exhaled biomarkers in lung disease. <https://doi.org/10.1183/13993003.00965-2016>
- [2] Stepanov E.V., Kasoev S.G. Multicomponent analysis of biomarkers in exhaled air using diode laser spectroscopy // Opt Spectrosc. 2019. Vol. 126. Pp. 736–744.

-
- [3] Tabalina A.S., Anfimov D.R., Fufurin I.L., Golyak I.S. Infrared quantum cascade laser spectroscopy as non-invasive diagnostic tests for human diseases // Proc SPIE. 2020. Art. 11359. <https://doi.org/10.1117/12.2555042>
 - [4] Fufurin I., Berezhanskiy P., Golyak I., Anfimov D., Kareva E., Scherbakova A., Demkin P., Nebritova A., Morozov A. Deep Learning for Type 1 Diabetes Mellitus Diagnosis Using Infrared Quantum Cascade Laser Spectroscopy // Materials. 2022. Vol. 15 (9). Art. 2984.
 - [5] Boelens H.F., Dijkstra R.J., Eilers P.H., Fitzpatrick F., Westerhuis J.A. New background correction method for liquid chromatography with diode array detection, infrared spectroscopic detection and Raman spectroscopic detection // Journal of Chromatography A. 2004. Vol. 1057 (1-2). Pp. 21–30.
 - [6] Duda R.O., Hart P.E., Stork D.G. Pattern classification. Wiley, 2012. 680 p.
 - [7] Nugrahaeni R.A., Mutijarsa K. Comparative analysis of machine learning K-NN, SVM, and random forests algorithm for facial expression classification // International Seminar on Application for Technology of Information and Communication (ISemantic). 2016. Pp. 163–168. <https://doi.org/10.1109/ISEMANTIC.2016.7873831>
 - [8] Stepanov E.V., Kasoев S.G. Multicomponent analysis of biomarkers in exhaled air using diode laser spectroscopy // Opt Spectrosc. 2019. Vol. 126. Pp. 736–744.
 - [9] Fufurin I., Golyak I., Romanov D., Tabalina A., Kareva E.R., Morozov A., Demkin P. Machine learning applications for spectral analysis of human exhaled breath for early diagnosis of diseases // Proc. SPIE 11553, Optics in Health Care and Biomedical Optics X, 115531G. October 10, 2020. <https://doi.org/10.1117/12.258404>

The use of Machine Learning for Medical Diagnosis of Diseases by Infrared Spectra of Human Exhaled Air

✉ Konopleva A.A.	konopleva.lady@gmail.com
Anfimov D.R.	Dimananfimov97@gmail.com
Golyak I.S.	igorgolyak@yandex.ru
Fufurin I.L.	igfil@mail.ru

BMSTU, Moscow, 105005, Russia

Infrared spectroscopy based on a quantum cascade laser (CCL) is a convenient and fast way to identify substances. In the mid-infrared range, it is possible to simultaneously register the characteristic spectral lines of a number of chemical compounds. The CCL adjustment range from 5.3 to 12.8 microns makes it possible to use IR spectroscopy to detect a larger number of substances, which can be widely used in various fields. Currently, machine learning is widely used in various fields of science, technology, and medicine. This popularity can be attributed to the ease of use and high accuracy of the result obtained. It seems relevant to use a combination of IR quantum cascade spectroscopy and machine learning to identify substances in exhaled air. This paper shows the possibility of using the proposed methods to analyze the spectra of exhaled air for the diagnosis of some socially significant diseases.

Keywords: *infrared spectroscopy, quantum cascade laser, exhaled air analysis, biomarker, machine learning*

УДК 004.89

Выявление групп спроса на станочное оборудование посредством интеллектуального анализа и обоснованной кластеризации данных из таможенных документов

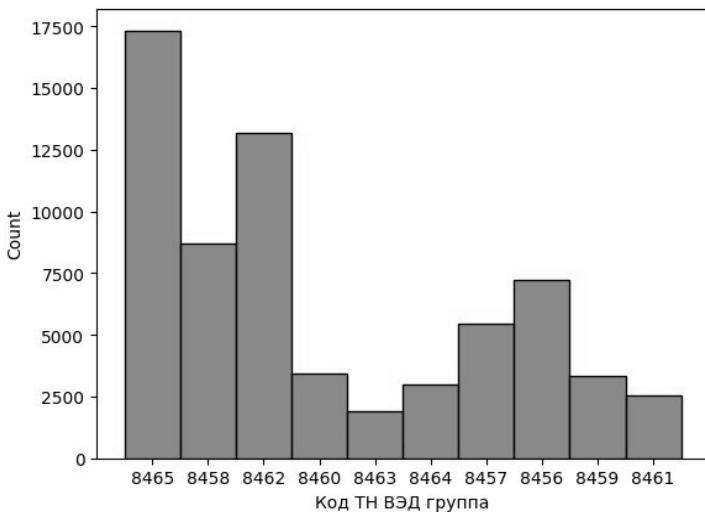
©	Масич Игорь Сергеевич	i-masich@yandex.ru
	Суханов Денис Александрович	dsuhanov@emtc.ru
	Медведев Андрей Васильевич	amedvedev@emtc.ru
	Строганов Павел Андреевич	pstroganov@emtc.ru

МГТУ им. Н.Э. Баумана, НОЦ «Технологии искусственного интеллекта»,
Москва, 105005, Россия

Статья посвящена исследованию возможности применения методов кластеризации текстовой информации для обоснованного выявления сегментов рынка промышленного оборудования. Объектом интеллектуального анализа являются данные, собранные из таможенных документов, которые оформляются на импортируемое промышленное оборудование. Результатом исследования являются кластеры или группы станков, которые позволяют экспертам в промышленном оборудовании принимать решения по развитию импортозамещения той или иной группы оборудования.

Ключевые слова: кластеризация, анализ текстов, обнаружение подгрупп, промышленное оборудование, станки

Введение. Анализ спроса на станочное оборудование является актуальной практической задачей. В данном исследовании рассматриваются возможности применения интеллектуального анализа данных для обоснованного выявления сегментов промышленного оборудования. Одним из наиболее важных источников информации для такого анализа являются данные, собранные из таможенных документов, которые оформляются на ввозимое станочное оборудование. Эти данные отображают актуальный спрос на станки. Исходные данные представляют собой статистику импорта/экспорта промышленных станков за период с 2017 по 2022 г. Основные параметры: дата таможенных операций, код ТН ВЭД, наименование, производитель, страна происхождения, стоимость единицы, вес единицы, количество. В исходном датасете 66165 записей, представлены 223 кода ТН ВЭД. Распределение станков по кодам ТН ВЭД представлено на рисунке. К сожалению, имеющаяся в таких данных группировка по кодам товарной номенклатуры внешнеэкономической деятельности (ТН ВЭД) не является достаточной для определения спроса по сегментам рынка. Эта группировка является довольно обобщенной, кроме того, код ТН ВЭД может быть указан некорректно, а некоторое оборудование может задаваться разными кодами. Таким образом, имеется актуальная задача выделения обоснованных кластеров (сегментов/ниш) рынка, на которые был спрос в течение 5 лет.



Распределение станков по кодам ТН ВЭД

Материалы и методы. В связи с тем что на практике код ТН ВЭД и стоимость оборудования могут быть указаны не корректно, анализ данных был произведен на основе указанных наименований и веса станков. Анализ данных состоял из следующих этапов: 1) обработка текстовых данных; 2) кластерный анализ векторизованных данных; 3) обнаружение подгрупп.

С помощью методов анализа текстов, были произведены процедуры токенизации (разбиение на отдельные слова), лемматизации (неопределенная форма для различных частей речи), и векторизация текста. Для векторизации использовалось три различных метода, результаты применения в табл. 1.

Таблица 1. Соотношение метрики к типу моделей и набору данных

Метод / метрика	F-мера	Точность
Мешок слов	0,670	0,671
Tf-Idf	0,593	0,620
Word2Vec	0,022	0,023

При векторизации был использован список стоп-слов, или шумовых слов: предлоги, союзы, междометия и т. п. — итого 151 слово. Наилучшие результаты показал метод векторизации «Мешок слов» и Tf-Idf. В качестве гиперпараметра метода, было выбрано 1500 самых популярных слов, встречающихся в названиях станков. Данный гиперпараметр может быть оптимизирован для улучшения финального результата кластеризации. К полученному датасету (размерность 66165, 1500) были применены алгоритмы кластеризации DBSCAN и KMeans с различными гиперпараметрами.

Для определения наиболее подходящего числа кластеров использовалась индекс S_Dbw , который учитывает как внутрикластерное расстояние, так и межкластерную плотность:

$$S_Dbw(C) = Scat(C) + Dens_bw(C).$$

Определение S_Dbw указывает, что оба критерия «хорошей» кластеризации (т. е. компактность и разделение) должным образом объединены, что позволяет надежно оценивать результаты кластеризации. Первый член $Scat(C)$ показывает среднее рассеяние внутри кластеров с. Небольшое значение этого термина является показателем компактных кластеров. $Dens_bw(C)$ показывает среднее число точек между кластерами с (т. е. показывает плотности между кластерами) по отношению к плотности внутри кластеров. Небольшое значение $Dens_bw(C)$ указывает на хорошо разделенные кластеры. Число кластеров c , которое минимизирует вышеуказанный индекс, можно рассматривать как оптимальное значение для числа кластеров, присутствующих в наборе данных.

Основная идея заключается в том, что для каждой пары центров кластеров по крайней мере одна из их плотностей должна быть больше плотности их средней точки (посередине между двумя центрами). Индекс представляет собой суммирование этих двух членов, и минимальное значение S_Dbw указывает на оптимальное число кластеров. S_Dbw — это единственная внутренняя мера валидации, которая хорошо работает во всех аспектах (влияние монотонности, шума, плотности, подкластеров, разноразмерных распределений), в то время как другие меры имеют определенные ограничения в различных ситуациях, главным образом при наличии шума и подкластеров [2].

Результаты. Результаты кластеризации методом DBSCAN приведены в табл. 2, результаты кластеризации методом KMeans приведены в табл. 3.

Таблица 2. Результаты кластеризации методом DBSCAN

eps	0,5	0,8	0,5	0,5
min_samples	5	5	4	3
Кол-во кластеров	1 340	1 340	1 878	2 951
Кол-во записей шума	46 857	46 857	44 705	41 486

Таблица 3. Результаты кластеризации методом KMeans

n_clusters	20	50	100	200	250	250	300	500
init	random	random	random	random	random	k-means++	random	random
S_Dbw	0,84	0,77	0,74	0,68	0,65	0,65	0,67	0,61

После сравнения результатов кластеризации, а также принимая во внимание специфику задачи и предметной области, можно сделать вывод, что наилучшим вариантом кластеризации является KMeans, 250 кластеров.

Была выдвинута гипотеза о том, что поле датасета «Код ТН ВЭД» — товарная номенклатура внешнеэкономической деятельности — достаточно хорошо характеризует разнообразие станков. Количество уникальных кодов ТН ВЭД в датасете — 223. Число кластеров было выбрано исходя из количества уникальных значений поля «Код ТН ВЭД». В следующей серии экспериментов использовался метод кластеризации KMeans с количеством кластеров 223, а также были опробованы различные гиперпараметры и подходы к обработке данных. Результаты экспериментов приведены в табл. 4.

Таблица 4. Результаты кластеризации методом KMeans, 223 кластера

№	Коли-чество кластеров	Вектори-зация названия	Предобработка датасета	Adjusted Rand-Index	Silhouette Coeffi-cient
1	223	Tfidf	На всех записях датасета	0,115	0,114
2	151	Tfidf	Группировка по коду ТН ВЭД и наименованию станка. Отбор кодов ТН ВЭД размером более 10 записей датасета	0,111	0,066
3	223	Tfidf	На всех записях датасета. С учетом «Стоимости» и «Веса» станка	0,027	0,119
4	223	Count Vectorizer	На всех данных	0,087	0,059
5	223	Tfidf	На всех данных. С учетом «Стоимости» и «Веса» станка, предобработка OneHot Encoding	0,031	0,098

Коэффициент силуэта (Silhouette Coefficient) позволяет оценить степень соответствия построенной кластерной структуры обучающим данным, т. е. оценить качество кластеризации. Наилучшим подходом стал эксперимент №3, в котором использовалась векторизация названия станка методом Tfidf, с учетом полей датасета «Стоимость» и «Вес» станка. Было проверено соответствие результатов кластеризации исходной группировке станков по кодам «Код ТН ВЭД», по метрике Adjusted Rand-Index — среднее значение 0,074 — можно сделать вывод о несоответствии кластеризации по названию станков кодам ТН ВЭД.

Разделения объектов на кластеры, полученное с помощью методов кластеризации, само по себе не дает описания групп, которое может быть обос-

нованно использовано для обозначения сегментов рынка. К примеру, центроиды полученных кластеров выглядят следующим образом:

Cluster 0: ЧПУ станок числовым управлением виде программным центр разобранных линия обработки

Cluster 1: следующие состав штука компоненты штамповки линии линия предназначена производства деталей Cluster 2: привода 40 системой пресс усилием программным числовым управлением использования используемых

Cluster 3: горячей автомобилей 02 кривошипный усилием других штамповки цилиндрических модели заготовок

Cluster 4: прессования торговая алюминиевых сплавов марка линия используются использованием использования используемых

Cluster 5: горячей черных высота кривошипный усилием пресса ширина цветных штамповки мм

Для описания полученных кластеров был использован метод обнаружения подгрупп и описания их с помощью их логических выражений [3]. Логические выражения или паттерны являются полезным инструментом для поддержки принятия решений при классификации объектов [4].

Обнаружение подгрупп — это метод интеллектуального анализа данных, который позволяет выявлять закономерности в данных. Цель обнаружения подгрупп состоит в том, чтобы идентифицировать описания подмножеств данных, которые показывают подходящее распределение по отношению к заранее заданному целевому понятию. Для проведения экспериментов использовалась реализация Pysubgroup [5]. Исходными данными является векторизованный текст с метками, полученными в результате кластерного анализа.

В качестве оценочной меры выделяемых подгрупп использовалась следующая функция качества:

$$QF = \left(\frac{N_{SG}}{N} \right)^\alpha \left(\frac{p_{SG}}{N_{SG}} - \frac{p}{N} \right),$$

где α — это настраиваемый параметр, N — общее число объектов, p — число положительных (целевых) объектов (число объектов в кластере), N_{SG} — число объектов в выделяемой подгруппе, p_{SG} — число объектов преобладающего класса в выделяемой подгруппе. QF использует α , чтобы настроить влияние отношения N_{SG}/N . Согласно [6], в экспериментах мы использовали значение $\alpha = 1$. Для оценки паттерна также используется доля целевых значений (*Target_share_sg*), которая определяется как отношение p_{SG}/N_{SG} .

Для интерпретации результатов кластеризации эксперимента № 3 была проведена процедура обнаружения подгрупп и формирования паттернов/правил, которые характеризуют тот или иной кластер. На вход процедуры обнаружения подгрупп (Pysubgroup) подавался датасет, состоящий из булевых значений (1 — слово есть в записи, 0 — слова нет в записи), совмещенный с метками кластеров (mark). Кроме того, были внесены изме-

нения в селекторы процедуры обнаружения подгрупп, были использованы только правила/паттерна, которые состоят из конъюнкции признаков без отрицания, т.е. без отрицания содержащихся слов в названии станка. В таблице XX приведены несколько примеров описания кластеров, из 10 наибольших по размеру кластеров.

Таблица 5. Интерпретация результатов кластеризации процедурой обнаружения подгрупп

№ кла- стера	Качество (QF)	Подгруппа	Коли- чество записей	pSG	Target_ shareSG
54	0,012447	станок==1 AND чпу==1	5816	720	0,123796424
	0,011593	чпу==1	14489	828	0,057146801
	0,008692	станок==1	17907	743	0,041492154
	0,003121	предназначен==1 AND станок==1 AND чпу==1	1772	186	0,104966140
	0,002921	предназначен==1 AND чпу==1	3212	201	0,062577833
	0,002175	предназначен==1 AND станок==1	4658	189	0,040575354
	0,001724	металлообрабатывающий==1 AND станок==1 AND чпу==1	592	96	0,162162162
	0,001591	металлообрабатывающий==1 AND чпу==1	1259	101	0,080222399
	0,001552	металлообрабатывающий==1 AND станок==1	1256	99	0,078821656
	0,001407	предназначен==1	8070	210	0,026022305
68	0,007824	резки==2	699	400	0,572246066
	0,005050	резки==1	3652	308	0,084337349
	0,004074	плазменной==1	411	209	0,508515815
	0,004039	металла==1	4247	267	0,062867907
	0,003366	резки==2 AND станок==1	294	172	0,585034014
	0,002629	установка==1	978	146	0,149284254
	0,002317	лазерной==1	1076	132	0,122676580
	0,002292	металла==1 AND резки==2	193	117	0,606217617
	0,002221	металла==1 AND резки==1	1061	127	0,119698398
	0,002169	предназначен==1 AND резки==2	200	111	0,555000000
72	0,014112	виде==1 AND военного==1	2059	734	0,356483730
	0,013534	военного==1 AND разобранном==1	1978	704	0,355915066
	0,013517	военного==1	5942	765	0,128744530
	0,013232	виде==1 AND военного==1 AND назначения==1	1914	688	0,359456635
	0,013171	виде==1 AND назначения==1	2239	690	0,308173292
	0,013074	виде==1 AND военного==1 AND разобран- ном==1	1907	680	0,356581017

Окончание табл. 5

№ кластера	Качество (QF)	Подгруппа	Количество записей	p _{SG}	Target_share _{SG}
72	0,012826	военного==1 AND частично==1	1928	668	0,346473029
	0,012732	военного==1 AND назначения==1	5433	718	0,132155347
	0,012691	военного==1 AND назначения==1 AND разобранном==1	1844	660	0,357917570
	0,012638	назначения==1 AND разобранном==1	2142	662	0,309056956
78	0,01656	станок==1	17907	184 0	0,102753113
	0,003344	деревообрабатывающий==1	1298	240	0,184899846
	0,003187	деревообрабатывающий==1 AND станок==1	1066	219	0,205440901
	0,001703	пила==1	446	110	0,246636771
	0,00164	мод==1 AND станок==1	941	135	0,143464400
	0,001506	пильный==1	742	117	0,157681941
	0,001446	компоненты==1	442	97	0,219457014
	0,001334	станок==1 AND шлифовальный==1	716	107	0,149441341
	0,001297	ixc==1 AND станок==1	643	101	0,157076205
	0,001258	деревообрабатывающий==1 AND мод==1	307	80	0,260586319

Обсуждение. Для оценки качества проведенной кластеризации по смыслу необходима проверка полученных результатов экспертом предметной области. Предварительно, полученные кластеры можно разделить на информативные и не информативные. К последним относится кластер № 72, например, который соответствует всем станкам не военного назначения, — слово «военный», а точнее, отрицание «не военный» встречается в 14 % названий всех станков. Вероятно, это связано со спецификой таможенного оформления оборудования для военных и не военных целей, поэтому упоминание словосочетания «не военный» очень популярно в названии станков.

Примерами информативных кластеров могут послужить кластеры:

- 68 — станки для резки металла плазменной или лазерной;
- 78 — станки деревообрабатывающие пильные или шлифовальные.

Кластер 78 требуется разделить на разные подгруппы:

- станки деревообрабатывающие пильные;
- станки деревообрабатывающие шлифовальные.

Для этой цели в продолжении данного исследования в будущем потребуется более точно настроить гиперпараметры используемых методов (например, параметр α обнаружения подгрупп) и подходы к обработке данных — на основании обратной связи от эксперта предметной области.

Выводы. Для обработки данных из таможенных документов по импорту/экспорту станков применены методы интеллектуального анализа данных —

обработки текстовых данных, кластерного анализа, обнаружения подгрупп. Векторизованные данные характеризуются большим числом признаков (число разных используемых слов в наименованиях оборудования). Особенностью задачи является также наличие большого числа кластеров. В исходном наборе данных выявлены подгруппы объектов, которые описаны логическими выражениями. С помощью такого описания подгруппу станков можно определить набором слов, которые характеризуют эту подгруппу.

Наличие подобных задач показывает необходимость развития следующих методов интеллектуального анализа данных: обработка текстовых данных, методы решения задач обучения без учителя, интерпретируемое машинное обучение (построение разреженных логических моделей).

Литература

- [1] Halkidi M., Vazirgiannis M. Clustering validity assessment: Finding the optimal partitioning of a data // ICDM. Washington, DC, USA. 2001. Pp. 187–194.
- [2] Liu Y., Li Z., Xiong H., Gao X., Wu J. Understanding of internal clustering validation measures // IEEE International Conference on Data Mining. 2010. Pp. 911–916.
<https://doi.org/10.1109/ICDM.2010.35>
- [3] Herrera F., Carmona C.J., González P., Del Jesus M.J. An overview on subgroup discovery: Foundations and applications // Knowledge and Information Systems. 2010. Vol. 29 (3). Pp. 495–525.
- [4] Masich I.S., Tyncheko V.S., Nelyub V.A., Bukhtoyarov V.V., Kurashkin S.O., Borodulin A.S. Paired patterns in logical analysis of data for decision support in recognition // Computation. 2022. Vol. 10 (10). Art. 185.
- [5] Lemmerich F., Becker M. Pysubgroup: Easy-to-use subgroup discovery in python // Joint European Conference on Machine Learning and Knowledge Discovery in Databases (ECMLPKDD). 2018, September. Pp. 658–662.
- [6] Lemmerich F. Novel Techniques for Efficient and Effective Subgroup Discovery. Doctoral Thesis, 2014.
- [7] Popat Sh.K., Emmanuel M. Review and comparative study of clustering techniques. 2014.
- [8] Anastasiu D.C., Tagarelli A., Karypis G. Document Clustering: The Next Frontier. 2013.
- [9] Aggarwal Charu C, Reddy Chandan K. Data clustering: algorithms and applications. CRC Press, 2013.
- [10] Mikolov T., Chen K., Corrado G. et al. Efficient estimation of word representations in vector space. arXiv preprint, arXiv:1301.3781. 2013.
- [11] Pengtao X., Xing E.P. Integrating document clustering and topic modeling. arXiv preprint, arXiv:1309.6874. 2013.
- [12] Romano S., Nguyen Xuan Vinh, Bailey J. et al. Adjusting for Chance Clustering Comparison Measures. arXiv preprint, arXiv:1512.01286. 2015.
- [13] van Craenendonck T., Blockeel H. Using internal validity measures to compare clustering algorithms. AutoML Workshop at ICML. 2015. Pp. 1–8.
- [14] Field A. Discovering statistics using IBM SPSS statistics. Sage, 2013.

Identification of Demand Groups for Machine Tools Through Intellectual Analysis and Reasonable Clustering of Data from Customs Documents

© **Masich I.S.**
Sukhanov D.A.
Medvedev A.V.
Stroganov P.A.

i-masich@yandex.ru
dsuhanov@emtc.ru
amedvedev@emtc.ru
pstroganov@emtc.ru

BMSTU, SEC "AI Technologies", Moscow, 105005, Russia

The article is devoted to the study of the possibility of using methods of clustering textual information for a reasonable identification of segments of the industrial equipment market. The object of intellectual analysis is data collected from customs documents that are issued for imported industrial equipment. The result of the study are clusters or groups of machines that allow experts in industrial equipment to make decisions on the development of import substitution of a particular group of equipment.

Keywords: clustering, text analysis, subgroup discovery, industrial equipment, machine tools

УДК 004.08

Исследование возможности нахождения аномалий в сетевом трафике с помощью алгоритмов кластеризации, валидации и применения метода косинусной близости

© Соколов Григорий Владимирович g.sokolov@baumlab.pro
Шучалин Григорий Васильевич g.shuchalin@baumlab.pro
Гантимуров Андрей Павлович a@baumlab.pro

МГТУ им. Н.Э. Баумана, НОЦ «Технологии искусственного интеллекта»,
Москва, 105005, Россия

Исследована возможность нахождения аномалий в сетевом трафике с помощью алгоритмов кластеризации, последующей валидации и применения метода косинусной близости. Рассмотрены методы предобработки и подготовки данных. В конце статьи сделан вывод о перспективных методах использования полученных результатов. Хорошо обученный алгоритм DBSCAN в связке с Apache Spark может быть использован в системах информационной безопасности. Кроме того, используя полученные данные и дополнительные методы, можно продолжить исследование применения алгоритма в отношении других направлений, таких как разработка комплексных систем защиты данных и безопасность информационных технологий и систем в целом. Заложенные данные могут позволить в дальнейшем определять зоны риска информационной безопасности и оценивать вероятность утечки данных из системы.

Ключевые слова: сетевой трафик, алгоритмы кластеризации, DBSCAN

Введение. Информационная безопасность — это практика предотвращения несанкционированного доступа, использования и раскрытия информации. В современных государственных и частных компаниях, в условиях высокой нагрузки на систему и большого количества производимых операций, существует риск нарушения информационной безопасности внутренних сетей предприятий [1, 2]. Сегодня предотвращение утечек данных является главным приоритетом для ИТ отрасли и вторым для безопасности организаций [3]. При этом причиной 85 % утечек данных является человеческий фактор [4, 5].

В таких условиях потребность в специалистах и прогрессивных технологиях для предотвращения нарушений информационной безопасности постоянно растет.

Методы для улучшения информационной безопасности помогают защитить данные от взлома или повреждения, а также снизить восприимчивость систем к ущербу в целом.

Одним из таких методов снижения рисков информационной безопасности может стать использование технологий машинного обучения — для предотвращения несанкционированного доступа пользователей к данным и защиты сетей от различного вида кибер угроз.

Целью данного исследования является определение возможности нахождения аномалий в сетевом трафике с помощью алгоритмов кластеризации, валидации и применения метода косинусной близости. Конечная цель исследования — повышение информационной безопасности во внутренней сети организаций и снижение рисков противоправных действий со стороны пользователей.

Материалы и методы. Для решения задачи нахождения аномалий в сетевом трафике был взят за основу следующий принцип — каждое противоправное действие пользователя считать аномалией. Также было принято решение разделить все сессии на обычные и аномальные, после чего предоставить сотрудникам информационной безопасности возможность валидировать и размечать сессии.

Для выполнения поставленной задачи требовалось провести кластеризацию интернет-соединений и выявить аномалии, после чего провести их валидацию. Также стояла задача настроить нахождение похожих соединений по входному вектору с помощью метода косинусной меры.

В качестве источника входных данных был получен датасет объемом 1,5 Гб строк со следующими признаками:

- Время соединения;
- IP-адрес клиента;
- IP-адрес сервера;
- длительность соединения;
- информация о соединении;
- Protocol.

Цель кластеризации — разметка и создание обучающего набора данных.

Процесс кластеризации состоит из четырех этапов:

- получение сырых данных (загрузка);
- предобработка (подготовка данных);
- обучение без учителя (кластеризация и разметка);
- сохранение результатов.

Входные данные для задачи анализа. Кластеризация проводилась через алгоритм DBSCAN (Density-Based Spatial Clustering of Applications with Noise) — это алгоритм на основе плотности, который делит область с достаточно высокой плотностью на кластеры и находит кластеры любой формы в зашумленной пространственной базе данных. DBSCAN был выбран, так как не было известно общее количество кластеров.

DBSCAN объединяет сессии в кластеры по признакам: минимальное количество ближайших соседей, расстояние до ближайших соседей и метрика расстояния. Была выдвинута гипотеза, что аномалий во внутренней сети предприятия будет мало, поэтому кластеры с малым количеством сессий будут являться аномалиями.

Для исследования были взяты первые 10 тысяч строк датасета, показанные на рис. 1.

В качестве признаков для кластеризации решено было сначала использовать столбцы Length и Protocol. Далее добавлять новые признаки.

	Time	Source	Destination	Protocol	Length	Info
0	2021-08-25 09:07:24,238759	[REDACTED]	[REDACTED]	TCP	66	9400 > 49323 [SYN, ACK] Seq=0 Ack=1 Win=8192...
1	2021-08-25 09:07:24,435889	[REDACTED]	[REDACTED]	TCP	252	9400 > 49323 [PSH, ACK] Seq=1 Ack=149 Win=26...
2	2021-08-25 09:07:24,435912	[REDACTED]	[REDACTED]	HTTP/JSON	60	HTTP/1.1 200 OK , JavaScript Object Notation (...)
3	2021-08-25 09:07:34,130115	[REDACTED]	[REDACTED]	TCP	479	9400 > 49323 [PSH, ACK] Seq=204 Ack=508 Win=...
4	2021-08-25 09:07:34,130140	[REDACTED]	[REDACTED]	HTTP/JSON	60	HTTP/1.1 200 OK , JavaScript Object Notation (...)
5	2021-08-25 09:07:35,402073	[REDACTED]	[REDACTED]	TCP	66	9400 > 49341 [SYN, ACK] Seq=0 Ack=1 Win=8192...
6	2021-08-25 09:07:35,407029	[REDACTED]	[REDACTED]	HTTP	199	HTTP/1.1 401 Unauthorized
7	2021-08-25 09:07:36,111179	[REDACTED]	[REDACTED]	TCP	66	9400 > 49346 [SYN, ACK] Seq=0 Ack=1 Win=8192...
8	2021-08-25 09:07:36,116324	[REDACTED]	[REDACTED]	TCP	60	9400 > 49346 [ACK] Seq=1 Ack=2801 Win=262400...
9	2021-08-25 09:07:36,125299	[REDACTED]	[REDACTED]	TCP	470	9400 > 49346 [PSH, ACK] Seq=1 Ack=2851 Win=2...

Рис. 1. Датасет

Категориальный признак Protocol был закодирован методом LabelEncoder, далее над всеми признаками была проведена стандартизация, показанная на рис. 2.

	Time	Source	Destination	Length	Info	Protocol_HTTP	Protocol_HTTP/JSON	Protocol_TCP
0	2021-08-25 09:07:24,238759	[REDACTED]	[REDACTED]	-0.492090	9400 > 49323 [SYN, ACK] Seq=0 Ack=1 Win=8192...	-0.576888	-0.078342	0.586280
1	2021-08-25 09:07:24,435889	[REDACTED]	[REDACTED]	-0.409647	9400 > 49323 [PSH, ACK] Seq=1 Ack=149 Win=26...	-0.576888	-0.078342	0.586280
2	2021-08-25 09:07:24,435912	[REDACTED]	[REDACTED]	-0.494749	HTTP/1.1 200 OK , JavaScript Object Notation (...)	-0.576888	12.764577	-1.705668
3	2021-08-25 09:07:34,130115	[REDACTED]	[REDACTED]	-0.309032	9400 > 49323 [PSH, ACK] Seq=204 Ack=508 Win=...	-0.576888	-0.078342	0.586280
4	2021-08-25 09:07:34,130140	[REDACTED]	[REDACTED]	-0.494749	HTTP/1.1 200 OK , JavaScript Object Notation (...)	-0.576888	12.764577	-1.705668
5	2021-08-25 09:07:35,402073	[REDACTED]	[REDACTED]	-0.492090	9400 > 49341 [SYN, ACK] Seq=0 Ack=1 Win=8192...	-0.576888	-0.078342	0.586280
6	2021-08-25 09:07:35,407029	[REDACTED]	[REDACTED]	-0.433139	HTTP/1.1 401 Unauthorized	1.733438	-0.078342	-1.705668
7	2021-08-25 09:07:36,111179	[REDACTED]	[REDACTED]	-0.492090	9400 > 49346 [SYN, ACK] Seq=0 Ack=1 Win=8192...	-0.576888	-0.078342	0.586280
8	2021-08-25 09:07:36,116324	[REDACTED]	[REDACTED]	-0.494749	9400 > 49346 [ACK] Seq=1 Ack=2801 Win=262400...	-0.576888	-0.078342	0.586280
9	2021-08-25 09:07:36,125299	[REDACTED]	[REDACTED]	-0.313021	9400 > 49346 [PSH, ACK] Seq=1 Ack=2851 Win=2...	-0.576888	-0.078342	0.586280

Рис. 2. Признак Protocol закодированный методом LabelEncoder

Необходимо было подтверждение гипотезы о том, что аномалий во внутренней сети предприятия будет мало, поэтому кластеры с малым количеством сессий будут являться аномалиями. Для подтверждения гипотезы было принято дополнительное решение — использовать для обработки данных open-source фреймворк Apache Spark, который разбивает поток данных на пакеты временных интервалов. Его логика показана на рис. 3.

Результаты. На следующем этапе необходимо было выполнить валидацию разметки найденных потенциальных аномалий. Для этого отобранные кластеры были переданы специалистам по информационной безопасности, которые либо валидировали данные, либо нет. В результате был получен созданный обучающий датасет для алгоритмов кластеризации.

Для специалистов по информационной безопасности дополнительно был создан дашборд с необходимым функционалом, показанный на рис. 4.

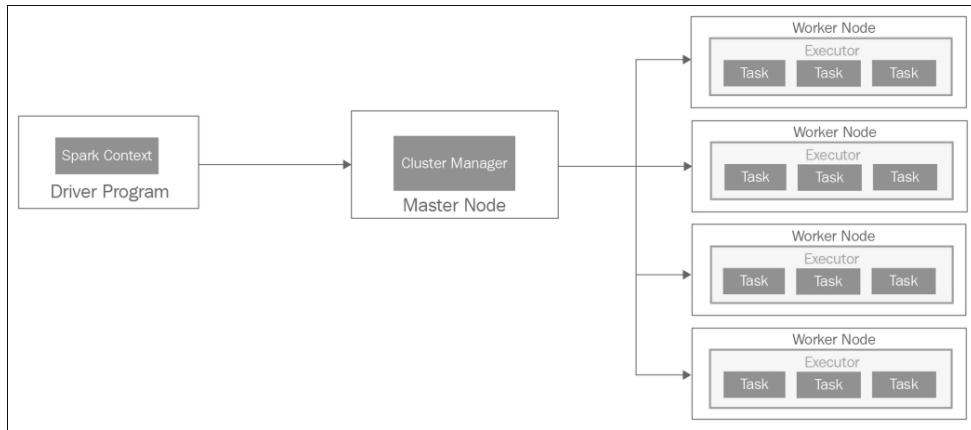


Рис. 3. Логика работы Apache Spark

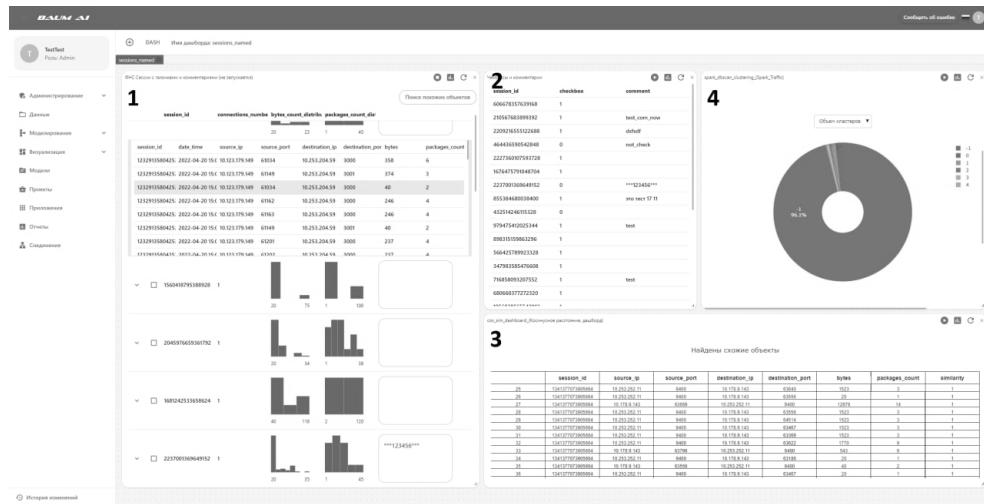


Рис. 4. Дашборд:

1 — аномальные сессии для валидации сотрудником, с возможностью комментария и детального просмотра сессии; 2 — таблица, где показаны сессии которые подтвердил или прокомментировал сотрудник информационной службы безопасности; 3 — найденные похожие объекты, не подтвержденные аномальные сессии в формате таблицы с соединениями; 4 — диаграмма с процентом найденных аномалий от общего числа

Также был применен поиск похожих объектов по методу косинусной близости. Косинусная близость — мера сходства между двумя ненулевыми векторами внутреннего пространства. Он определяется как равный косинусу угла между ними, который также совпадает с внутренним произведением тех же векторов, нормализованных на единицу. Косинус 0° равен 1, и он меньше 1

для любого угла в интервале $(0, \pi]$ радиан. Это оценка ориентации, а не величины: два вектора с одинаковой ориентацией имеют косинусное сходство 1, два вектора, ориентированных под углом 90° относительно друг друга, имеют подобие 0, а два диаметрально противоположных вектора имеют подобие -1 , независимо от их величины.

Косинусная мера позволяет сравнивать аномальный объект (входной вектор) с объектами из датасета и находить по косинусному расстоянию ближайшие объекты, которые также могут считаться аномалиями.

Для проверки работы метода в качестве входного вектора была взята вторая строка датасета (индекс 1) с признаками Length, Protocol_HTTP, Protocol_HTTP/JSON, Protocol_TCP, показанная на рис. 5.

	Time	Source	Destination	Length	Info	Protocol_HTTP	Protocol_HTTP/JSON	Protocol_TCP
0	2021-08-25 09:07:24.238759	[REDACTED]	[REDACTED]	-0.492090	9400 > 49323 [SYN, ACK] Seq=0 Ack=1 Win=8192...	-0.576888	-0.078342	0.586280
1	2021-08-25 09:07:24.435889	[REDACTED]	[REDACTED]	-0.409647	9400 > 49323 [PSH, ACK] Seq=1 Ack=149 Win=26...	-0.576888	-0.078342	0.586280
2	2021-08-25 09:07:24.435912	[REDACTED]	[REDACTED]	-0.494749	HTTP/1.1 200 OK , JavaScript Object Notation (...)	-0.576888	12.764577	-1.705668
3	2021-08-25 09:07:34.130115	[REDACTED]	[REDACTED]	-0.309032	9400 > 49323 [PSH, ACK] Seq=204 Ack=508 Win=...	-0.576888	-0.078342	0.586280
4	2021-08-25 09:07:34.130140	[REDACTED]	[REDACTED]	-0.494749	HTTP/1.1 200 OK , JavaScript Object Notation (...)	-0.576888	12.764577	-1.705668

Рис. 5. Датасет

Обсуждение. Как видно из результатов эксперимента, выдвинутая гипотеза сработала — благодаря алгоритму кластеризации DBSCAN удалось найти кластеры с небольшим количеством объектов и обнаружить аномалии среди них. Также был применен еще один метод для определения аномалий — косинусная мера, которая позволяет сравнивать аномальный объект (входной вектор) с объектами из датасета и находить по косинусному расстоянию ближайшие объекты, которые также могут считаться аномалиями.

Было проанализировано более 80 тысяч сессий, включающих 40 млн соединений. Самая короткая сессия составила 2 соединения, самая длинная — 120 тысяч соединений. В результате было получено три кластера и найдено 45 аномалий. При этом кластер 1 содержит 61 объект, что тоже может говорить о редкости и аномальности содержащихся в нем объектов. Пример результатов показан на рис. 6.

Результат работы алгоритма:
Лучшие гиперпараметры:
Eps = 1, min_samples = 20, metric = 'chebyshev'
Лучшая метрика silhouette_score = 0.816
Количество кластеров = 3
Количество объектов без кластера = 45

Рис. 6. Результат работы алгоритма DBSCAN

Учитывая, что это был экспериментальный подход в распределенном вычислении с помощью Apache Spark и первое применение двух фреймворков вместе, временные промежутки расчетов не показали большой эффективности. В дальнейшем планируется улучшение алгоритма DBScan + Apache Spark с помощью оптимизации конфигурации Spark сессий. Также планируется использование данного подхода для автоматизации решения поиска аномалий.

Заключение. Полученные характеристики свидетельствуют о способности алгоритма DBSCAN к нахождению кластеров и обнаружению аномалий во внутренней сети. Этот факт может свидетельствовать о возможности дальнейшего исследования данного алгоритма с целью повышения точности.

Хорошо обученный алгоритм DBSCAN в связке с Apache Spark может быть использован в системах информационной безопасности. Кроме того, используя полученные данные и дополнительные методы, возможно продолжить исследование применения алгоритма в отношении других направлений, таких как разработка комплексных систем защиты данных и безопасность информационных технологий и систем в целом.

Заложенные данные могут позволить в дальнейшем определять зоны риска информационной безопасности и оценивать вероятность утечки данных из системы. Все это свидетельствует о перспективности исследований в области информационной безопасности с применением методов искусственного интеллекта.

Литература

- [1] Masich I.S. et al. Paired patterns in logical analysis of data for decision support in recognition // Computation. 2022. Vol. 10, no. 10. Art. 185.
- [2] Mikhalev A.S. et al. The Orb-weaving spider algorithm for training of recurrent neural networks // Symmetry. 2022. Vol. 14, no. 10. Art. 2036.
- [3] Masich I.S. et al. Prediction of critical filling of a storage area network by machine learning methods // Electronics. 2022. Vol. 11, no. 24. Art. 4150.
- [4] Bukhtoyarov V.V. et al. A study on a probabilistic method for designing artificial neural networks for the formation of intelligent technology assemblies with high variability // Electronics. 2023. Vol. 12, no. 1. Art. 215.
- [5] Barantsov I.A. et al. Classification of acoustic influences registered with phase-sensitive otdr using pattern recognition methods // Sensors. 2023. Vol. 23, no. 2. Art. 582.

Investigation of the Possibility of Finding Anomalies in Network Traffic Using Clustering, Validation and Cosine Proximity Algorithms

© Sokolov G.V.
Shuchalin G.V.
Gantimurov A.P.

g.sokolov@baumlab.pro
g.shuchalin@baumlab.pro
a@baumlab.pro

BMSTU, SEC "AI Technologies", Moscow, 105005, Russia

The article studies the possibility of finding anomalies in network traffic with the help of clustering algorithms, subsequent validation and application of cosine proximity method. Methods of pre-processing and data preparation are considered. At the end of the article the conclusion about perspective methods of using the obtained results is made. A well-trained DBSCAN algorithm linked to Apache Spark can be used in information security systems. It is also possible to further explore the application of the algorithm to other areas, such as the development of integrated data protection systems and the security of information technology and systems in general, using the data obtained and additional methods. The built-in data could then allow for the identification of information security risk areas and the assessment of data leakage from the system.

Keywords: network traffic, clustering algorithms, DBSCAN

УДК 004.08

Прогнозирование времени заполнения хранилища данных с помощью модели полиномиальной регрессии

© Соколов Григорий Владимирович g.sokolov@baumlab.pro
Шучалин Григорий Васильевич g.shuchalin@baumlab.pro
Гантиумиров Андрей Павлович a@baumlab.pro

МГТУ им. Н.Э. Баумана, НОЦ «Технологии искусственного интеллекта»,
Москва, 105005, Россия

В индустрии систем хранения данных (СХД) существует проблема отсутствия умных инструментов мониторинга состояния хранилищ данных с возможностью прогнозирования их показателей и состояния в будущем. С их помощью можно было бы настраивать хранилища данных, чтобы обеспечить их надежность и повысить отказоустойчивость. Нами было принято решение разработать такой инструмент, для прогнозирования общего объема занимаемой памяти в хранилище. Целью работы является создание прогнозирующей системы на базе zero-code платформы BAUM AI.

Ключевые слова: СХД, регрессия, прогнозирование, zero-code

Введение. Одной из наиболее популярных задач в области анализа данных является прогнозирование процессов непрерывно изменяющихся во времени, так называемых временных рядов. Например, объем производства промышленной продукции, стоимость ценных бумаг на бирже, спрос на продукцию розничной торговли, погодные показатели и т.д. Однако, существуют нестандартные случаи, с одним из которых столкнулась наша команда разработки [1–3].

В области СХД требуются умные инструменты, позволяющие:

- прогнозировать показатели хранилищ;
- повысить надежность и отказоустойчивость.

В качестве решения могут выступить методы машинного обучения в части прогнозирования временных рядов. Формулировка задачи звучала так: спрогнозировать момент времени, при котором хранилище данных будет полностью заполнено. В классическом варианте, задача прогнозирования временного ряда выглядит иначе [4, 5].

В общем виде временной ряд выглядит следующим образом: y_1, \dots, y_t , $y_t \in R$ — это значения некоторой величины, измеренные через постоянные временные интервалы.

Задача в классическом варианте, состоит в поиске значения y_{T+h} , т. е. значения измеряемой величины в следующий момент времени $t + h$ — завтра, на следующей неделе, через год и т. д.

В нашем случае необходимо спрогнозировать момент времени наступления события, проще говоря, нужно ответить на вопрос: «когда будет заполнено хранилище данных?» вместо «насколько будет заполнено хранилище в следующий момент времени?», то есть необходимо вычислить индекс $t + h$.

В процессе необходимо было решить ряд вопросов:

- как использовать модель для решения обратной задачи, где целевой признак все еще непрерывная величина, но найти нужно время?
- как предобработать входящие данные?
- как оценить эффективность работы модели?

Материалы и методы. В первом приближении мы использовали модель линейной регрессии. Сразу стало понятно, что предобученную модель использовать не получится, во-первых, ее обобщающая способность будет крайне низкой, а во-вторых, скажется чувствительность к выбросам. Поэтому был выбран не стандартный подход — модель обучается в реальном времени на части последних полученных данных с заранее заданным интервалом, например, последний час или последние сутки. Затем, с помощью коэффициентов обученной модели делается прогноз. Чтобы исключить влияние выбросов, данные обрабатываются скользящим средним, тогда кривая нагрузки становится более гладкой. Пример использования, показан на рис. 1.

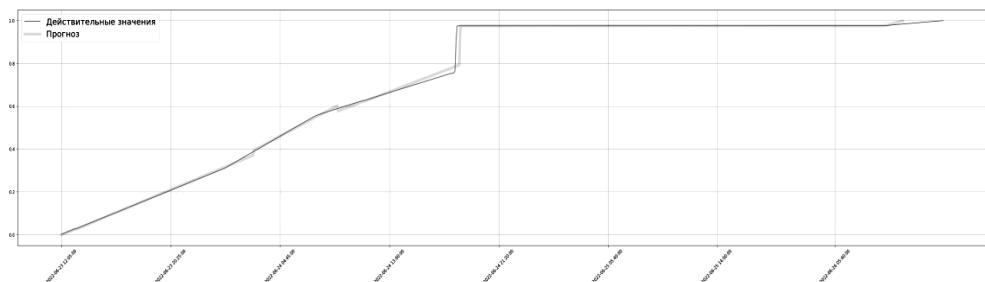


Рис. 1. Прогнозирование заполняемости хранилища данных с применением линейной регрессии

Далее нами была испытана регрессия более высокого порядка. Схема ее работы была такой же. Теоретически, она должна была иметь более высокую обобщающую способность, но в части использования этой модели появился ряд вопросов. Во-первых, не ясно было как выбрать степень полинома, чтобы избежать переобучения и не получить слишком простую модель. Во-вторых, не понятно как задать условие не убывания нагрузки, так как полином, зачастую уходил в ноль и был не способен спрогнозировать уровень в 100 % загрузки памяти. Пример использования, показан на рис. 2.

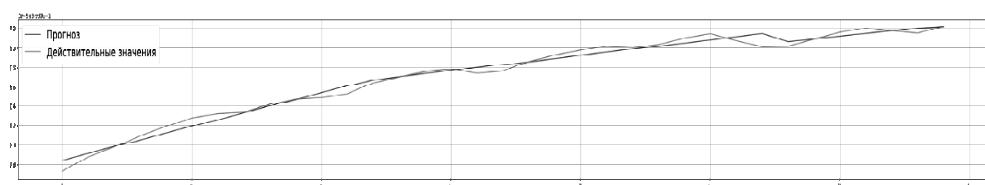


Рис. 2. Прогнозирование заполняемости хранилища данных с применением полиномиальной регрессии

Для оценки эффективности работы модели мы решили создать собственную метрику, так как стандартные метрики тяжело интерпретировать, что очень важно для конечного пользователя. В качестве математической модели мы решили использовать криволинейный интеграл. С его помощью можно найти площадь между двумя кривыми. Это как раз то, что нужно было для нас. Если найти площадь между кривой загрузки памяти СХД и прогнозирующим полиномом, то получится более интерпретируемая величина, особенно визуально. Пример, показан на рис. 3.

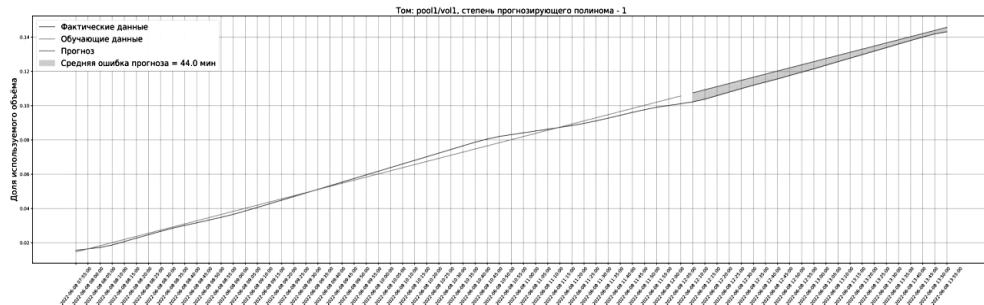


Рис. 3. Оценка эффективности

Результаты. В итоге у нас получилось микросервисное приложение, работающее в режиме реального времени, которые впоследствии мы реализовали на нашей Zero code платформе, показанное на рис. 4. В качестве выходного значение, пользователю демонстрируется сообщение с прогнозом, а также его визуальное представление, с возможностью оповещения в Telegram, показанное на рис. 5.

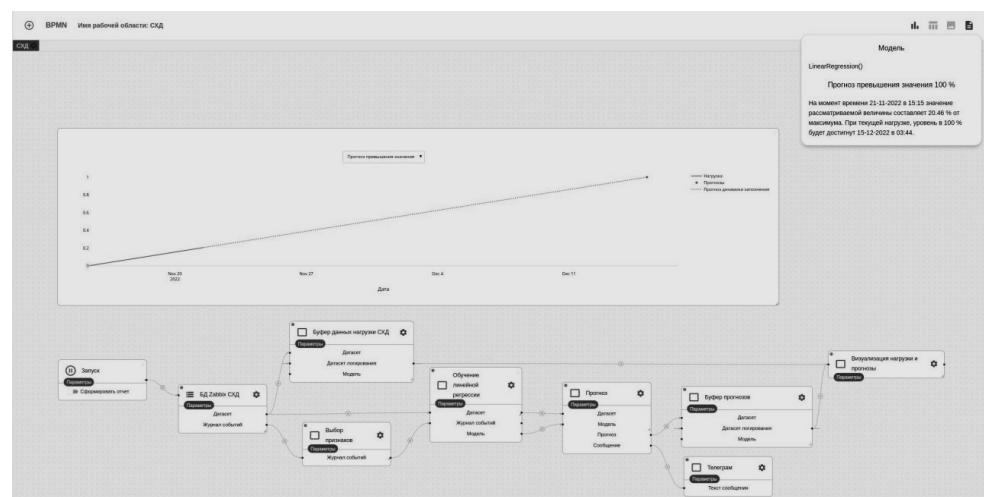


Рис. 4. Микросервисное приложение на платформе BAUM AI

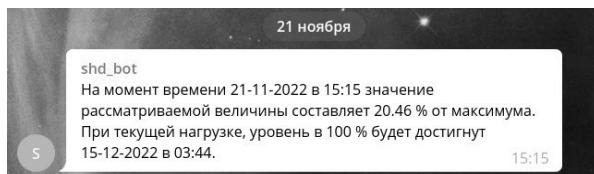


Рис. 5. Пример оповещения в Telegram

Заключение. Было проведено прогнозирование заполняемости СХД при помощи линейной и полиномиальной регрессии. Для оценки эффективности была разработана собственная метрика, так как готовые решения не удовлетворяли полученным результатам.

В будущем мы планируем модернизировать наше решение, например, добавить возможность мониторинга ряда параметров нескольких устройств, не ограничиваясь объемом памяти одного устройства, а также возможность выбора режима работы.

Литература

- [1] Masich I.S. et al. Paired patterns in logical analysis of data for decision support in recognition // Computation. 2022. Vol. 10, no. 10. Art. 185.
- [2] Mikhalev A.S. et al. The Orb-Weaving Spider Algorithm for Training of Recurrent Neural Networks // Symmetry. 2022. Vol. 14, no. 10. Art. 2036.
- [3] Masich I.S. et al. Prediction of critical filling of a storage area network by machine learning methods // Electronics. 2022. Vol. 11, no. 24. Art. 4150.
- [4] Bukhtoyarov V.V. et al. A study on a probabilistic method for designing artificial neural networks for the formation of intelligent technology assemblies with high variability // Electronics. 2023. Vol. 12, no. 1. Art. 215.
- [5] Barantsov I.A. et al. Classification of acoustic influences registered with phase-sensitive otdr using pattern recognition methods // Sensors. 2023. Vol. 23, no. 2. Art. 582.

Forecasting the Filling Time of the Data Warehouse Using the Polynomial Regression Model

✉ Sokolov G.V.
Shuchalin G.V.
Gantimurov A.P.

g.sokolov@baumlab.pro
g.shuchalin@baumlab.pro
a@baumlab.pro

BMSTU, SEC "AI Technologies", Moscow, 105005, Russia

In the data storage systems industry (SSI), there is a lack of smart tools to monitor the status of data warehouses with the ability to predict their performance and future status. They could be used to configure data warehouses to ensure their reliability and improve fault tolerance. We decided to develop such a tool to predict the total amount of memory in the repository. The aim is to create a predictive system based on the zero-code platform BAUM AI.

Keywords: SSI, regression, forecasting, zero-code

УДК 004.032.26

Применение нейронной сети архитектуры EfficientNetB0 для задачи анализа видеопотока из зоны индукционной пайки волноводных трактов

© Тынченко Вадим Сергеевич vadimond@mail.ru
Курашкин Сергей Олегович scorpion_ser@mail.ru
Нелюб Владимир Александрович mail@emtc.ru

МГТУ им. Н.Э. Баумана, НОЦ «Технологии искусственного интеллекта»,
Москва, 105005, Россия

Индукционная пайка зарекомендовала себя как надежный метод неразъемного соединения волноводных трактов в аэрокосмической промышленности, так как в данной отрасли уделяется большое внимание качеству соединения. Однако существует проблема определения этапов технологического процесса, что зачастую влечет большое количество дефектов (расплав, протекание припоя, не провары и т. п.) В данном исследовании проводится анализ естественных, искусственных и сверточных нейронных сетей с целью выявления наиболее подходящей архитектуры для разработки в будущих исследованиях интеллектуальной системы определения этапов технологического процесса индукционной пайки. Результаты показали, что архитектура EfficientNetB0 достигает точности 97,5 % на тестовом датасете, что является отличным показателем.

Ключевые слова: EfficientNetB0, индукционная пайка, нейронные сети, волновод

Введение. Методология пайки деталей [1] при помощи токов высокой частоты (ТВЧ) была разработана одновременно с появлением способа индукционного нагрева металлов. В общем случае такой технологический процесс заключается в соединении двух или более деталей между собой с использованием специального припоя, у которого температура плавления ниже, чем у соединяемых деталей. При этом особенность индукционной пайки заключается в том, что тепловая энергия, с помощью которой осуществляется соединение деталей, не привносится извне, а образуется в деталях вследствие действия ТВЧ.

Заполнение расплавленным припоем зазоров между деталями и диффузионное проникновение его в поверхностные слои в зоне пайки, а также взаимное растворение металла деталей и припоя обеспечивают, после охлаждения деталей и кристаллизации припоя, получение механически прочного и герметичного соединения. Пайка при индукционном нагреве проводится с помощью «твёрдых» припоев, обладающих температурой плавления выше 550°C , и «мягких» припоев с температурой плавления менее 400°C [2, 3].

С каждым днем оптические технологии играют все большую роль в метрологии. Изменения, вызванные разработкой портативных измерительных манипуляторов в начале 1990-х годов и появлением вскоре после этого лазерных трекеров [4], полностью перевернули традиционные отраслевые ме-

тоды контроля с ног на голову. Однако в большинстве портативных измерительных решений по-прежнему используются технологии, имеющие серьезные ограничения в производственной среде. Например, эти решения требуют исключительной стабильности на протяжении всего процесса измерения. Оптические решения, особенно те, которые используют видеокамеры, обходят эти ограничения, обеспечивая автоматическое позиционирование и непрерывные измерения. Теперь технологии оцифровки, основанные на лазере и белом свете, также могут производить все более плотные данные.

Исследуется связь между фотограмметрией и компьютерным зрением. В работе [5] рассматриваются основные проблемы как компьютерного зрения, так и фотограмметрии, и определяются общие цели, а также различные подходы. Взаимодействие в прошлом было ограничено как различиями в терминологии, так и в основной философии, касающейся манипулирования проекционными уравнениями.

В статье [6] представлена система контроля дефектов пайки для специальной платы с интегральной схемой с помощью компьютерного зрения. На данной плате с интегральной схемой закреплен окклюдер пространства, который блокирует свет от CCD-матрицы к проверяемым контактам чипа. Эта система может проверять заблокированные светом дефекты пайки контактов чипа посредством конструкции аппаратной системы и системы программного обеспечения. Это дешевая, но автоматическая система проверки дефектов пайки, которая может обнаруживать дефекты пайки вместо ручного визуального осмотра и повышать скорость и стабильность обнаружения.

Таким образом, основной целью данного исследования является повышение качества технологического процесса индукционной пайки (ИП) путем применения нейронной сети архитектуры EfficientNetB0 для анализа видеопотока в зоне пайки.

Материалы и методы. В ходе изучения предметной области было выделено несколько этапов пайки, для которых предполагается возможность визуальной классификации, все они представлены в таблице. Самым сложным с точки зрения получения данных этапом является «Нагрев до температуры плавления припоя». Доля кадров этого этапа относительно всего видео технологического процесса составляет примерно 5 %.

Главная задача состоит в определении этапа пайки на входном изображении, полученном при записи или обработки потокового видео технологического процесса, за счет наличия у него характерных особенностей, позволяющих классифицировать этот этап как отдельную часть технологического процесса. Данное решение позволило бы убрать субъективизм, обусловленный наличие оператора, конечным результатом чего являлось бы повышение качества технологического процесса [7].

Входными данными для задачи анализа видеопотока будет являться массив пикселей, получаемый в виде отдельного кадра из поточного видео с камеры. В качестве выходных данных определим: наименование/уникальный номер этапа, которому соответствует входное изображение.

Этапы технологического процесса ИП

Стадия процесса	Характерные особенности
Предварительный нагрев изделия до температуры высыхания флюса	Флюс начинает приобретать белый оттенок
Нагрев до температуры плавления (300 °C)	Флюс из белого становится прозрачным с выделением некоторого количества визуально заметных испарений
Нагрев до температуры плавления припоя (580...600 °C)	Начинает плавиться припой. Припой переходит в жидкое состояние и начинает перетекать в технические отверстия сборки
Окончание плавления припоя	Припой затвердевает. На данном этапе температура фиксируется и производится выдержка на зафиксированной температуре (5...15 с)

Таким образом, задача сводится к обработке входного изображения при помощи компьютерного зрения. Для извлечения полезной информации и отбрасывания ненужной используются дескрипторы признаков. Дескриптор признаков преобразует исходное изображение из формата «Ширина × Высота × Количество каналов» в массив признаков «Ширина × Высота × Количество признаков» [8].

EfficientNet. EfficientNet — это семейство нейронных сетей, одно из наиболее актуальных на данный момент. Сети на основе EfficientNet сейчас показывают отличные результаты на самых разных наборах данных: CIFAR-100, Flowers-102, ImageNet и др. Основная идея состоит в создании базовой структуры с возможностью эффективного с вычислительной точки зрения дальнейшего масштабирования — комбинированного масштабирования.

У сверточных сетей есть три измерения: ширина (количество каналов), глубина (количество слоев) и разрешение (количество пикселей в изображении). Соответственно по каждому из этих измерений нейронную сеть можно масштабировать.

Базовой моделью сети является EfficientNet-B0, основной строительный блок которой MBConv — мобильная обращенная свертка с узким местом, к которой добавлена технология «сжатия и стимуляции». Если в ResNet количество каналов соответствует большому на входе, затем происходит сжатие, затем опять увеличение сверткой 1×1 (паттерн «широкий-узкий-широкий»), то в блоке EfficientNet InvertedResBlock (далее ISB) используется паттерн «узкий-широкий-узкий».

Структура EfficientNet-B0 уменьшает общее количество операций и размер модели, что позволяет ей иметь точность Топ-5, сравнимую с точностью ResNet-34, несмотря на то, что у нее вчетверо меньше тренируемых параметров, и ее обучение требует на порядок меньше вычислительных операций.

Результаты. Для работы был использован компьютер под управление OS Windows с процессором Intel Core i5-9400, а также видеокартой Nvidia GeForce 1060 с 6 ГБ памяти графического ускорителя.

Программные средства, использованные при реализации:

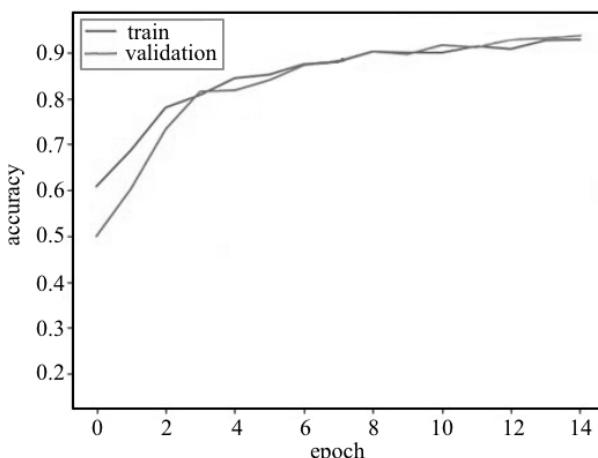
- редактор Visual Studio Code с расширением Jupyter Notebook;
- графический редактор и видеоредактор для подготовки данных;
- язык программирования Python (версия 3.9) в составе среды Anaconda (ядро Conda) [9];
- библиотека работы с изображениями OpenCV;
- библиотеки scikit, TensorFlow;
- API Keras пакета TensorFlow для создания моделей нейронных сетей.

Дополнительно использовалось программное обеспечение Nvidia CUDA и cuDNN для использования графического ускорителя в процессе обучения.

TensorFlow и его API Keras являются самыми популярными инструментами для создания нейронных сетей на данный момент.

В данном исследовании был проведен обзор архитектур естественной нейронной сети, искусственной нейронной сети, а также ее обучение и сверточной нейронной сети EfficientNet. На имеющемся наборе данных было проведено тестирование для определения наиболее подходящих моделей.

На рисунке представлена точность модели EfficientNetB0.



Точность модели EfficientNetB0 (синей линией обозначена
точность EfficientNetB0, а зеленой — точность на проверочной выборке)

Как видно на рисунке, модель EfficientNetB0 показывает высокую эффект на проверочной выборке, что свидетельствует о его применимости для обучения нейронной сети.

В качестве функции потерь использовалась категориальная кросс-энтропия. Максимальная точность была 0,982, на тестовом образце — 0,975. В среднем 40...46 с требовалось для одного периода обучения.

Заключение. Не смотря на существующие методы оптимизации и автоматизации процесса индукционной пайки, существует проблема получение стабильного качества паяного соединения в условиях неопределенности (отказ одного или обоих пирометрических датчиков). Для решения данной проблемы в данном исследовании предлагается исследование моделей для распознавания изображений в будущем используемых при разработке системы слежения за технологическим процессом пайки. В результате анализа существующих подходов были выбраны сверточные нейронные сети, а именно архитектура EfficientNetB0. Подготовка датасета включала в себя проведение натурных экспериментов и приведение изображений к необходимому размеру. Данная архитектура показала лучшую эффективность на проверочной выборке — 97,5 %.

Дальнейшее исследование предполагает сравнение данной архитектуры с другими (VGG19, xResNet50, EfficientNetB0, EfficientNetB2, Xception, DenseNet169) и последующей разработки интеллектуальной системы определения этапов технологического процесса индукционной пайки. Данная разработка обусловлена необходимостью слежением за технологическим процессом и оперативным определением изменения температуры нагрева даже в случае отказа пирометрических датчиков с целью предотвращения дефектов в зоне неразъемных соединений.

Литература

- [1] Ланин В.Л., Сергачев И.И. Индукционные устройства для монтажной пайки в электронике // Электронная обработка материалов. 2012. Т. 48, № 4. С. 103–107.
- [2] Гусев В.Ю. и др. Индукционная пайка волноводов из алюминиевых сплавов для космических аппаратов связи // Будущее машиностроения России: Десятая Всероссийская конференция молодых ученых и специалистов: сб. матер. М.: Изд-во МГТУ им. Н.Э. Баумана, 2017. С. 532–534.
- [3] Masich I.S. et al. Paired patterns in logical analysis of data for decision support in recognition // Computation. 2022. Vol. 10, no. 10. Art. 185.
- [4] Mikhalev A.S. et al. The orb-weaving spider algorithm for training of recurrent neural networks // Symmetry. 2022. Vol. 14, no. 10. Art. 2036.
- [5] Masich I.S. et al. Prediction of critical filling of a storage area network by machine learning methods // Electronics. 2022. Vol. 11, no. 24. Art. 4150.
- [6] Bukhtoyarov V.V. et al. A study on a probabilistic method for designing artificial neural networks for the formation of intelligent technology assemblies with high variability // Electronics. 2023. Vol. 12, no. 1. Art. 215.
- [7] Barantsov I.A. et al. Classification of acoustic influences registered with phase-sensitive otdr using pattern recognition methods // Sensors. 2023. Vol. 23, no. 2. Art. 582.
- [8] Mocanu D.C. et al. Scalable training of artificial neural networks with adaptive sparse connectivity inspired by network science // Nature communications. 2018. Vol. 9, no. 1. Art. 2383.
- [9] Pedregosa F. et al. Scikit-learn: Machine learning in Python // Journal of machine Learning research. 2011. Vol. 12. Pp. 2825–2830.

Application of the EfficientNetB0 Architecture Neural Network for the Task of Analyzing the Video Flow from the Zone of Induction Brazing Waveguide Tracts

© Tynchenko V.S.
Kurashkin S.O.
Nelub V.A.

vadimond@mail.ru
scorpion_ser@mail.ru
mail@emtc.ru

BMSTU, SEC "AI Technologies", Moscow, 105005, Russia

Induction brazing has proven to be a reliable method for seamlessly connecting waveguide routes in the aerospace industry, as it pays great attention to the quality of the compound. However, there is a problem of determining the stages of the technological process, which often entails a large number of defects (melt, drift, no seepage, etc.) artificial and convoluted neural networks in order to identify the most suitable architecture for the development in future studies of an intelligent system for determining the stages of the technological process of induction soldering. The results showed that the EfficientNetB0 architecture achieves 97.5 % accuracy on the test dataset, which is an excellent indicator.

Keywords: EfficientNetB0, induction brazing, neural nets, waveguide

УДК 004.89

Применение архитектуры нейронной сети U-Net для сегментации клеток мозга по трипановым синим изображениям

© Тынченко Вадим Сергеевич	vadimond@mail.ru
Суханов Денис Александрович	den829@mail.ru
Кудрявцев Алексей Александрович	vatutu@gmail.com
Агеев Даниэль Алиханович	daniel.ageev0000@gmail.com

МГТУ им. Н.Э. Баумана, НОЦ «Технологии искусственного интеллекта»,
Москва, 105005, Россия

Рассмотрена задача семантической сегментации изображений клеток головного мозга крыс, окрашенных трипановым синим. Для решения задачи разработана математическая модель в виде сверточной нейронной сети, основанной на архитектуре U-Net с глубиной свертки равной 4. В результате исследований лучшая модель имеет метрику 0,8513 (коэффициент Дайса) на тестовой выборке и точность определения живых клеток составляет 98,62 %. Рассмотрено возможное будущее улучшение текущих моделей за счет изменений в архитектуре сверточной нейронной сети и подбора гиперпараметров для оптимизаторов.

Ключевые слова: клетки мозга, сегментация биомедицинских изображений, распознавание изображений, обработка изображений, глубокие сверточные нейросети, U-Net

Введение. Целью данной статьи является разработка математической модели для семантической сегментации изображений клеток головного мозга крыс, окрашенных трипановым синим (рис. 1). Модель сегментации позволит выделять живые клетки в автоматическом режиме.

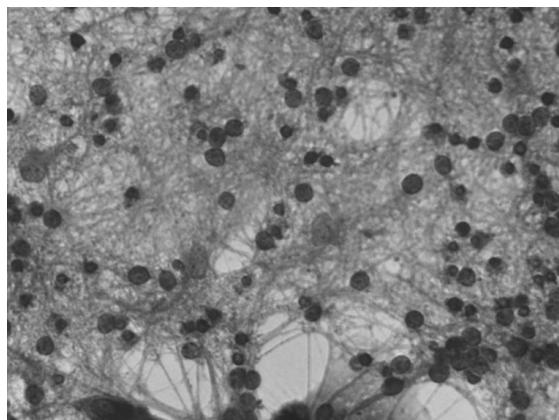


Рис. 1. Изображение клеток головного мозга, окрашенное трипановым синим

Актуальность работы обусловлена необходимостью быстрой и точной оценки жизнеспособности клеток головного мозга для изучения воздействия лекарственных средств, физических или химических стимуляторов и других потенциальных факторов, влияющих на их функционирование. В настоящее время широким кругом специалистов ведутся фундаментальные исследования в области алгоритмов искусственного интеллекта, нашими коллегами сделан ряд работ в данной области [1–5]. Разрабатываемая модель сегментации изображений клеток головного мозга позволит отслеживать динамику отмирания клеток, в режиме реального времени.

Для решения задачи семантической сегментации часто применяются глубокие сверточные нейронные сети [6]. В биомедицинских задачах наилучшие результаты показывает U-Net [7], которая может обучаться на малом наборе данных.

Материалы и методы. Обнаружение живых/мертвых (D/A тест) клеток головного мозга по изображениям, окрашенных трипановым синим производилось с помощью семантической сегментации искусственной нейронной сетью. Данные представляли собой 30 RGB — изображений, одно из изображений представлено на рис. 1. Для каждого такого изображения имелась его копия с помеченными живыми клетками (рис. 2).

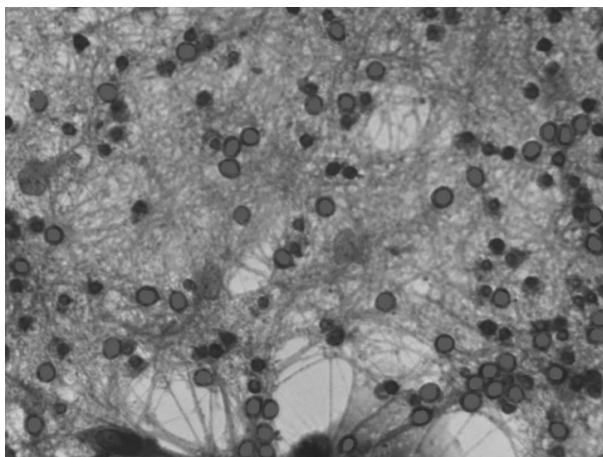


Рис. 2. Изображение клеток головного мозга с выделенными живыми нейронами

Для решения задачи семантической сегментации использовалась сверточная нейронная сеть. Учителем для сверточной нейронной сети является маска исходного изображения. Для исходных изображений были подготовлены маски исходных изображений (рис. 3).

Исходные изображения и их подготовленные маски имели размер 1376×1032 пикселей, для обучения сверточной нейросети, они были сжаты до размера 512×512 пикселей. За основу была взята архитектура сети U-Net с глубиной равной 4, схематичное представление изображено на рис. 4.

На вход сети подавалось RGB-изображение 512×512 , которое проходит через 4 блока кодирования и декодирования. На выходе имеем сигмойдную функцию активации и черно-белое изображение размером 512×512 пикселей.



Рис. 3. Мaska для изображения на рис. 1, используя маркеры на рис. 2

Производилась аугментация изображений. Каждое изображение аугментировалось 4 раза: поворот по часовой стрелки на 90° , поворот против часовой стрелки на 90° , отображение по оси X , отображение по оси Y . Таким образом, увеличили выборку в 5 раз.

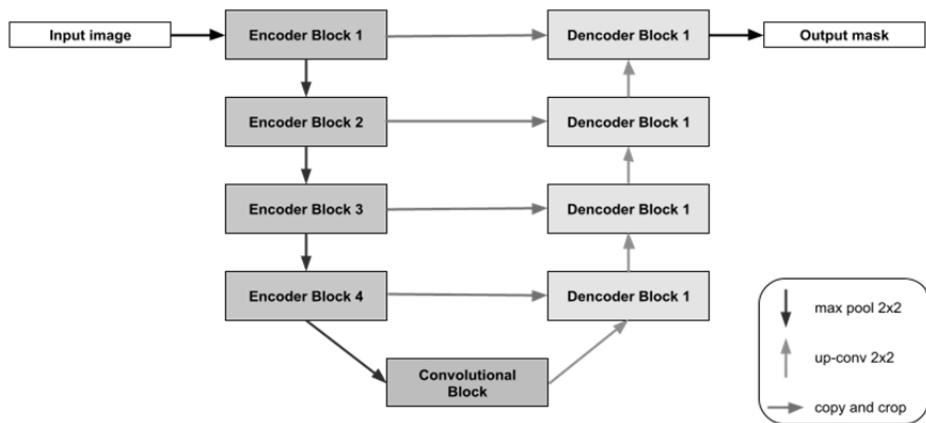


Рис. 4. Блочная архитектура сети U-net

К основной архитектуре искусственной сверточной нейросети U-Net исследовалось влияние добавления слоев BatchNormalization2d и/или DropOut($p = 0.3$) на конечный результат. В качестве оптимизатора для обуче-

ния рассматривалось три варианта с различными параметрами: SGD, Adam [8], RMSprop [9]. Метрика вычислялась по коэффициенту Дайса (*DSC*) [10]:

$$DSC = \frac{2 \cdot |Y^{pred} \cap Y| + 1}{|Y^{pred}| + |Y| + 1},$$

где Y^{pred} — предсказанный массив; Y — исходный массив. В формуле добавлена единица, чтобы избежать возможного деления на 0, в случае, когда Y^{pred} и Y — представляют собой массивы из нулей. Функция потерь — объединение коэффициента Дайса и бинарной кросс-энтропии [11] ($BCE_{Dice} loss$):

$$BCE_{Dice} loss = -\frac{1}{N} \sum_{n=1}^N \left[Y_n \log Y_n^{pred} + (1 - Y_n) \log(1 - Y_n^{pred}) \right] + 1 - DSC,$$

где Y_n^{pred} — элемент предсказанного массива, Y_n — элемент исходного массива, N — количество элементов массива.

Результаты. Результаты экспериментов представлены в таблице. Сокращения: BN — добавление слоев BatchNormalization; DO — добавление слоев DropOut; m — момент импульса [12]; w_decay — сокращение весов.

На тестовую выборку отводилось 20 % всего набора данных. Функция потерь при обучении модели U-Net+BN+DO с оптимизатором Adam представлена на рис. 5. При обучении моделей использовалась ранняя остановка. Если в течение 10 эпох подряд функция потерь не уменьшалась, то останавливаем обучение и сохраняем модель с лучшими результатами. Результат работы модели U-Net+BN+DO (Adam) представлен на рис. 6.

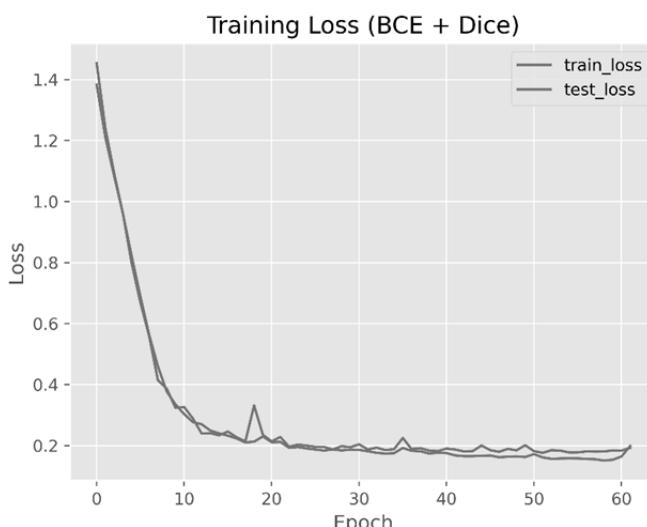


Рис. 5. Функция потерь при обучении модели U-Net+BN+DO на аугментированных данных, с оптимизатором Adam

Соотношение метрики к типу моделей и набору данных

Набор данных	Тип нейросети	Глубина нейросети	Оптимизатор	Скорость обучения	Метрика, Dice	Дополнительные параметры
30	U-Net	4	Adam	1e-3	0.7031	
150	U-Net	4	Adam	1e-3	0.8391	
150	U-Net+BN	4	Adam	1e-3	0.8505	
150	U-Net+DO	4	Adam	1e-3	0.8371	
150	U-Net+BN+DO	4	Adam	1e-3	0.8513	
150	U-Net	4	RMSprop	1e-4	0.7699	
150	U-Net+BN	4	RMSprop	1e-3	0.8421	
150	U-Net+DO	4	RMSprop	1e-4	0.7634	
150	U-Net+BN+DO	4	RMSprop	1e-3	0.8393	
150	U-Net	4	SGD	1e-1	0.8277	m=0.9, w_decay=1e-5
150	U-Net+BN	4	SGD	1e-1	0.8239	Nesterov, m=0.1, w_decay=1e-5
150	U-Net+DO	4	SGD	1e-1	0.8261	m=0.8, w_decay=1e-5
150	U-Net+BN+DO	4	SGD	1e-1	0.8008	Nesterov, m=0.1, w_decay=1e-5

Для получения предсказанной маски использовалось изображение, показанное на рис. 1.

Обсуждение. Имея изначальную выборку из 30 изображений и их масок, получить хороший результат не представлялось возможным, поэтому в первую очередь была реализована аугментация данных. На аугментированных данных, без изменения других параметров, видим значительное улучшение метрики с 0,7031 до 0,8391, см. таблицу. Дальнейшее изменение архитектуры сверточной нейросети, а именно добавление слоев нормализации и дропаута так же дало свой результат, метрика выросла до 0,8513. Стоит отметить, что оптимизатор Adam является наиболее удобным в использовании, в отличие от других оптимизаторов, таких как SGD и RMSprop, для которых требуется подбор параметров в зависимости от архитектуры нейросети и решаемой задачи. На рис. 5 видно, как слои дропаута борются с переобучением, и функция потерь на обучающей выборке не так сильно отстает от функции потерь на тестовой выборке. На рис. 6 предсказанная маска выглядит очень близкой к оригинальной, за исключением одной клетки, которую нейросеть определила, как живую. Сравнивая эталонные изображения и полученные на выходе из нейросети, стоит отметить, что общее количество определяемых

живых клеток совпадает или в некоторых случаях отличается не более чем на две позиции.

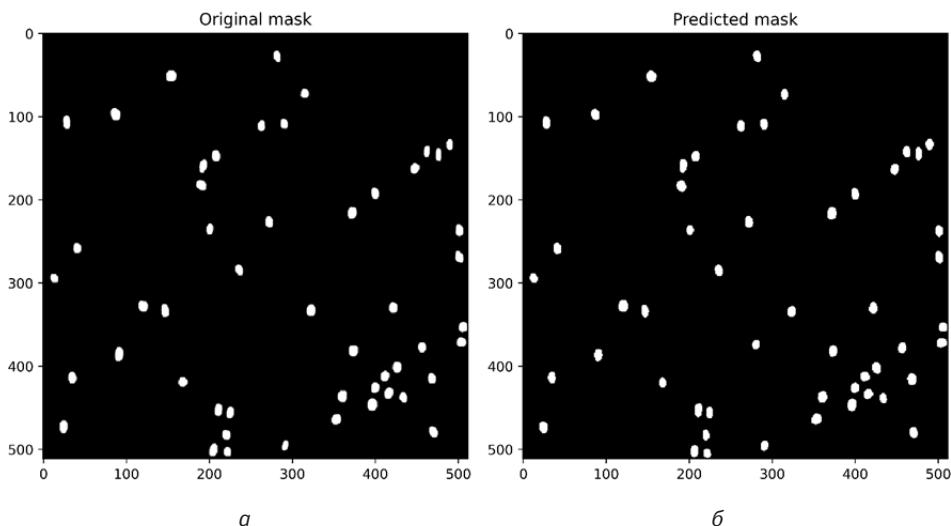


Рис. 6. Сравнение оригинальной маски (а) и маски, полученной при работе нейросети (б)

Выводы. Достигнутый результат показан в таблице и на рис. 6. Среди 13 приведенных моделей, лучшую метрику показывает модель U-Net со слоями нормализации и дропаута, глубиной свертки 4, на оптимизаторе Adam со скоростью обучения 0,001...0,8513 (коэффициент Дайса). Для дальнейшего улучшения результатов предполагается увеличение глубины сверточной нейронной сети. Подбор гиперпараметров для оптимизатора Adam путем поиска по сетке, случайного поиска или с помощью генетического алгоритма. Аналогичный подбор гиперпараметров для других оптимизаторов. Также ожидаются новые изображения клеток головного мозга крыс, окрашенные трипановым синим, что, безусловно, улучшит распознавание модели, сделает ее более гибкой. Будут рассмотрены другие способы аугментации, кроме тех, что присутствовали в статье. Более того, предполагается другой подход к сегментации изображений, заключающийся не в сжатии исходного изображения с 1376×1032 пикселей до 512×512 , а в его делении на части по 512×512 пикселей, что увеличит выборку данных.

Литература

- [1] Barantsov I.A., Pnev A.B., Koshelev K.I., Tynchenko V.S., Nelyub V.A., Borodulin A.S. Classification of acoustic influences registered with phase-sensitive otdr using pattern recognition methods // Sensors. 2023. Vol. 23 (2). Art. 582.
- [2] Bukhtoyarov V.V., Tynchenko V.S., Nelyub V.A., Masich I.S., Borodulin A.S., Gantimurov A.P. A study on a probabilistic method for designing artificial neural networks for the formation of intelligent technology assemblies with high variability // Electronics. 2023. Vol. 12 (1). Art. 215.

- [3] Masich I.S., Tynchenko V.S., Nelyub V.A., Bukhtoyarov V.V., Kurashkin S.O., Gantimurov A.P., Borodulin A.S. Prediction of critical filling of a storage area network by machine learning methods // Electronics. 2022. Vol. 11 (24). Art. 4150.
- [4] Mikhalev A.S., Tynchenko V.S., Nelyub V.A., Lugovaya N.M., Baranov V.A., Kukartsev V.V., Sergienko R.B., Kurashkin S.O. The orb-weaving spider algorithm for training of recurrent neural networks // Symmetry. 2022. Vol. 14 (10). Art. 2036.
- [5] Masich I.S., Tynchenko V.S., Nelyub V.A., Bukhtoyarov V.V., Kurashkin S.O., Borodulin A.S. Paired patterns in logical analysis of data for decision support in recognition // Computation. 2022. Vol. 10 (10). Art. 185.
- [6] van Valen D.A., Kudo T., Lane K.M., Macklin D.N., Quach N.T., DeFelice M.M., Maayan I., Tanouchi Y., Ashley E.A., Markus W. Covert: deep learning automates the quantitative analysis of individual cells in live-cell imaging experiments // PLOS Computational Biology. 2016. Vol. 12 (11). Art. e1005177.
- [7] Ronneberger O., Fischer P., Brox T. U-Net: convolutional networks for biomedical image segmentation // Medical Image Computing and Computer-Assisted Intervention. 2015. Pp. 234–241.
- [8] Kingma D.P., Ba J. Adam: A Method for Stochastic Optimization. 2014. Available at: <https://arxiv.org/abs/1412.6980> (accessed January 30, 2017).
- [9] RMSProp and equilibrated adaptive learning rates for non-convex optimization. Available at: <https://arxiv.org/abs/1502.04390v1> (accessed Augusr, 29, 2015).
- [10] Dice L.R. Measures of the amount of ecologic association between species // Ecology. 1945. Vol. 26 (3). Pp. 297–302.
- [11] Murphy K. Machine Learning: a probabilistic perspective. Massachusetts Institute of Technology (MIT), USA, 2012. P. 1067.
- [12] Sutskever I., Martens J., Dahl G., Hinton G.E., Sanjoy D. On the importance of initialization and momentum in deep learning // Proceedings of the 30th International Conference on Machine Learning (ICML-13). USA, 2016. Pp. 1139–1147.

Application of U-Net Architecture Neural Network for Segmentation of Brain Cell Images Stained with Trypan Blue

©	Tynchenko V.S. Sukhanov D.A. Kudryavtsev A.A. Ageev D.A.	vadimond@mail.ru den829@mail.ru vatutu@gmail.com daniel.ageev0000@gmail.com
---	-------------------------------------------------------------------	--------------------------------------------------------------------------------------

BMSTU, SEC “AI Technologies”, Moscow, 105005, Russia

This article discusses the problem of semantic segmentation of images of rat brain cells stained with trypan blue. To solve the problem a mathematical model was developed in the form of a convolutional neural network based on the U-Net architecture with a convolution depth of 4. The result of applying the selected model according to metric Dice is 0.8513, according to the accuracy of detecting the number of living neurons is 98.62 %. A possible future improvement of the current models due to small changes in the architecture of the convolutional neural network, the selection of hyperparameters for optimizers.

Keywords: brain cells, biomedical image segmentation, image recognition, image preprocessing, deep convolutional networks, U-Net

Искусственный интеллект как объект изучения в инженерном образовании

УДК 81'322.2

Роль мультидисциплинарных исследований в автоматической обработке научно-технических текстов

© | Бутенко Юлия Ивановна

iubutenko@bmstu.ru

МГТУ им. Н.Э. Баумана, Москва, 105005, Россия

Работа посвящена реализации мультидисциплинарного подхода для решения задач автоматической обработки научно-технических текстов в части извлечения специальной терминологии, который был опробирован в ходе реализации практик для студентов кафедр Л4 и ИУ7. Описаны задачи и результаты полученные на каждом этапе, а также поделены аспекты исследования, реализуемые студентами разных кафедр. Показаны результаты анализа эффективности разработанной системы извлечения многокомпонентных терминов из параллельных текстов. Представлены междисциплинарные трудности реализации такого подхода, а также некоторые перспективы его развития.

Ключевые слова: термин, научно-технический текст, обработка естественного языка, разметка, междисциплинарность

Для успешного решения задач автоматической обработки научно-технических текстов необходимо участие ряда специалистов из таких широких областей как лингвистика, информатика и математика, каждая из которых может быть разделена на ряд направлений. При этом найти специалиста, который был бы знаком со всеми указанными областями знаний крайне сложно, поэтому появляется необходимость в формировании мультидисциплинарных команд для решения разного типа задач автоматической обработки текстов на естественном языке. В МГТУ им. Н.Э. Баумана есть опыт организации подобных студенческих команд в рамках организации практик.

Как известно, к одной из наиболее сложных задач автоматической обработки научно-технических текстов на английском и русском языках являются термины разной формальной структуры — в состав термина может входить от одного до двенадцати слов, которые в совокупности обозначают одно понятие. Таким образом, термин может быть однокомпонентным и состоять из ключевого слова, или представлять собой терминологическую группу, в состав которой входит ключевое слово или ядро группы, одно или несколько левых определений и одно или несколько правых или предложных определений, которые уточняют или модифицируют смысл терминологической единицы [1]. В процессе автоматического извлечения терминов из научно-технических текстов наибольшую сложность представляют многокомпонентные термины — терминологические словосочетания, созданные лексическим и синтаксическим способами, т. е. словосочетания, составленные по определенным моделям. Способ образования терминов в виде цепочки слов часто используется на практике [2, 3]. Результаты исследований, проведенные студентами кафедры Л4 в ходе

исследовательской практики показали, что структурные модели русскоязычных многокомпонентных терминов включают 23 модели, а для англоязычных многокомпонентных терминов выделена 21 модель. Указанные модели легли в основу метода извлечения многокомпонентных терминов на английском и русском языках [4], представленного на рис. 1.



Рис. 1. Метод извлечения англо- и русскоязычных многокомпонентных терминов

На основе предложенного метода студентами кафедры ИУ7 было создано приложение на языке Python с использованием библиотек tkinter, nltk, pymorphy2, os, sys. Программа предоставляет пользователю интерфейс для ввода текстов, подлежащих анализу. Из полученных текстов путем морфологического анализа слов, в него входящих, а также их взаимного расположения, выделяются словосочетания, которые могут быть многокомпонентными терминами. Далее пользователь может вручную отобрать термины, классифицировать их и сохранить в базе данных, состоящей из нескольких текстовых файлов, с которыми работает программа и которые можно анализировать с помощью функции поиска [5]. Интерфейс программы для извлечения многокомпонентных терминов из параллельных научно-технических текстов представлен на рис. 2.

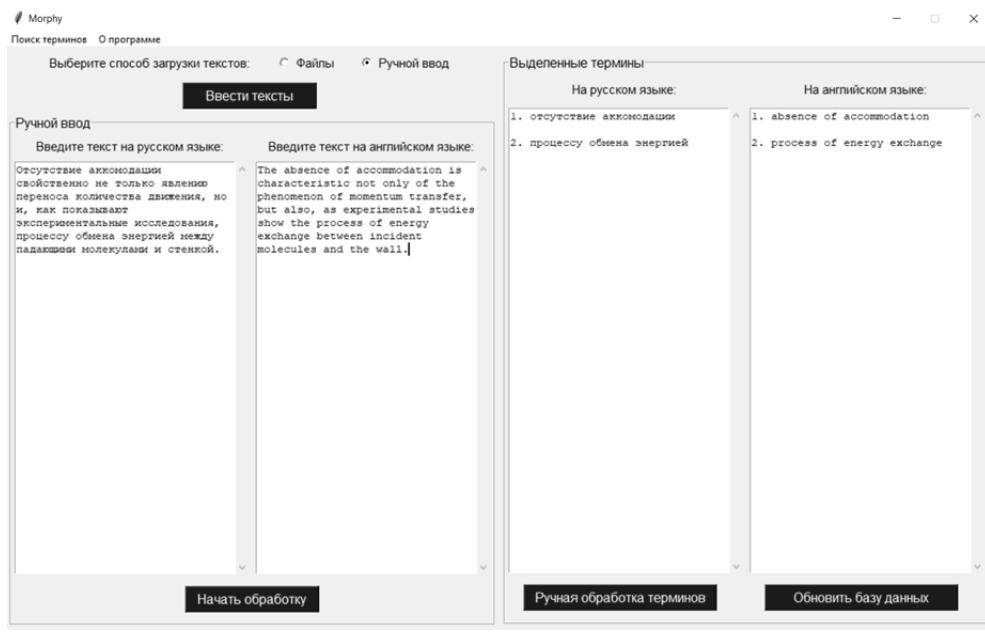


Рис. 2. Интерфейс системы извлечения многокомпонентных терминов из параллельных научно-технических текстов

В программе реализована функция выявления количества повторений терминов в каждом тексте — повторяющийся по тексту термин будет выведен один раз, а количество его употреблений указывается в скобках рядом с термином. Термины могут извлекаться из текстов как на двух языках, так и на одном языке.

Ручная проверка результатов работы разработанной системы извлечения многокомпонентных терминов проводилась студентами кафедры Л2 и Л4 МГТУ им. Н.Э. Баумана. В таблице представлены фрагменты такой проверки.

Анализируя результаты работы предлагаемой системы, можно выделить некоторые положительные и отрицательные моменты. Из текста на русском языке программа довольно хорошо извлекает термины, автоматически преобразовывая их ядерные элементы в именительный падеж единственного числа, однако не распознает аббревиатуры как в русском тексте, так и в английском, а также часто определяет только часть многокомпонентных терминов. Возможная причина этого в том, что базе нет определенной модели.

Стоит отметить, что при реализации такого мультидисциплинарного подхода возникали трудности понимания терминологии. Как оказалось, как в терминологии искусственного интеллекта, так и лингвистики есть одинаковые термины с близким значением: *основа слова, синтаксический анализ предложения*, и даже возникали нюансы с подсчетом количества компонентов термина.

Анализ ошибок системы извлечения многокомпонентных терминов из параллельных научно-технических текстов

		Язык	
		Русский	Английский
Морозов В.М., Каленова В.И. Управление спутником при помощи магнитных моментов: управляемость и алгоритмы стабилизации // Космические исследования. 2020 №3. С. 199–207		56	35
Всего действительных терминов		3	4
Результат программы	Термин	Описание проблемы и возможное решение	
1. Снабженная магнитная системой	Магнитная система ориентации	Программа, возможно, определила, что трехкомпонентный термин должен включать в себя именно прилагательное «снабженная», а не существительное «ориентации» по модели прил. + прил. + сущ., данную модель стоит поменять на прил. + сущ. + сущ.	
2. Function of geomagnetic field	Geomagnetic field	Были присоединены ненужные существительное «Function» и предлог «Of», возможно ошибка в модели, стоит создать четкую модель двухкомпонентного термина прил. + сущ.	
3. Original nonstationary system	Nonstationary system	Ситуация, идентичная с пунктом 4, из модели прил. + прил. + сущ. следует убрать первое прилагательное	

Разработанная система извлечения многокомпонентных терминов является основой для проведения дальнейших исследований в рамках создания параллельного корпуса научно-технических текстов и многоязычной терминологической базы данных.

Литература

- [1] Лейчик В.М. Оптимальная длина и структура термина // Вопросы языкознания. 1981. № 2. С. 63–73.
- [2] Лейчик В.М. Исходные понятия, основные положения, определения современного терминоведения и терминографии // Вестник Харьковского политехнического университета. 1994. № 1. С. 147–180.
- [3] Гринев-Гриневич С.В., Сорокина Э.А. Опыт описания формальной структуры термина (на материале английской терминологии лексикологии) // Вестник Московского государственного областного университета. Сер. Лингвистика. 2020. № 5. С. 74–85.
<https://doi.org/10.18384/2310-712X-2020-5-74-85>

- [4] Бутенко Ю.И. Строганов Ю.В., Сапожков А.М. Метод извлечения русскоязычных много-компонентных терминов в корпусе научно-технических текстов // Прикладная информатика. 2021. № 6. С. 21–27. <https://doi.org/10.37791/2687-0649-2021-16-6-21-27>
- [5] Бутенко Ю.И., Строганов Ю.В., Сапожков А.М. Система извлечения многокомпонентных терминов и их переводных эквивалентов из параллельных научно-технических текстов // Научно-техническая информация. Сер. 2. Информационные процессы и системы. 2022. № 9. С. 12–21. <https://doi.org/10.36535/0548-0027-2022-09-3>

The Role of Multidisciplinary Research in Automatic Processing of Scientific and Technical texts

© | Butenko Yu.I.

iubutenko@bmstu.ru

BMSTU, 105005, Russia

The paper is devoted to the implementation of a multidisciplinary approach to solving the problems of automatic processing of scientific and technical texts in terms of extraction of special terminology, which was tested during the implementation of practices for students of the departments L4 and IU7. The tasks and results obtained at each stage are described and the aspects of the research implemented by students of different departments are subdivided. The results of the analysis of the effectiveness of the developed system of extraction of multi-component terms from parallel texts are presented. The interdisciplinary aspects of this approach are presented, as well as some perspectives for its development.

Keywords: term, scientific and technical text, natural language processing, markup, interdisciplinarity

УДК 004.89

Технология информационного сопровождения формирования образовательных программ с элементами искусственного интеллекта

© Гузева Татьяна Александровна
Цибизова Татьяна Юрьевна

gta29@bmstu.ru
mumc@bmstu.ru

МГТУ им. Н.Э. Баумана, Москва, 105005, Россия

Статья посвящена использованию элементов искусственного интеллекта при формировании образовательных программ высшего образования и трансляции компонентов образовательной программы на сайт. Представлена технология формирования и утверждения образовательных программ в цифровой среде. Показан процесс формирования и утверждения актуализированных образовательных программ посредством информационных ресурсов с элементами искусственного интеллекта.

Ключевые слова: искусственный интеллект, цифровая среда, образовательная программа, библиотека дисциплин, учебный план

Введение. В условиях цифровой экономики наиболее актуальной задачей является необходимость изменения подходов к управлению образовательным процессом вуза [1, 2]. Образовательный процесс в соответствие с современными запросами должен быть не только гибким, но и мобильным при его формировании [3, 4]. В настоящее время все образовательные организации разрабатывают положения или локально-нормативные акты, которые регламентируют процесс проектирования образовательных программ [5].

При проектировании образовательных программ в больших университетах, таких как МГТУ им. Н.Э. Баумана, возникает ряд дополнительных трудностей, связанных с объемом формируемых документов. В МГТУ в настоящее время реализуется более 600 образовательных программ, включающих 18 000 программ дисциплин и практик. Получить качественные образовательные программы при таком объеме данных без применения современных цифровых технологий не представляется возможным.

Управление образовательной программой через единую систему формирования всех ее составляющих позволит рассчитывать эффективность программ на всех этапах реализации, выявлять нерентабельные элементы на ранних стадиях с возможностью последующей их актуализации, проводить многоступенчатый экспертный контроль качества подготовленных документов.

Такой системой в МГТУ им. Н.Э. Баумана является цифровая образовательная среда «Электронный университет» (ЦОС «ЭУ») [6, 7].

Формирование образовательных программ в цифровой среде. Подсистема «Библиотека учебных программ» определена первичным звеном всей этой сложной модели. За единицу формирования образовательной программы принята дисциплина с ее параметрами: наименование; количество зачет-

ных единиц, семестров, недель реализации, академических часов и модулей; объем контрольных мероприятий и модулей; виды нагрузки, контрольных мероприятий, промежуточной или итоговой аттестации. Принята принципиально новая идеология составления учебного плана. Большинство автоматизированных систем, ранее рассмотренных и прежняя технология «Электронного университета» основаны на жестком учебном плане, а новая технология составления учебных планов строится на основе программ дисциплин и практик [8].

Первый этап моделирования начинается с заполнения «Библиотеки учебных программ», она создается для каждой кафедры по инициативе выпускающей или обучающей кафедры. Гибкость системы позволяет вводить и контролировать параметры дисциплины, согласно нормам, утвержденным законодательными и локальными нормативными документами, а также непрерывно совершенствовать их для повышения качества подготовки кадров.

Для максимального исключения внесения ошибочных данных и возможностью быстрой их корректировки, данные **единожды**, вносятся в «обложку» дисциплины в подсистеме «Библиотека учебных программ» с последующей трансляцией во все остальные подсистемы ЦОС «ЭУ» [9–11].

Введенная идентификация позволяет заново не формировать эту дисциплину ежегодно при изменении любого из параметров (кроме наименования), а транслировать ее в следующий учебный год, и в каждом году видеть, чем она отличается, кому она читается, будет или уже читалась. При заполнении «обложки» дисциплины, автоматически рассчитываются часы на контрольные мероприятия с учетом общей трудоемкости, времени на аудиторную и самостоятельную работу.

Интерфейс позволяет формировать и загружать обязательные для дисциплин документы: аннотации, рабочие программы дисциплин, фонд оценочных средств. Для создания документов поочередно выбираются Литература, Компетенции, Программное обеспечение, вкладки соединены соответственно с электронной библиотечной системой, подсистемой «Стандарты» и Лабораторией лицензионного программного обеспечения. Далее посредством вкладки выгружается файл, который требует заполнения отдельных полей, не связанных с нормированным и обязательным контентом. После заполнения содержательной части в «Библиотеку дисциплин» подгружаются файлы РПД и ФОС.

Далее подгруженные документы проходят многоуровневую проверку, а введенная идентификация, позволяет определить стадию проверки рецензентом, которая осуществляется в электронной форме. После получения идентификатора формируется подписной лист, соединенный с кадровой базой.

Каждое структурное подразделение имеют свою «Библиотеку дисциплин», сформированную по годам реализации, а рабочие программы дисциплин и программы практик в pdf формате доступны всем обучающимся и преподавателям. Аннотации транслируются на сайт Университета, а фонды оценочных средств доступны согласно, правам доступа.

Подсистема «Учебные планы» наглядно выдает информацию обо всех учебных планах Университета, факультета, кафедры по уровням подготовки. Учебные планы формируются из дисциплин подсистемы «Библиотека дисциплин». Подсистема «Учебные планы» позволяет ознакомиться с планом любого года поступления конкретной направленности и при необходимости напечатать план в разных форматах. Доступ к календарному графику и матрице компетенций, осуществляется с этой же страницы. Из плана можно так же перейти в «Библиотеку дисциплин». Кроме того, учебные планы могут формироваться для разных траекторий обучения — индивидуальные, адаптированные и планы ускоренного обучения.

Подсистема «Стандарты» контролирует процесс формирования учебного плана и в онлайн режиме сообщает об ошибках, допущенных при проектировании плана, и не позволяет получить печатную форму и сформировать годовые учебные планы до тех пор, пока учебный план не будет соответствовать всем требованиям.

Элементы структуры подсистемы «Нормативные документы» — «Стандарты» представлены на рис. 1.



Рис. 1. Структура подсистемы «Нормативные документы» — «Стандарты»

Процесс формирования и утверждения актуализированных образовательных программ посредством информационных ресурсов с элементами искусственного интеллекта. В целях выполнения требований по структуре официального сайта образовательной организации высшего образования в информационно-телекоммуникационной сети «Интернет» и формату представления информации утвержденных Постановлением Правительства Российской Федерации от 20.10.2021 № 1802, ст. 29 Федерального закона от 29.12.2012 № 273-ФЗ «Об образовании в Российской Федерации», Приказ Федеральной службы по надзору в сфере образования и науки РФ от 14.08.2020 № 831 на сайте каждой образовательной организации должен быть специальный раздел «Сведения об образовательной организации», включающий в себя разделы «Образование» и «Образовательные стандарты и требования».

В разделе «Образовательные стандарты и требования» указывается информация о федеральных государственных образовательных стандартах, федеральных государственных требованиях, утвержденных образовательных стандартах, самостоятельно устанавливаемых требованиях, в том числе с электронной подписью руководителя организации.

В разделе «Образование» указывается информация о реализуемых образовательных программах, в том числе о реализуемых адаптированных образовательных программах, информация об описании образовательной программы, о численности обучающихся (аспирантура, бакалавриат, магистратура, специалитет, техникум), информация о результатах приема, информация о направлениях и результатах научной (научно-исследовательской) деятельности и научно-исследовательской базе для ее осуществления, информация о результатах перевода, восстановления и отчисления, информация о лицензии на осуществление образовательной деятельности.

В общей сложности в раздел «Образование» из подсистем ЦОС «Электронный университет» поступает более 80 000 файлов, распределяемых при помощи элементов искусственного интеллекта в соответствующие разделы и подразделы сайта.

Из подсистем ЦОС «ЭУ» при помощи элементов искусственного интеллекта компоненты образовательных программ в автоматическом режиме собираются в файлы и поступают на сайт в раздел «Информация о реализуемых образовательных программах», в том числе о реализуемых адаптированных образовательных программах: код и наименование направления подготовки; направленность (профиль); шифр программы; формы обучения; нормативный срок обучения; срок действия государственной аккредитации, общественной, профессионально-общественной аккредитации (дата окончания действия свидетельства о государственной аккредитации); языки, на которых осуществляется образование (обучение); учебные предметы, курсы, дисциплины (модули), предусмотренные соответствующей образовательной программой; практики, предусмотренные соответствующей образовательной программой; использование при реализации образовательной программы электронного обучения и дистанционных образовательных технологий полное/частичное.

В раздел «Об описании образовательной программы» автоматически формируются и поступают на сайт следующие сведения, например, для образовательных программ бакалавриата: код и наименование направления подготовки, специальности; направленность (профиль); шифр программы; описание образовательной программы (ОПОП); учебный план / Календарный учебный график (УП); аннотации к рабочим программам дисциплин (по каждому учебному предмету, курсу, дисциплине (модулю), практики, в составе образовательной программы) с приложением рабочих программ (Рабочие программы РП); методические и иные документы, разработанные образовательной организацией для обеспечения образовательного процесса, а также рабочие программы воспитания и календарные планы воспитательной работы (Рабочая программа воспитания и календарные планы воспитательной работы — РПВ).

Данные файлы формируются из подсистемы «Учебные планы» всех годов обучения по конкретной ОПОП с использованием элементов искусственного интеллекта путем сравнения и исключением повторяющихся, причем часть файлов подписываются электронной подписью (рис. 2, 3).

Учебные планы									
Перечень выгрузки файлов									
Сформировать архив для передачи на сайт.									
<input type="checkbox"/> маг	Код	Каф	РП и Аннотации	РПВ и Метод. док.	2022	ОПОП	2021	до 2020 включительно	УП 2022 - 2021
01.04.04/02	ФН2	RП	Загруженный	РПД, РПП, Литература, РПВ.			Загруженный		
01.04.04/04	ИБМ3	RП	Загруженный	РПД, РПП, Литература, РПВ.			Сгенерировать	Загруженный	Сгенерировать
01.04.04/04	ФН1	RП	Загруженный	РПД, РПП, Литература, РПВ.		01.04.04/04 Математическое и компьютерное моделирование в логистике	Практики, предусмотренные образовательной программы	Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования «Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)	Сгенерировать
01.04.04/05		RП	Загруженный	РПД, РПП, Литература, РПВ.			1. Начало-исследовательская работа	Учебные предметы, курсы, дисциплины (модули), предусмотренные образовательной программой	Сгенерировать
			Аннотации			2. Предметная практика	01.04.04/04 Математическое и компьютерное моделирование в логистике		
			Загруженный			3. Практико-технологическая практика	1. Аналитические методы проектирования		
						4. Технологическая практика	2. Автоматизированная деятельность в Российской Федерации		
							5. Информационные технологии в образовательных системах и цепях поставок		
							6. Административная инфраструктура логистических систем		
							7. Компьютерные и информационные системы в logistics		
							8. Математическое моделирование логистической инфраструктуры		
							9. Математическое моделирование логистической инфраструктуры		
							10. Математическое моделирование логистики		
							11. Математическое управление производством		
							12. Математическое моделирование логистики		
							13. Методы и инструменты метрологического обеспечения		
							14. Методы и инструменты метрологического обеспечения		
							15. Методы моделирования и формирования логистической цепочки		
							16. Методы моделирования и формирования логистической цепочки		
							17. Моделирование "зеленой" логистики		
							18. Моделирование извилистых объектов и систем		
							19. Моделирование логистики		
							20. Применение систем логистической поддержки менеджмента		
							21. Стандартизация и сертификация в логистике		
							22. Технологии информационной обработки данных в морском бизнесе		

Рис. 2. Фрагмент подсистемы «Учебные планы», формирующий архив выгрузки файлов для передачи на сайт

Технология формирования компонентов ОПОП, генерации компонентов в виде файлов и размещения их на сайте показана на рис. 4:

- 1) Описание образовательной программы (ОПОП);
- 2) Учебный план / Календарный учебный график (УП);
- 3) Рабочая программа воспитания и календарные планы воспитательной работы — РПВ и КПВР.

Методические и иные документы, разработанные образовательной организацией для обеспечения образовательного процесса, формируются в виде перечня из Списка литературы Рабочей программы дисциплины/практики (РПД/РПП). По ссылкам перечня можно перейти к конкретному учебно-методическому изданию либо на сайте Издательства МГТУ им. Н.Э. Баумана, причем аннотация доступна сразу, а после авторизации на сайте издательства можно скачать документ; либо на сайт Библиотеки МГТУ им. Н.Э. Баумана, откуда в зависимости от ЭБС перейти к самим учебно-методическим материалам (рис. 5).

Учебные планы

Перечень выгрузки файлов

[Сформировать архив для передачи на сайт](#)

моб[

Код	Каф	РП и Аннотации	РПВ и Метод.док.	опол	2021	до 2020 включительно	2022	УП 2022 - 2021	2021
01.04.04/02	ФН2	РП	Загруженный Аннотации	РД. РП. Литература. РП.	Загруженный				
01.04.04/04	ИБМ3	РП	Загруженный Аннотации	РД. РП. Литература. РП.	Сгенерировать	Загруженный		Сгенерировать	Сгенерировать

Специалитет

Магистратура

Рис. 3. Генерация компонентов ОПОП в подсистеме «Учебные планы» в ЦОС «ЭУ»

Образование

Об описание образовательной программы. [Скрыть/развернуть]

Образовательные программы высшего образования – программы магистратуры. [Скрыть/развернуть]

Учебное образование – высшее образование

Направление (профиль)	Шифр программы	Отрасль образовательной программы (ОПОП)	Наборный план / Концепция профессиональной подготовки (КПП)	Документы и материалы для обучения (по квалификации, учебник, лекции, курс дидактических материалов, практика и практико-орientированная программа с применением рабочих программ/рабочие программы ИТ)	Методические и иные документы, регламентирующие организацию для обеспечения качества обучения, а также рабочие программы, конспекты лекций и конспекты практических занятий, календарные планы-расписания работы (Рабочая программа воспитания и календарные планы академической работы – ИПВ)
01.04.04 Применение математики	0104.04/02ФН2	опол	2022	2021	
Математическое моделирование технических систем	0104.04/04ИБМ3	опол	уп	Аннотации	рп

Учебные планы

Перечень выгрузки файлов

[Сформировать архив для передачи на сайт](#)

моб[

Код	Каф	РП и Аннотации	РПВ и Метод.док.	2022	опол	2021	до 2020 включительно	2022	УП 2022 - 2021	2021
01.04.04/02	ФН2	РП	Загруженный Аннотации	РД. РП. Литература. РП.	Загруженный					
01.04.04/04	ИБМ3	РП	Загруженный Аннотации	РД. РП. Литература. РП.	Сгенерировать	Загруженный		Сгенерировать	Сгенерировать	

Специалитет

Магистратура

Рис. 4. Автоматическое размещение сгенерированных файлов на сайт

Методические и иные документы, разработанные образовательной организацией для обеспечения образовательного процесса, формируются в виде перечня из Списка литературы Рабочей программы дисциплины/практики (РПД/РПП). По ссылкам перечня можно перейти к конкретному учебно-методическому изданию либо на сайте Издательства МГТУ им. Н.Э. Баумана, причем аннотация доступна сразу, а после авторизации на сайте издательства можно скачать документ; либо на сайт Библиотеки МГТУ им. Н.Э. Баумана, откуда в зависимости от ЭБС перейти к самим учебно-методическим материалам (рис. 5).

Рис. 5. Фрагмент подсистемы «Учебные планы» с перечнем выгрузки файлов методических документов на сайт

Аннотации к рабочим программам дисциплин (по каждому учебному предмету, курсу, дисциплине (модулю), практики, в составе образовательной программы), а также сами рабочие программы дисциплин/практик (РПД/РПП) в виде файлов с использованием элементов искусственного интеллекта собираются из подсистемы «Библиотека учебных программ» ЦОС «Электронный университет» и разбираются в соответствии с учебными планами (УП) конкретного года поступления (обучения) по каждой ОПОП (рис. 6).

Аналогично аннотации всех дисциплин/практик конкретной ОПОП собираются в автоматическом режиме в момент выгрузки на сайт в единый документ — «Атлас аннотаций». РПД/РПП формируются в автоматическом режиме, в момент выгрузки на сайте списком — активными ссылками на каждую дисциплину/практику.

Учебные планы										
Перечень выгрузки файлов										
Сформировать архив для передачи на сайт										
<input type="checkbox"/> маг										
Код	Каф	РП и Аннотации	РПВ и Метод.док.	2022	опол	2021	до 2020 включительно	2022	УП 2022 - 2021	
Специалитет										
Магистратура										
01.04.04 / 02	ФН2	<p>РП </p> <p><input checked="" type="checkbox"/> Загруженный </p> <p>Аннотации </p> <p><input checked="" type="checkbox"/> Загруженный </p>	<p>РПД, РПЛ, Литература, РПВ.</p>		<p><input checked="" type="checkbox"/> Загруженный </p>				<input type="checkbox"/> Сгенерировать	
01.04.04 / 04	ИБМ3	<p>РП </p> <p><input checked="" type="checkbox"/> Загруженный </p> <p>Аннотации </p> <p><input checked="" type="checkbox"/> Загруженный </p>	<p>РПД, РПЛ, Литература, РПВ.</p> <p><input type="checkbox"/> Иностранный язык</p>		<p><input type="checkbox"/> Сгенерировать </p>		<p><input checked="" type="checkbox"/> Загруженный </p>		<input type="checkbox"/> Сгенерировать	
01.04.04 / 05	ФН1	<p>РП </p> <p><input checked="" type="checkbox"/> Загруженный </p> <p>Аннотации </p> <p><input checked="" type="checkbox"/> Загруженный </p>	<p>Название_для_01.04.04.pdf</p> <ul style="list-style-type: none"> <input checked="" type="checkbox"/> Аналитические методы принятия решений.pdf <input checked="" type="checkbox"/> Актикорганизационная деятельность в Российской Федерации.pdf <input checked="" type="checkbox"/> Имитационное моделирование логистических систем и цепей поставок.pdf <input checked="" type="checkbox"/> Информационная инфраструктура логистических систем.pdf <input checked="" type="checkbox"/> Компьютерные и интеллектуальные системы в логистике.pdf <input checked="" type="checkbox"/> Математические методы в экономике.pdf <input checked="" type="checkbox"/> Математическое моделирование логистической инфраструктуры.pdf <input checked="" type="checkbox"/> Менеджмент креативности и яркости.pdf <input checked="" type="checkbox"/> Методология управления проектами.pdf <input checked="" type="checkbox"/> Методология управления проектами.pdf <input checked="" type="checkbox"/> Методы и инструменты логистического вывода.pdf <input checked="" type="checkbox"/> Методы и инструменты многокритериального принятия решений.pdf <input checked="" type="checkbox"/> Методы и математические модели управления качеством.pdf <input checked="" type="checkbox"/> Методы моделирования и реорганизации логистических процессов.pdf <input checked="" type="checkbox"/> Методы обеспечения информационной и экономической безопасности.pdf <input checked="" type="checkbox"/> Моделирование зеленых цепей поставок.pdf <input checked="" type="checkbox"/> Моделирование инженерных объектов и систем.pdf <input checked="" type="checkbox"/> Научноисследовательская работа.pdf <input checked="" type="checkbox"/> Неконтактное моделирование.pdf <input checked="" type="checkbox"/> Порталы в менеджменте.pdf <input checked="" type="checkbox"/> Портфолио в защите ВФР.pdf <input checked="" type="checkbox"/> Предпринимательская практика.pdf <input checked="" type="checkbox"/> Проектирование систем логистической поддержки жизненного цикла.pdf <input checked="" type="checkbox"/> Проектноэкологическая практика.pdf <input checked="" type="checkbox"/> Системы статистической обработки данных в экономике.pdf <input checked="" type="checkbox"/> Технологии нейросетевой обработки данных в медиумном бизнесе.pdf <input checked="" type="checkbox"/> Технологическая практика.pdf 	<p>Size</p> <ul style="list-style-type: none"> 238.271 51.035 216.953 47.145 217.252 218.252 214.000 216.121 50.604 150.000 213.368 224.472 236.525 389.466 384.361 236.201 301.538 419.995 250.385 401.390 401.711 383.872 213.406 389.181 215.131 234.958 236.008 216.278 	<p>Name_для_01.04.04.pdf</p> <ul style="list-style-type: none"> <input checked="" type="checkbox"/> Аналитические методы принятия решений.pdf <input checked="" type="checkbox"/> Актикорганизационная деятельность в Российской Федерации.pdf <input checked="" type="checkbox"/> Имитационное моделирование логистических систем и цепей поставок.pdf <input checked="" type="checkbox"/> Информационная инфраструктура логистических систем.pdf <input checked="" type="checkbox"/> Компьютерные и интеллектуальные системы в логистике.pdf <input checked="" type="checkbox"/> Математические методы в экономике.pdf <input checked="" type="checkbox"/> Математическое моделирование логистической инфраструктуры.pdf <input checked="" type="checkbox"/> Менеджмент креативности и яркости.pdf <input checked="" type="checkbox"/> Методология управления проектами.pdf <input checked="" type="checkbox"/> Методология управления проектами.pdf <input checked="" type="checkbox"/> Методы и инструменты логистического вывода.pdf <input checked="" type="checkbox"/> Методы и инструменты многокритериального принятия решений.pdf <input checked="" type="checkbox"/> Методы и математические модели управления качеством.pdf <input checked="" type="checkbox"/> Методы моделирования и реорганизации логистических процессов.pdf <input checked="" type="checkbox"/> Методы обеспечения информационной и экономической безопасности.pdf <input checked="" type="checkbox"/> Моделирование зеленых цепей поставок.pdf <input checked="" type="checkbox"/> Моделирование инженерных объектов и систем.pdf <input checked="" type="checkbox"/> Научноисследовательская работа.pdf <input checked="" type="checkbox"/> Неконтактное моделирование.pdf <input checked="" type="checkbox"/> Порталы в менеджменте.pdf <input checked="" type="checkbox"/> Портфолио в защите ВФР.pdf <input checked="" type="checkbox"/> Предпринимательская практика.pdf <input checked="" type="checkbox"/> Проектирование систем логистической поддержки жизненного цикла.pdf <input checked="" type="checkbox"/> Проектноэкологическая практика.pdf <input checked="" type="checkbox"/> Системы статистической обработки данных в экономике.pdf <input checked="" type="checkbox"/> Технологии нейросетевой обработки данных в медиумном бизнесе.pdf <input checked="" type="checkbox"/> Технологическая практика.pdf 	<p>Size</p> <ul style="list-style-type: none"> 550.121 536.907 534.828 532.186 539.914 540.483 524.187 528.787 583.088 577.614 542.553 650.941 583.953 538.342 530.067 555.343 583.801 561.229 545.745 581.388 524.137 686.990 631.746 541.733 488.257 642.569 567.583 584.089 				

Рис. 6. Фрагмент подсистемы «Учебные планы», формирующий перечень выгрузки файлов дисциплин и аннотаций к дисциплинам на сайт

Заключение. Основным отличием предлагаемой технологии формирования образовательных программ является применение автоматизированных систем с элементами искусственного интеллекта. На уровне моделирования представлены все составляющие основной образовательной программы Университета и ее формирование в одной системе с выбором в качестве единицы формирования — учебную дисциплину, при этом обеспечивая гибкость образовательных траекторий, мобильность всех подразделений университета и повышение качества подготовки.

Предлагаемая модель представляет собой единую систему информационно-методического сопровождения формирования образовательных программ и их составляющих, позволяющая повысить мобильность всех подразделений университета, реализующих образовательные программы.

Управление образовательной программой через единую систему формирования всех ее составляющих позволяет рассчитывать эффективность программ на всех этапах реализации, выявлять нерентабельные элементы на ранних ста-

диях с возможностью последующей их актуализации, проводить многоступенчатый экспертный контроль качества подготовленных документов.

Литература

- [1] Балдин А.В., Пичугин А.А. Методология проектирования информационной системы управления университетом // Гражданская авиация на современном этапе развития науки, техники и общества: междунар. науч.-техн. конф., посв. 45-летию Университета: сб. тез. докл. участников. М.: МГТУ ГА, 2016. С. 226.
- [2] Цибизова Т.Ю., Пищулин В.И. Разработка систем управления организациями с использованием информационных технологий // Наука и образование: научное издание МГТУ им. Н.Э. Баумана. 2007. № 4. С. 6.
- [3] Хвецкович Э.Б., Мазурик М.С. Автоматизированные информационные системы управления учебным процессом вуза: практическое исследование // Наука о человеке: гуманитарные исследования. 2011. № 2 (8). С. 138–149.
- [4] Тубеков М.О., Касымбеков А.С. Автоматизированная информационная система «Университет» // Молодой ученый. 2017. № 11. С. 47–51.
- [5] Проектирование основных образовательных программ вуза при реализации уровневой подготовки кадров на основе федеральных государственных образовательных стандартов / под ред. С.В. Коршунова. М.: МИПК МГТУ им. Н.Э. Баумана, 2010. 212 с.
- [6] Guzева T.A., Baldin A.V., Perepelitsa P.S., Makarova Ju.B., Tsibizova T.Yu. The formation of educational programs in the digital environment // ITM Web of Conferences. International Forum “IT-Technologies for Engineering Education: New Trends and Implementing Experience” (ITEE-2019). 2020. Art. 02004.
- [7] Балдин А.В., Гузева Т.А., Цибизова Т.Ю. Разработка цифровой среды для проектирования образовательных программ // Будущее машиностроения России: Двенадцатая Всерос. конф.: сб. докл. М.: Изд-во МГТУ им. Н.Э. Баумана, 2019. С. 918–921.
- [8] Информационная управляющая система МГТУ имени Н.Э. Баумана «Электронный университет»: концепция и реализация / Т.И. Агеева и др.; под ред. И.Б. Федорова, В. М. Черненьского. М.: Изд-во МГТУ им. Н.Э. Баумана, 2009. 374 с.
- [9] Гузева Т.А., Балдин А.В., Перепелица П.С., Макарова Ю.Б., Цибизова Т.Ю. Формирование образовательных программ в цифровой среде // В сборнике: Цифровые технологии в инженерном образовании: новые тренды и опыт внедрения. Сборник трудов Международного форума. 2020. С. 140-144.
- [10] Гузева Т.А., Цибизова Т.Ю., Макарова Ю.Б. Цифровая модель проектирования основных образовательных программ университета // Технологии разработки и отладки сложных технических систем: VII Всерос. науч.-практ. конф.: сб. тр. М.: Изд-во МГТУ им. Н.Э. Баумана, 2020. С. 74–80.
- [11] Guzeva T.A., Tsibizova T.Yu., Makarova Yu.B. The digital design model of the basic educational programs of the university // AIP Conference Proceedings. Modeling in Engineering 2020. 2022. Art. 070008.

Technology of Information Support for the Formation of Educational Programs with Artificial Intelligence Elements

© | Guzeva T.A.
Tsibizova T.Yu.

gta29@bmstu.ru
mumc@bmstu.ru

BMSTU, 105005, Russia

The article is devoted to the use of elements of artificial intelligence in the formation of educational programs of higher education and the translation of the components of the educational program to the site. The technology of formation and approval of educational programs in the digital environment is presented. The process of formation and approval of updated educational programs by means of information resources with elements of artificial intelligence is shown.

Keywords: *artificial intelligence, digital environment, educational program, library of disciplines, curriculum*

УДК 519.6

Методика преподавания алгоритмов роевого интеллекта

© | Карпенко Анатолий Павлович

apkarpenko@mail.ru

МГТУ им. Н.Э. Баумана, Москва, 105005, Россия

Проблема преподавания алгоритмов роевого интеллекта заключается в их чрезвычайно большом числе и широком разнообразии используемых обозначений и выразительных средств. Предлагаем методику преподавания, основанную на систематизации этих средств. Представляем авторскую систематизацию основных сущностей роевых алгоритмов, используемых операторов, а также типовые структуры этих алгоритмов. Выделяем такие сущности, как параметры, особь, рой особей, мультирой и субвой, пространства, графы и метрики соседства особей и совокупностей особей, окрестности особей, регионы поиска и следы особей, объединения особей и множества соседей, характеристики сущностей, итерационная формула, другие сущности, включая аттракторы и каналы связей между особями. Среди операторов роевых алгоритмов выделяем следующие: инициализация роя и завершение итерационного процесса; операторы селекции, мутации, скрецивания; операторы локального поиска и глобального поиска; операторы управления роем и субвой; операторы удовлетворения ограничений; коммуникации особей и их объединений.

Ключевые слова: глобальная оптимизация, метаэвристические алгоритмы; биоинспирированные алгоритмы, роевый интеллект, роевые алгоритмы, эволюционные алгоритмы

Введение. Роевые алгоритмы вдохновлены живой природой (являются биоинспирированными) и включают в себя алгоритмы колонии муравьев, роя медоносных пчел, иммунной системы, бактерий, светлячков, сорняков и т. д. Роевые алгоритмы являются подмножеством класса популяционных алгоритмов, к которым принадлежат также: алгоритмы, вдохновленные неживой природой (алгоритмы гармонии звуков, гравитации, электромагнетизма, системы электрических зарядов и т.д.); алгоритмы, инспирированные человеческим обществом (алгоритмы эволюции разума, стохастического диффузионного поиска, культурный алгоритм, меметические алгоритмы, алгоритмы рассеянного поиска, прокладки путей и т. д.); прочие алгоритмы (алгоритм роя частиц, алгоритм динамических сеток и т. д.).

Рассматриваем задачу глобальной условной оптимизации вида

$$\min_{X \in D} \varphi(X) = \varphi(X^*) = \varphi^*,$$

где $X \in \Re^{|X|}$ — вектор варьируемых параметров; $D \subset \Re^{|X|}$ — область допустимых значений X ; $\varphi(X)$ — фитнес-функция; X^* , φ^* — искомые оптимальный вектор X и значение фитнес-функции соответственно.

Вероятно, наиболее известным примером роевого алгоритма является алгоритм оптимизации роем частиц (Particle Swarm Optimization, PSO) [1]. Для особи $s_i \in S$ итерационную формулу алгоритма определяют выражения

$$\begin{aligned} X'_i &= X_i + \Delta X_i; \\ \Delta X_i &= b_I \Delta X_i(t-1) + U_{|X|}(0; b_C) \otimes (X_i^{hbest} - X_i) + U_{|X|}(0; b_S) \otimes (X_i^{NBbest} - X_i). \end{aligned}$$

Здесь приняты следующие обозначения: $X_i, \Delta X_i$ — текущее положение и «скорость» особи; X_i^{hbest} — наилучшую точку в полном следе особи (см. ниже); s_i^{NBbest} — наилучшая особь из числа ближайших текущих соседей NB_i особи s_i ; $U_{|X|}(a; b)$ — $|X|$ -мерная случайная величина, компоненты которой равномерно распределены в интервале $[a; b]$.

Проблемы преподавания алгоритмов роевого интеллекта определяет их большое число, а также отсутствие систематизации выразительных средств. Предлагаем методику преподавания этих алгоритмов, основанную на систематизации и унификации выразительных средств.

Основные сущности роевых алгоритмов (исключая операторы).

Параметры. Как и другие сущности роевых алгоритмов, разделяем параметры на *стационарные* и *динамические*. Значения стационарных параметров остаются постоянными на протяжении всего поиска, то есть, до завершения итерационного процесса. Динамические параметры могут изменять свои значения в процессе поиска. Среди динамических параметров выделяем *программные, адаптивные и программно-адаптивные* параметры.

Метапараметрами называем свободные *вспомогательные* параметры, которые определяют значения *основных* параметров П-алгоритма (свободных и прочих).

Особь, рой и субвой. Особь S определяют ее следующие атрибуты:

$$V, \varphi(X)\langle, channel\rangle\langle, track\rangle\langle, \Phi - track\rangle.$$

Здесь V — вектор переменных состояния особи, компонентами которого, вообще говоря, являются векторы положения особи $X \in \Re_X$, ее скорости $\Delta X = (X - X^{t-1})$ и, может быть, ускорения $\Delta^2 X = \Delta X - \Delta X^{t-1}$; $\varphi(X) \in \Re_\varphi$ — фитнес-функция; *channel* — прямой канал связи особи с другими особями роя; *track*, Φ -*track* — след особи и ее феромонный след соответственно (см. ниже).

Рой S представляет собой совокупность особей, так что $S = \{s_i; i \in [1 : |S|]\}$.

Мощность $|S|$ роя может изменяться в процессе его эволюции. Различаем однородные и неоднородные рои.

Мультирои определяем, как совокупность некоторого числа коммутирующих суброев, эволюционирующих, по меньшей мере, на логическом уровне параллельно.

Пространства, графы и метрики соседства особей. Роевые алгоритмы используют следующие пространства: евклидово пространство поиска $\mathfrak{R}_X = \mathbb{R}^{|X|}$; пространство поиска в сферических координатах $\mathfrak{R}_A = \mathbb{R}^{|X|}$; цеплевое пространство $\mathfrak{R}_\phi = \mathbb{R}^1$; топологическое пространство \mathfrak{R}_T . Чаще всего применяют стационарные топологии соседства особей, определяемые следующими *графами соседства*: линейный граф; клика; кольцо; двумерный тор; кластер [1]. Стационарные графы соседства всех этих типов могут использоваться, например, алгоритмом роя частиц PSO.

Соседство особей в пространствах $\mathfrak{R}_\phi, \mathfrak{R}_X, \mathfrak{R}_A, \mathfrak{R}_T$ определяем с помощью *метрик соседства* вида $\mu_{\mathfrak{R}}(s_i, s_j)$, где $\mathfrak{R} \in \{\mathfrak{R}_\phi, \mathfrak{R}_X, \mathfrak{R}_A, \mathfrak{R}_T\}$. По общему правилу различаем стационарные и динамические метрики. В первом случае метрики (но, конечно, не их значения) не изменяются в процессе эволюции роя, а во втором случае — изменяются программно, адаптивно или программно-адаптивно.

Окрестности особей, регионы поиска и следы особей. Окрестностью A_i особи $s_i \in S$ в пространстве \mathfrak{R} (\mathfrak{R} — окрестностью этой особи) называем область этого пространства, элементы которой в смысле метрики $\mu_{\mathfrak{R}}(\cdot)$ близки к особи s_i . В роевых алгоритмах обычно используют окрестности в пространстве \mathfrak{R}_X . Окрестности особи в разных роевых алгоритмах могут называться по-разному, например, в муравьином алгоритме *HClAC* \mathfrak{R}_X — окрестность названа *зоной видимости* (муравья).

Центры окрестностей в пространствах $\mathfrak{R}_\phi, \mathfrak{R}_X$ могут не ассоциироваться с текущим значением фитнес-функции или положением той или иной особи. Так, в некоторых роевых алгоритмах говорят об окрестности (*регионе*) $A_{\mathfrak{R}_X}(X, R)$ одной из точек $X \in D$, например, некоторой точки следа особи. Концепция региона поиска близка концепции окрестности особи, с тем отличием, что регион поиска не «привязан» к особи, но представляет собой просто некоторую подобласть пространства поиска.

Рассматриваем только следы особей в пространстве поиска \mathfrak{R}_X (хотя можно было бы говорить также о следах в пространстве \mathfrak{R}_ϕ). Под (*обычным*) следом особи понимаем историю ее эволюции в пространстве поиска в течение некоторого числа итераций роевого алгоритма, предшествующих текущей итерации t , то есть полагаем, что след особи $s_i \in S$ образует последовательность ее положений и соответствующих значений фитнес-функции $\{(X_i(\tau), \varphi(X_i(\tau)); \tau \in [t_b : t_e])\}$, где t_b, t_e — начало и конец следа соответственно; $0 \leq t_b < t_e \leq t$.

В некоторых роевых алгоритмах полагают, что в каждой точке $X_i(\tau), \tau \in [t_i^\phi : t]$ пространства поиска \mathfrak{R}_X , в которой побывала особь s_i ,

остается *феромонная метка*, интенсивность которой (количество феромона) на данной итерации t определяет функция $\varphi_i(t, \tau, t_i^\varphi)$, где t_i^φ — номер итерации, на которой оставлена эта метка. Количество феромона в феромонных метках с ростом числа итераций уменьшается (это моделирует испарение феромона).

Объединения особей и множества соседей. Каждая особь роя S может входить одновременно в несколько *объединений* (так что объединения особей, используемые роевыми алгоритмом, вообще говоря, пересекаются). Рой и субвой можно считать объединениями особей в пространстве \Re_X . В некоторых роевых алгоритмах особи, входящие в данное их объединение, называются *соседями* (neighbors). Различаем стационарные и динамические объединения особей. Стационарное объединение не меняет состав особей, включенных в него, на протяжении всей эволюции роя — на всех итерациях $t \in [0 : \hat{t}]$. Напротив, состав динамического объединения меняется в процессе поиска.

Множеством соседей $NB_i(s_i)$ особи $s_i \in S$ в пространстве $\Re \in \{\Re_\varphi, \Re_X, \Re_T\}$ может быть объявлена совокупность особей $\{s_j\}$, текущие координаты $\{X_j\}$ которых принадлежат некоторой окрестности A_{\Re} этой особи:

$$NB_i(s_i, P) = \{s_j \mid X_j \in A_{\Re}(s_i, P)\} \subseteq S.$$

Характеристики сущностей. Характеристика сущности — величина, значения которой определяют «состояние» сущности. Характеристики изменяют свои значения в процессе эволюции роя и используются для управления его эволюцией. Примером характеристики является средняя относительная доля успешных мутаций, вычисленная на основе результатов эволюции роя в течение заданного числа поколений.

Другие сущности. Кроме указанных выше различаем еще следующие сущности роевых алгоритмов: атTRACTоры; каналы связей между особями и их наборами; события и т. д. [1].

Основные операторы роевых алгоритмов. Выделяем следующие классы операторов:

- инициализация роя и завершение итерационного процесса;
- операторы селекции, мутации и скрещивания;
- управление роем и субвой — ассоциация (association), «встряска» (shake-up), замена (replacement), исключение особей (deleting), кластеризация (clustering), обновление (renovation), переупорядочение, в частности, тасование (reordering), репликация (replication), расширение (expansion), расщепление (splitting), сжатие (compression);
- удовлетворение ограничений;
- локальный поиск — одноточечные одношаговые атTRACTорные алгоритмы, одноточечные одношаговые «когнитивные» алгоритмы, одноточеч-

ные одношаговые алгоритмы случайного и хаотического поиска, одноточечные одношаговые «социальные» алгоритмы, многоточечные алгоритмы, гибридные алгоритмы.

- глобальный поиск.

По общим правилам различаем детерминированные и стохастические операторы, а также стационарные и динамические (программные, адаптивные и программно-адаптивные) операторы.

Типы структур роевых алгоритмов. Предлагаем выделять следующие типовые структуры роевых алгоритмов:

- однороевые алгоритмы;
- одноуровневые многороевые алгоритмы;
- двухуровневые многороевые алгоритмы (рис. 1);
- трехуровневые многороевые алгоритмы (рис. 2).

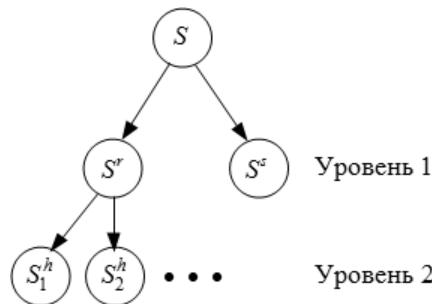


Рис. 1. Пример структуры трехуровневого многороевого алгоритма оптимизации роем пчел (OptBees [2])

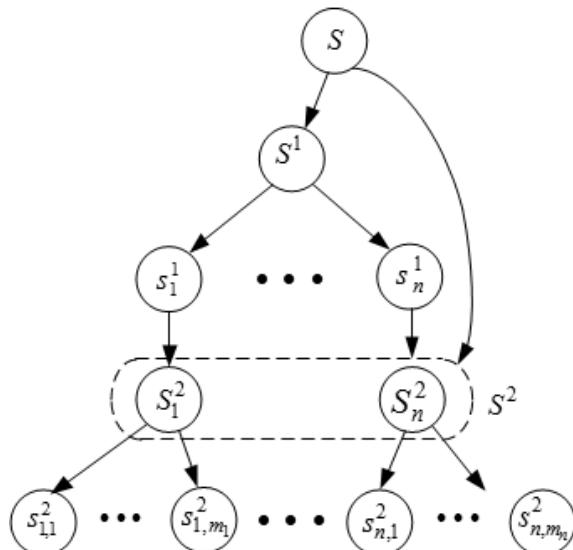


Рис. 2. Пример структуры трехуровневого многороевого алгоритма империалистической конкуренции (Imperialist Competitive Algorithm [3])

Заключение. Кроме представленных сущностей мы выделяем еще *базовые операции* роевых алгоритмов: операции линейной алгебры, генерация случайных и хаотичных величин, кластеризация совокупностей особей, многоцелевая оптимизация, генерация плана эксперимента, методы рандомизация поиска, сортировка, другие операции.

Автор использует представленный подход к преподаванию основ роевого интеллекта в курсе «Современные алгоритмы оптимизации» магистерской программы кафедры САПР МГТУ им. Н.Э. Баумана. Актуальными являются следующие проблемы: подготовка лабораторных работ по указанному курсу; подготовка методических материалов; разработка варианта курса для бакалавриата.

Литература

- [1] Карпенко А.П. Современные алгоритмы поисковой оптимизации. Алгоритмы, вдохновленные природой. М.: Изд-во МГТУ им. Н.Э. Баумана, 2014. 446 с.
- [2] Maia R.D., de Castro L.N., Caminhas W.M. OptBees — a Bee-inspired algorithm for solving continuous optimization problems // BRICS Congress on Computational Intelligence & 11th Brazilian Congress on Computational Intelligence. 2013. Pp. 142–151.
- [3] Abdollahi M., Isazadeh A., Abdollahi D. Imperialist competitive algorithm for solving systems of nonlinear equations // Computers and Mathematics with Applications. 2013. Vol. 65 (12). Pp. 1894–1908.

Methodology for Teaching Swarm Intelligence Algorithms

© | Karpenko A.P.

apkarpenko@mail.ru

BMSTU, Moscow, 105005, Russia

The problem of teaching swarm intelligence algorithms lies in their extremely large number and wide variety of notation and expressive means used. We propose a teaching methodology based on the systematization of these tools. We present the author's systematization of the main essences of swarm algorithms, the operators used, as well as the typical structures of these algorithms. We select such entities as parameters, an individual, a swarm of individuals, a multiroy and a subroy, spaces, graphs and metrics of the neighborhood of individuals and sets of individuals, neighborhoods of individuals, search regions and traces of individuals, unions of individuals and sets of neighbors, characteristics of entities, iterative formula, other entities, including attractors and communication channels between individuals. Among the operators of swarm algorithms, we single out the following: swarm initialization and completion of the iterative process; selection, mutation, crossover operators; local search and global search operators; swarm and subswarm management operators; constraint satisfaction operators; communication of individuals and their associations.

Keywords: global optimization, metaheuristic algorithms; bioinspired algorithms, swarm intelligence, swarm algorithms, evolutionary algorithms

УДК 004.8

Практика применения искусственного интеллекта и нейронных сетей в задачах управления в образовании: методология, кейсы, деловые игры

© Ляпунцова Елена Вячеславовна
Ноговицын Максим Александрович

lev86@bmstu.ru
maximnogovitsyn@gmail.com

МГТУ им. Н.Э. Баумана, Москва, 105005, Россия

Широкое применение современных технологий позволяют создавать необходимые условия к развитию более устойчивого экономического, технологического и образовательного суверенитета страны. Задача такого применения умных технологий, в частности искусственного интеллекта и нейронных сетей, стать одним из мировых лидером в ряде высоко технологичных направлениях, укрепить позиции в международном, научном, образовательном, экономическом плане. Бизнес и корпорации стремятся внедрить технологии для эффективного управления проектами. Но, важной составляющей данного этапа является изучение и использование инновационных технологий в образовательной и научной среде для подготовки квалифицированных кадров для экономики.

Ключевые слова: умные технологии, образование, образовательный продукт, искусственный интеллект, управление образованием

В настоящее время большое внимание уделяется развитию и применению умных технологий для управления проектами, процессами, задачами с учетом программы развития экономики страны и Национальных проектов Российской Федерации «Образование», «Университеты и наука».

За период 2019–2022 гг. более на 270 % увеличилось число компаний с применением умных технологий для управления проектами, задачами, процессами. «Около 52 % крупных организаций в России внедряют в свою деятельность искусственный интеллект, а объем данного рынка к 2030 году должен увеличиться минимум вдвое — до 20 миллиардов рублей», — заявил вице-премьер РФ Д. Чернышенко [2]. Согласно опубликованной аналитики более 40 % организаций в мире внедрили технологии искусственного интеллекта (ИИ) в различных формах [3].

Разработаны дорожные карты развития по ряду направлений: «Современные и перспективные сети мобильной связи», «Новое индустриальное программное обеспечение», «Новое общесистемное программное обеспечение», «Квантовые коммуникации», «Квантовые вычисления», «Искусственный интеллект» [1,4].

По прогнозам аналитиков и экспертов вклад сферы искусственного интеллекта (ИИ) в ВВП России к 2025 году составит 2 %. Важно отметить, что запланировано разработка более 60 перспективных технологических решений.

Именно поэтому важно закладывать базис и фундаментальные знания и навыки в университетских экосистемах, в научных и экспериментальных лабораториях и центрах, которые объединяют вместе все целевые аудитории, создавая все предпосылки разработки актуальных технологических решений для конкретных задач и проектов.

Массовое внедрение искусственного интеллекта в ключевых отраслях — это основной результат при разработке дорожных карт и выполнения поставленных задач в Федеральном проекте «Искусственный интеллект», что должно достичь соответствующих экономических эффектов. В развитие Национальной стратегии утвержден Федеральный проект «Искусственный интеллект» сроком реализации до конца 2024 г. Предусмотрено бюджетное финансирование в размере 24,1 млрд руб., а также из внебюджетных источников — 5,1 млрд рублей [5].

Все тенденции нацелены на получение эффекта технологического, научного и образовательного суверенитетов страны. Это возможно, если университетах будут созданы все условия для получения новых знаний и навыков применения умных технологий, которым относятся парадигма нейронных сетей, искусственный интеллект, виртуальная и дополненная реальности.

Высшее образование встраивается в общую линию цифровизации, вузы стремительно «переходят в цифру» и переводят образовательную активность в онлайн, а аналоговое, традиционное образование уходит в прошлое. Вузы находятся в стадии переосмысливания образовательного процесса и дидактики, поиска эффективных цифровых образовательных технологий и электронных ресурсов, которые позволяют подготовить выпускника к требованиям современного рынка труда [6]. Применение ИИ в образовании — это значимая тема и стоит изучать с учетом реальных проектов и конкретных примеров. Именно по этой причине возникает задача: формирования правил и рекомендаций, разработки методологии и практики применения ИИ в образовании. И если применять искусственный интеллект в образовании, то точно стоит отталкиваться от реальных возможностей, которые доступны уже сейчас. В июне прошел семинар «AI в обучении: на что способны технологии уже сейчас?», чтобы найти золотую середину между реальностью и фантастикой. Представители и эксперты в области образования из «СберУниверситета», НИУ ВШЭ и Университета 2035 в диалоге обсудили актуальные темы: алгоритмы ИИ и нейронных сетей, которые применяются в обучении в настоящее время; реальные кейсы применения ИИ в образовании; в какие образовательные проекты точно можно и имеет смысл внедрить ИИ; этические стороны применения ИИ и нормативно-правовое поле использование продукта с помощью ИИ [7].

Основное направления деятельности применения искусственного интеллекта в образовании — это большие данные (Data Science). Данные и описание основных алгоритмов приведены в таблице 1.

При описании и применении любой технологии необходимо знать четко цель и средства, которые стоит применить. В табл. 2 сгруппированы кейсы

в зависимости от цели использования технологии, что позволяет с большей уверенностью достичь нужного результата с учетом понятий, указанных в данной статье.

Таблица 1. Алгоритмы ИИ в образовании

№ п/п	Основные типы ИИ в обучении	Описание алгоритмов ИИ в образовании
1	Ансамбли алгоритмов	В основу лежат логика различной степени сложности. ИИ отвечает за построение индивидуальных траекторий обучения, анализ эффективности плана урока
2	Предобученные нейросети	Для создания решения одной конкретной задачи, обучаются на большом объеме данных, автоматическое понимание языка, распознавание эмоций на лицах. Применяются модели opensource: GPT-3; BERT; YaLM 100B; RUGPT-3
3	Нейросети теневого глубокого обучения	Предобученную нейросеть дообучают на меньшем объеме данных, для решения узкой задачи, языковой нейросети курса

Таблица составлена авторами.

Таблица 2. Кейсы применения ИИ в образовании

№ п/п	Кейсы: цель использования технологии	ИИ в обучении софт-скиллам	ИИ в оценке учащихся	ИИ в учебной аналитике	ИИ в улучшении опыта студента
1	Кейс	Подбор команд с помощью ИИ (опыт НТИ)	Автоматическая разработка заданий (опыт Института русского языка им. Пушкина)	Предсказательная аналитика (прогноз для планирования уроков и контроля)	Перевод конспекта лекции для методистов (на базе моделей opensource: Speech to text, BERT)
2	Кейс	Диагностика коммуникативных навыков	Проверка заданий с открытыми ответами/эссе	Аналитика качества учебных материалов	Адаптивное обучение (возможность развиваться осознанно)
3	Кейс	—	—	Аналитика цифровой рефлексии (Минцифра)	—

Таблица составлена авторами.

Методология — это стратегия исследования, которая определяет способ проведения такого исследования с учетом определенных методов и способов. Кейсы — это реальные примеры и ситуации, с помощью которых разбираются с применением теоретических и практических идей. Деловая игра — это имитация принятия решения в разных профессиональных ситуациях при наличии неопределенностей, вызовов.

Постулаты при внедрении ИИ в области образования:

- контролировать качества работы ИИ,
- проверять работу системы и верификация;
- поддерживать принципы этичности и прозрачности;
- ИИ не заменит учителя и преподавателя, а высвобождает им время;
- омнить про человечность при работе с технологией.

При применении ИИ в образовании важны принципы, методы, нормативно-правовые аспекты. Ведь технология освобождает от монотонного и рутинного труда. Методологи образовательного процесса создают экосистему образовательного продукта с применением педагогического дизайна и различных моделей. Технология, которая выстроена высококвалифицированными методистами, позволяет повысить доступность и качество образования, что нацелено на помочь преподавателю. ИИ-технологии обладают большим потенциалом, поэтому и дальше будут использоваться во многих сферах, включая образование. Однако необходимо соблюдать безопасность, конфиденциальность. Важно применять ИИ-технологии исключительно во благо педагога и ученика.

В статье сделается попытка сформировать универсальную методологию, т. е. сформировать пошаговый алгоритм.

1. Провести опрос и мониторинг целевой аудитории и лиц, принимающих решение.

2. Выделить на предприятии направления перспективных и стратегических исследований.

3. Изучить потребности в интеллектуализации производственных задач.

4. Обеспечить долгосрочное развитие и применение методологии.

5. Внедрить инструментарий и систему в области искусственного интеллекта из предлагаемого запроса.

6. Рассмотреть основные области применение ИИ на конкретном промышленном предприятии, их возможная конкретизация направлений исследования.

7. Проанализировать основные задачи, решаемые нейронными сетями в промышленности.

8. Определить необходимость создания цифровых двойников на предприятии, создание изделий совместно с ИИ, что позволит более эффективно решить задачи разработки изделий, их производство и эксплуатацию.

9. Изучить возможные предпосылки проектной деятельности организации с учетом применения основ и теории многоагентных систем.

Практика применения ИИ пока не имеет системного характера и важно именно сейчас заложить методологию для эффективного использования в об-

разовании. В полной мере не имеется нормативно-правового поля и не существуют документы, которые четко регламентируют использование ИИ в сфере образования. Пока обозначены ориентиры, которые содержатся в документах федерального уровня [8, 9].

Важно создать все условия для применения технологии на практике: технологии языкового распознавания, обработки и генерации естественного языка, технологии персонализации обучения, адаптивного обучения, виртуальные помощники, прокторинг, технологии интервального (промежуточного) обучения, автоматическая оценка, смарт-кампус, геймификация, чат-боты, кейсы, деловые игры.

Использование технологий ИИ в образовании базируются на совокупности информационного, гуманистического, правового подходов. Однако возникают противоречия и служат предпосылками исследования этических и аксиологических аспектов применения ИИ в сфере образования.

Все выше сказанное является предпосылкой для формирования научного направления, которое точно будет объединять и практические, и технологические аспекты на стыке дисциплин и конвергентных наук. И, следовательно, возникающие противоречия дают основания подходить к данной теме системно и с научной точки зрения.

В заключении, стоит отметить, что внедрение инновационного всегда сложный и порой трудный процесс, переход от традиционных к новаторским предложениям не всегда является быстрым процессом. Однако именно изменение мышления и понимания трендов, вызовов и возможностей дают положительный результат для эффективного развития образования и экономики.

Литература

- [1] Национальные проекты РФ. URL: <https://национальныеприоритеты.рф/> (дата обращения 11.04.2023).
- [2] Чернышенко спрогнозировал рост российского рынка ИИ-технологий к 2030 году. URL: <https://ria.ru/20230116/ii-1845241370.html> (дата обращения 11.04.2023).
- [3] Gartner Survey Shows 37 Percent of Organizations Have Implemented AI in Some Form. Available at: <https://www.gartner.com/en/newsroom/press-releases/2019-021-gartner-survey-shows-37-percent-of-organizations-have> (accessed April 11, 2023).
- [4] Демократизация технологий ИИ — ключевой тренд 2023 года. Available at: <https://issek.hse.ru/news/809194064.html> (accessed April 10, 2023).
- [5] Федеральный проект «Искусственный интеллект». URL: https://www.economy.gov.ru/material/directions/fed_proekt_iskusstvennyy_intellekt/ (дата обращения 10.04.2023).
- [6] Семенова Л.М. Динамика цифровой дидактики в условиях трансформации высшего образования. Ч. I // Мир науки. Педагогика и психология. 2020. № 3. URL: <https://mir-nauki.com/PDF/87PDMN320.pdf> (дата обращения 10.04.2023).
- [7] AI в обучении: на что способны технологии уже сейчас? URL: <https://sberuniversity.ru/edutech-club/events/seminar-edutech-sessiya-49/?ysclid=l74ep9mz5n723464186> (дата обращения 10.04.2023).
- [8] Указ Президента РФ от 10.10.2019 № 490 «О развитии искусственного интеллекта в Российской Федерации» (вместе с «Национальной стратегией развития искусственного ин-

теллекта на период до 2030 года»). URL: https://www.consultant.ru/law/podborki/iskusstvennyj_intellekt/ (дата обращения 10.04.2023).

- [9] Федеральный закон от 24.04.2020 № 123-ФЗ «О проведении эксперимента по установлению специального регулирования в целях создания условий для разработки и внедрения технологий искусственного интеллекта в субъекте Российской Федерации — городе федерального значения Москве и внесении изменений в статьи 6 и 10 Федерального закона «О персональных данных». URL: https://www.consultant.ru/document/cons_doc_LAW_351127/#dst0 (дата обращения 11.04.2023).

The Practice of using Artificial Intelligence and Neural Networks in Management tasks in Education: Methodology, Cases, Business Games

© Lyapunotsva E.V.
Nogovitsyn M.A.

lev86@bmstu.ru
maximnogovitsyn@gmail.com

BMSTU, Moscow, 105005, Russia

The widespread use of modern technologies makes it possible to create the necessary conditions for the development of a more sustainable economic, technological and educational sovereignty of the country. The task of such application of smart technologies, in particular artificial intelligence and neural networks, is to become one of the world leaders in a number of high-tech areas, to strengthen positions in international, scientific, educational, and economic terms. Businesses and corporations are striving to introduce technologies for effective project management. However, an important component of this stage is the study and use of innovative technologies in the educational and scientific environment for the training of qualified personnel for the economy.

Keywords: smart technologies, education, educational product, artificial intelligence, education management

УДК 004.81

Карта компетенций выпускника технического вуза для когнитивного моделирования: разработка и оценка навыков

© Панилов Павел Алексеевич panilovp.a@bmstu.ru
Рыжова Наталья Валентиновна leftan.v@bmstu.ru
Цибизова Татьяна Юрьевна tumc@bmstu.ru

МГТУ им. Н.Э. Баумана, Москва, 105005, Россия

Рассмотрена карта компетенций выпускника технического вуза для когнитивного моделирования. Представлены основные компетенции и навыки, необходимые для работы в области когнитивного моделирования, а также предложена система оценки компетенций и навыков выпускников для создания карты компетенций. Описаны примеры компетенций и навыков, а также способы их оценки. Предложенная система оценки позволит выпускникам технического вуза получить обратную связь по результатам оценки своих компетенций и навыков, а также рекомендации по дополнительному обучению и развитию недостающих компетенций. Регулярное обновление системы оценки и карты компетенций поможет выпускникам оставаться в курсе современных требований рынка труда и развития технологий в области когнитивного моделирования.

Ключевые слова: карта компетенций, технический вуз, когнитивное моделирование, навыки, компетенции, система оценки, обучение, повышение квалификации

Введение. В настоящее время когнитивное моделирование становится все более востребованным в различных сферах, таких как машинное обучение, робототехника, разработка программного обеспечения и другие. Эта область требует от специалистов высокой квалификации и определенных навыков. В связи с этим, необходимо разработать карту компетенций выпускника технического вуза для когнитивного моделирования, которая помогла бы выпускникам подготовиться к современным требованиям рынка труда и развивать свои навыки [1, 2].

Карта компетенций выпускника технического вуза для когнитивного моделирования может включать следующие компетенции и навыки.

1. Программирование

- знание языков программирования (Python, Java, C++, MATLAB и т. д.);
- навыки разработки программного обеспечения;
- знание алгоритмов и структур данных.

2. Математическое моделирование

- знание математических методов и их применения в моделировании;
- навыки работы с математическими пакетами (MATLAB, Mathematica и т. д.);
- опыт создания математических моделей и анализа их результатов.

3. Искусственный интеллект

- знание методов машинного обучения и их применения в обработке данных;
- навыки работы с фреймворками машинного обучения (TensorFlow, Keras, PyTorch и т. д.);
- опыт разработки и обучения нейронных сетей.

4. Обработка и анализ данных

- знание методов обработки и анализа данных (статистические методы, машинное обучение и т. д.);
- навыки работы с базами данных и языками запросов (SQL, NoSQL и т. д.);
- опыт работы с большими объемами данных и их обработки.

5. Коммуникация и управление проектами

- навыки коммуникации и работы в команде;
- знание методов управления проектами (Scrum, Agile и т. д.);
- опыт управления проектами и достижения целей.

6. Экспертиза и консультирование

- знание технологий и методов когнитивного моделирования;
- опыт консультирования и экспертизы проектов в области когнитивного моделирования;
- навыки предоставления консультаций и рекомендаций по улучшению проектов.

7. Аналитическое мышление и решение проблем

- навыки аналитического мышления и решения проблем;
- опыт и умение принимать решения на основе анализа данных;
- знание методов и техник решения проблем.

Каждая компетенция может быть разбита на несколько уровней: начинающий, средний и продвинутый. Каждый уровень включает набор конкретных знаний и навыков, которые нужны для достижения этого уровня [3]. Кроме того, каждая компетенция может быть связана с определенными проектами или задачами, которые выпускник может решить при наличии соответствующих навыков и знаний [4, 5].

Примеры применения компетенций выпускника технического вуза для когнитивного моделирования.

1. Разработка алгоритмов машинного обучения для анализа данных мозговой активности. Выпускник технического вуза, который обладает навыками программирования и пониманием архитектуры компьютера, может разработать алгоритмы для обработки данных мозговой активности и использовать методы машинного обучения для классификации и прогнозирования поведения человека [6, 7].

2. Создание когнитивных моделей для анализа решения проблем и принятия решений. Выпускник, который обладает знаниями в области психологии и когнитивной науки, может разработать когнитивные модели для анализа решения проблем и принятия решений. Такие модели могут помочь в обучении и тренировке людей для принятия лучших решений в условиях неопределенности [8, 9].

3. Разработка программного обеспечения для когнитивных тестов. Выпускник, который обладает навыками программирования и пониманием теории искусственного интеллекта, может разработать программное обеспечение для когнитивных тестов, которые используются для измерения когнитивных способностей и проблемных областей [10]. Такие тесты могут быть полезны для определения уровня развития когнитивных способностей у людей и для разработки персонализированных обучающих программ.

4. Разработка системы обнаружения и диагностики психических заболеваний. Выпускник, который обладает навыками программирования и знаниями в области психологии и когнитивной науки, может разработать систему обнаружения и диагностики психических заболеваний, которая использует данные мозговой активности и другие биомаркеры для определения возможных заболеваний и предотвращения их развития [11, 12].

Для оценки компетенций и навыков можно использовать систему баллов. Каждый уровень компетенции может быть оценен от 1 до 10 баллов в зависимости от сложности и важности навыков и знаний, которые он включает. Оценка может быть произведена как на основе знаний и опыта, так и на основе проектной деятельности, с помощью которой можно оценить реальные навыки выпускника.

После оценки компетенций и навыков выпускников можно создать карту компетенций, которая будет отражать уровень знаний и навыков по каждой компетенции. Карта компетенций может быть представлена в виде блок-схемы, где каждая компетенция будет представлена отдельным блоком, а уровень знаний и навыков будет отражаться цветом или размером блока.

Создание карты компетенций позволит выпускникам технических вузов увидеть свои слабые и сильные стороны в области когнитивного моделирования, что поможет им определить свои карьерные пути и развиваться в нужном направлении. Кроме того, работодатели смогут оценить уровень компетенций и навыков потенциальных сотрудников, что поможет им подобрать наиболее подходящих кандидатов для работы в области когнитивного моделирования.

Предложим алгоритм создания карты компетенций для когнитивного моделирования.

Шаг 1: Определение ключевых компетенций и навыков

Первым шагом необходимо определить ключевые компетенции и навыки, необходимые для успешного выполнения задач в области когнитивного моделирования. Для этого можно провести анализ требований к вакансиям, опросить работодателей и экспертов, а также обратиться к существующим описаниям должностей в данной области.

Шаг 2: Оценка уровней компетенций и навыков

На этом шаге необходимо определить уровни владения ключевыми компетенциями и навыками для каждой должности. Это можно сделать, используя различные методы, такие как опрос работников, проведение тестирования, анализ результатов работы и т. д. Результаты могут быть представлены в виде матрицы, где по горизонтали будут указаны ключевые компетенции и навыки, а по вертикали — уровни владения ими.

Шаг 3: Создание карты компетенций

Для создания карты компетенций необходимо взять полученные результаты и визуализировать их в виде диаграммы. Это может быть круговая диаграмма, где каждая область соответствует отдельной компетенции, а ее размер определяется уровнем владения данной компетенцией. Также можно использовать древовидную диаграмму, где каждый уровень владения компетенцией соответствует отдельной ветви дерева.

Шаг 4: Проверка и обновление карты компетенций

Карта компетенций должна регулярно обновляться, чтобы отражать изменения в требованиях к должностям и владении компетенциями и навыками работников. Для этого можно использовать обратную связь от работников, результаты работы и проведение периодических обзоров требований к должностям в данной области.

Карты компетенций для когнитивного моделирования могут различаться в зависимости от конкретной области или направления.

Разработаем несколько таких карт (рис. 1–3).

1. Карта компетенций в области машинного обучения

Основные компетенции: математика и статистика, программирование, знание алгоритмов машинного обучения.

Навыки: линейная алгебра, теория вероятностей, языки программирования (Python, R), анализ данных, визуализация данных.

Уровни компетенций: начинающий, средний, продвинутый.

Шкала оценки: от 1 до 10 баллов.

Примерные задачи для оценки компетенций: разработка модели прогнозирования, анализ данных на предмет выбросов и корреляции, создание визуализации данных.

2. Карта компетенций в области компьютерного зрения

Основные компетенции: математика, знание алгоритмов компьютерного зрения, программирование.

Навыки: линейная алгебра, теория вероятностей, языки программирования (Python, C++), обработка изображений, распознавание образов.

Уровни компетенций: начинающий, средний, продвинутый.

Шкала оценки: от 1 до 10 баллов.

Примерные задачи для оценки компетенций: разработка системы распознавания лиц, создание алгоритмов для обработки изображений в режиме реального времени.

3. Карта компетенций в области нейронных сетей

Основные компетенции: математика и статистика, знание алгоритмов нейронных сетей, программирование.

Навыки: линейная алгебра, теория вероятностей, языки программирования (Python), оптимизация алгоритмов, создание нейронных сетей.

Уровни компетенций: начинающий, средний, продвинутый.

Шкала оценки: от 1 до 10 баллов.

Примерные задачи для оценки компетенций: создание нейронной сети для распознавания рукописных цифр, оптимизация работы нейронной сети на основе алгоритма обратного распространения ошибки.

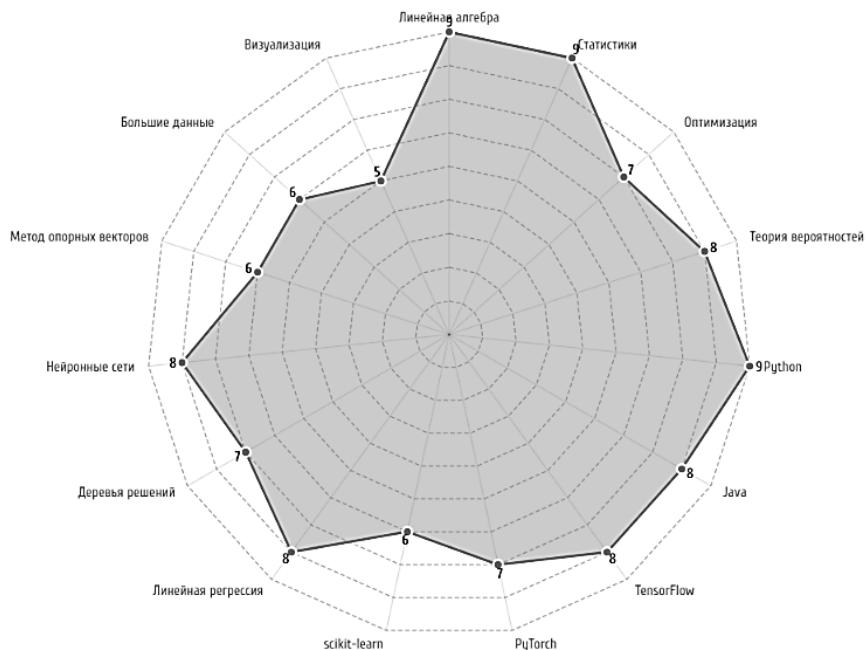


Рис. 1. Карта компетенций в области машинного обучения

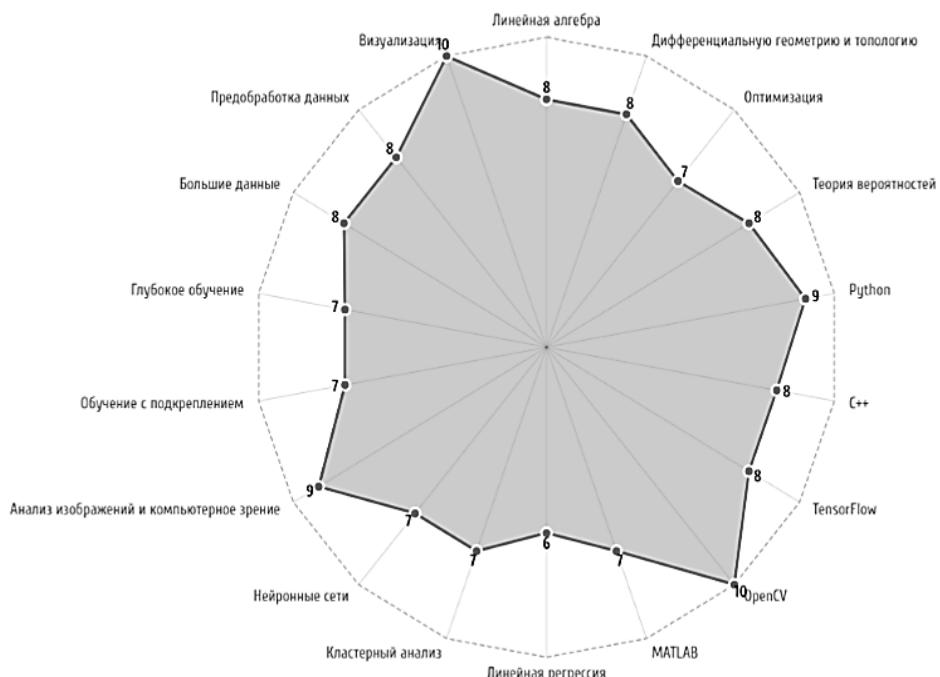


Рис. 2. Карта компетенций в области компьютерного зрения

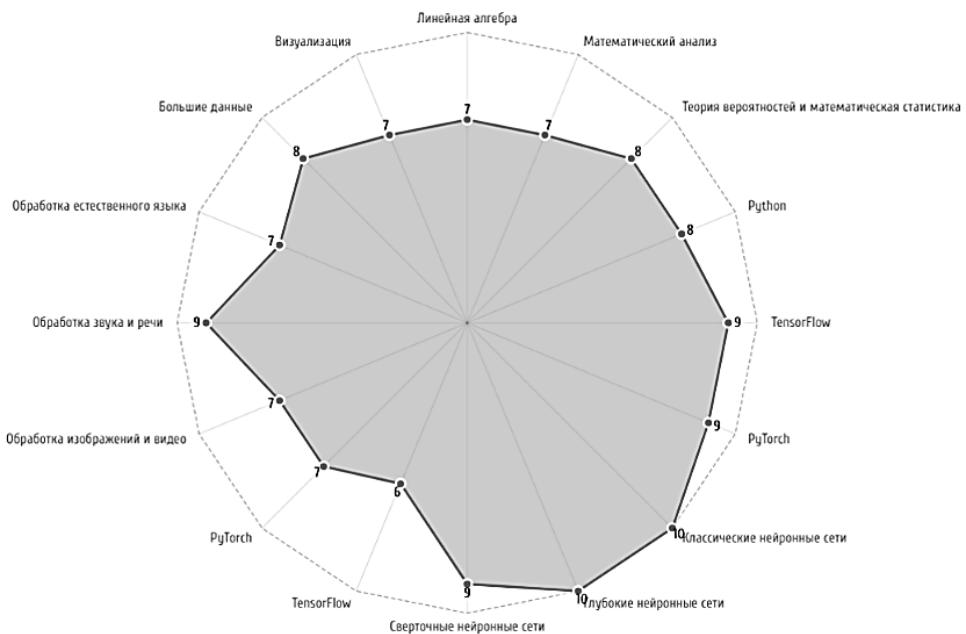


Рис. 3. Карта компетенций в области нейронных сетей

Заключение. В данной статье была представлена карта компетенций выпускника технического ВУЗа для когнитивного моделирования, которая включает в себя ключевые компетенции и навыки, необходимые для успешной работы в области когнитивного моделирования. Карта была разработана с учетом актуальных требований к профессиональным компетенциям в данной области и может использоваться в качестве основы для создания программ обучения и оценки компетенций.

Также была предложена система оценки компетенций и навыков для когнитивного моделирования, которая позволяет определить уровень владения выпускником необходимыми навыками и компетенциями. Эта система может быть использована для оценки квалификации выпускников, а также для планирования и улучшения программ обучения в данной области.

В целом, карта компетенций и система оценки, представленные в данной статье, могут быть полезными инструментами для студентов и преподавателей технических ВУЗов, которые занимаются когнитивным моделированием, а также для работодателей, которые ищут высококвалифицированных специалистов в данной области.

Литература

- [1] Лэнгли П., Лэйрд Дж.И., Роджерс С. Когнитивные архитектуры: исследовательские вопросы и проблемы // Исследования когнитивных систем. 2009. Vol. 10 (2). Pp. 141–160.
- [2] Рыжова Н.В. Роль образовательной организации в подготовке студентов к построению карьерной траектории на современном рынке труда // Кадровый потенциал инновационного развития: II Междунар. науч.-практ. конф. М.: Изд-во МГТУ им. Н.Э. Баумана, 2022. С. 177–180.
- [3] Цибизова Т.Ю., Зимин В.Н. Разработка способа реализации функции абилитации студентов и выпускников образовательных организаций в современных условиях // Автоматизация. Современные технологии. 2017. Т. 71, № 10. С. 465–468.
- [4] Рыжова Н.В. Коммуникативная компетенция как необходимый фактор развития современного специалиста // XLV Академические чтения по космонавтике, посвященные памяти академика С.П. Королева и других выдающихся отечественных ученых — пионеров освоения космического пространства: сб. тез.: в 4 т. М.: Изд-во МГТУ им. Н.Э. Баумана, 2021. Т. 2. С. 232–234.
- [5] Рыжова Н.В., Комкова Т.Ю. Отдел трудоустройства как инструмент планирования и построения карьеры выпускника // Будущее машиностроения России: Тринадцатая Всерос. конф.: сб. докл. В 2 т. М.: Изд-во МГТУ им. Н.Э. Баумана, 2020. Т. 1. С. 266–270.
- [6] Панилов П.А., Иванов А.М. Агентная имитационная модель и онтология финансового взаимодействия физических и юридических лиц с банками на примере банк-клиента // Молодежный научно-технический вестник. 2012. № 5. С. 39.
- [7] Пальцов С.В., Денискова А.О. Использование агентного подхода при реализации интеллектуальной системы // Новая наука: теоретический и практический взгляд. 2016. № 117-2. С. 159–161.
- [8] Суханов В.А., Цибизова Т.Ю. Архитектура системы развития и поддержки профессиональной интеллектуальной деятельности // Динамика сложных систем — XXI век. 2020. Т. 14, № 1. С. 23–31.
- [9] Зотов В.В., Неусыпин К.А., Цибизова Т.Ю., Чернега Е.В. Использование метода группового учета аргументов для прогнозирования профессиональной траектории // Технологии разработки и отладки сложных технических систем: VII Всерос. науч.-практ. конф.: сб. тр. М.: Изд-во МГТУ им. Н.Э. Баумана, 2020. С. 155–161.
- [10] Малахов Н.А., Цибизова Т.Ю. Аналитическое конструирование управления в краевых задачах. Практическое использование // Перспективы науки. 2019. № 12 (123). С. 55–61.
- [11] Капитонов Д.Д., Ушаков К.Е., Воскресенская О.Е. Применение прототипа модели процессов обработки и хранения визуальной и слуховой информации человеком для исследования различных способов установки приоритетов входной информации // Будущее машиностроения России: Четырнадцатая Всерос. конф.: сб. докл. В 2 т. М.: Изд-во МГТУ им. Н.Э. Баумана, 2022. С. 214–216.
- [12] Капитонов Д.Д. Разработка прототипа системы моделирования процессов обработки и хранения визуальной и слуховой информации человеком // Вестник Российского нового университета. Сер. Сложные системы: модели, анализ и управление. 2023. № 1. С. 29–36.

Graduate Competency Map for Cognitive Modeling: Development and Assessment of Skills

© Panilov P.A.
Ryzhova N.V.
Tsibizova T.Yu.

panilovp.a@bmstu.ru
leftan.v@bmstu.ru
mumc@bmstu.ru

BMSTU, Moscow, 105005, Russia

This article considers the competence map of a graduate of a technical university for cognitive modeling. The article presents the basic competencies and skills required to work in the field of cognitive modeling, and also proposes a system for assessing the competencies and skills of graduates to create a competency map. Examples of competencies and skills are described, as well as ways to assess them. The proposed assessment system will allow graduates of a technical university to receive feedback on the results of assessing their competencies and skills, as well as recommendations for additional training and the development of missing competencies. Regular updating of the assessment system and competency map will help graduates stay up to date with modern labor market requirements and technology developments in the field of cognitive modeling.

Keywords: competency map, technical university, cognitive modeling, skills, competencies, assessment system, training, advanced training

УДК 004.81

Методология эксперто-агентного когнитивного моделирования предупреждения воздействия на критическую информационную инфраструктуру

© Панилов Павел Алексеевич panilovp.a@bmstu.ru
Цибизова Татьяна Юрьевна mumc@bmstu.ru
Воскресенский Георгий Александрович georgii.voskresenskii@gmail.com

МГТУ им. Н.Э. Баумана, Москва, 105005, Россия

Рассмотрена методология эксперто-агентного когнитивного моделирования для предупреждения воздействия на критическую информационную инфраструктуру предприятия машиностроения. Были рассмотрены существующие модели и их недостатки, а также предложена усовершенствованная модель, которая включает в себя элементы анализа эффективности, автоматической настройки, машинного обучения, алгоритмов искусственного интеллекта, прогнозирования и анализа данных в реальном времени. Такие усовершенствования помогут повысить эффективность модели и обеспечить защиту критической информационной инфраструктуры предприятия машиностроения от возможных угроз и воздействий.

Ключевые слова: эксперто-агентное когнитивное моделирование, критическая информационная инфраструктура, кибербезопасность, сценарии атак, рекомендации по предотвращению воздействия, многокритериальная оптимизация

Введение. В современном мире критическая информационная инфраструктура (КИИ) является одним из ключевых объектов, обеспечивающих функционирование различных областей жизни. К ИИ относятся такие объекты, как энергетические системы, телекоммуникационные сети, системы управления транспортом, системы банковской и финансовой деятельности, системы здравоохранения и др. В связи с этим возникает необходимость разработки методологий и моделей для предупреждения воздействия на КИИ. Методология эксперто-агентного когнитивного моделирования (ЭАКМ) может быть использована для предупреждения воздействия на КИИ. Эта методология объединяет экспертную оценку и агентные моделирования, которые могут использоваться для анализа различных сценариев атак на КИИ. Эта статья рассматривает методологию ЭАКМ для предупреждения воздействия на КИИ.

Анализ существующих моделей. На данный момент существует несколько моделей, предназначенных для предупреждения воздействия на КИИ [1]. Наиболее известными являются модели:

- 1) модель круговой защиты;
- 2) модель «Дерево жизни»;
- 3) модель «Интервальные доверительные интервалы».

Модель круговой защиты предполагает создание системы защиты, состоящей из нескольких кругов защиты, каждый из которых выполняет определенную функцию защиты КИИ. Эта модель имеет следующие недостатки:

- 1) сложность реализации;
- 2) невозможность учитывать всех возможных угроз;
- 3) неэффективность в случае появления новых угроз.

Модель «Дерево жизни» представляет собой дерево, каждый узел которого описывает событие, которое может произойти в системе. Эта модель имеет следующие недостатки:

Сложность реализации;

- 1) невозможность учитывать все возможные события;
- 2) неэффективность в случае появления новых событий.

Модель «Интервальные доверительные интервалы» основана на использовании статистических методов для определения вероятности наступления определенного события. Однако эта модель также имеет недостатки:

- 1) необходимость постоянного обновления и анализа данных;
- 2) неэффективность в случае появления новых событий;
- 3) необходимость использования большого количества данных для достижения точности прогнозирования.

Разработка методологии экспертно-агентного когнитивного моделирования. Для решения задачи предупреждения воздействия на критическую информационную инфраструктуру предлагается использовать методологию эксперто-агентного когнитивного моделирования (ЭАКМ).

ЭАКМ основывается на использовании экспертных знаний и агентных технологий для разработки моделей, способных эффективно предупреждать воздействие на КИИ [2].

ЭАКМ позволяет создавать модели, которые могут адаптироваться к изменяющейся среде и учитывать новые угрозы и события [3].

Основными компонентами ЭАКМ являются:

- 1) экспертная система, которая используется для хранения и обработки экспертных знаний [4, 5];
- 2) агентная система, которая используется для моделирования поведения системы и обеспечения ее защиты [6, 7];
- 3) методы машинного обучения, которые используются для анализа данных и обнаружения новых угроз и событий [8, 9].

Модель для предупреждения воздействия на КИИ предприятия машиностроения. Предложим модель для предупреждения воздействия на КИИ предприятия машиностроения с использованием ЭАКМ.

Экспертная система будет содержать экспертные знания о том, какие угрозы могут возникнуть и какие меры защиты необходимо принимать.

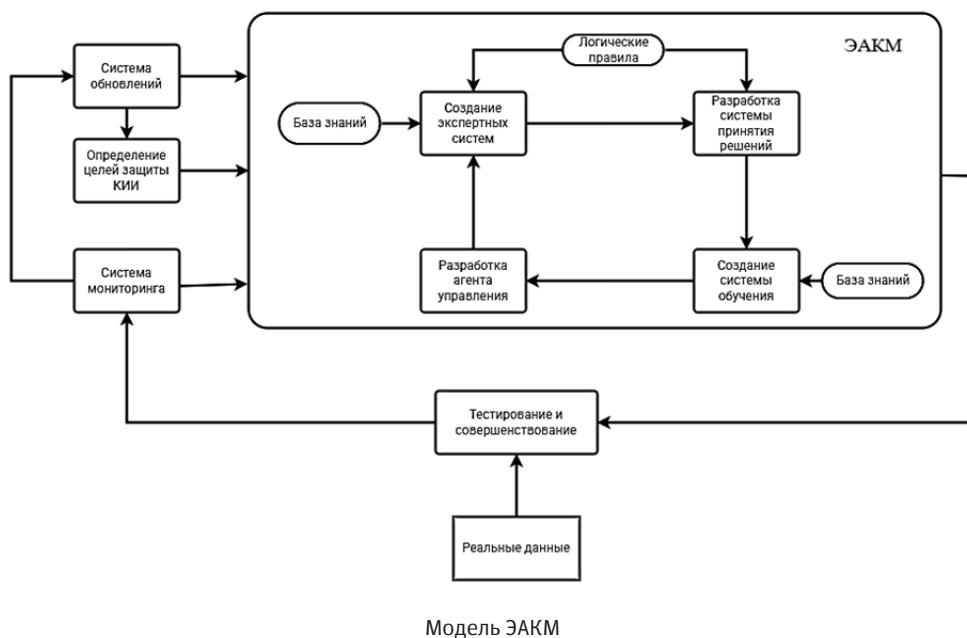
Агентная система будет обеспечивать защиту КИИ предприятия. Агенты будут отвечать за контроль доступа, мониторинг системы, обнаружение угроз и принятие мер по защите системы.

Методы машинного обучения будут использоваться для анализа данных и обнаружения новых угроз. Например, будет использоваться метод анализа аномалий, который позволяет обнаруживать необычное поведение в системе.

В результате модель предупреждения воздействия на КИИ предприятия машиностроения будет обладать следующими преимуществами:

- 1) адаптивность к изменяющейся среде;
- 2) учет всех возможных угроз и событий, включая новые;
- 3) эффективность в обнаружении угроз и принятии мер по защите системы;
- 4) быстрое реагирование на новые события и угрозы;
- 5) минимизация рисков воздействия на КИИ предприятия машиностроения.

Предложим алгоритм проектирования модели ЭАКМ для предприятия машиностроения (см. рисунок).



Модель ЭАКМ

Проектирование модели может включать следующие шаги:

1. *Определение целей защиты КИИ.* Первый шаг заключается в определении целей защиты КИИ предприятия машиностроения. Необходимо проанализировать типы КИИ и определить, какие угрозы и воздействия могут на них повлиять, а также какие уязвимости могут быть использованы для атак. Также необходимо определить, какие данные и системы КИИ являются наиболее критическими и нуждаются в особой защите.
2. *Создание экспертных систем.* Далее следует создание экспертных систем, которые будут использоваться для мониторинга и анализа КИИ. Экспертные системы могут быть созданы на основе баз знаний, логических правил и машинного обучения, чтобы автоматически анализировать данные, обнаруживать угрозы и выдавать предупреждения.
3. *Разработка системы принятия решений.* Система принятия решений может быть создана на основе логических правил, экспертных систем и ма-

шинного обучения. Она должна определять, какие меры необходимо принимать в ответ на обнаруженные угрозы и воздействия на КИИ.

4. Разработка агента управления. Агент управления должен быть способен управлять системами КИИ предприятия машиностроения, включая перезагрузку систем, изменение настроек и конфигураций, а также принятие других необходимых мер для устранения угроз и предотвращения воздействия на КИИ.

5. Создание системы обучения. Система обучения может быть создана на основе машинного обучения и экспертного подхода, включая сбор и анализ опыта и знаний специалистов в области безопасности КИИ. Она должна обеспечивать постоянное обновление и совершенствование экспертной системы, а также обучение системы принятия решений и агента управления.

6. Развёртывание и настройка модели. После создания всех компонентов модели, необходимо произвести ее развертывание и настройку. Это включает в себя настройку экспертных систем, системы принятия решений, агента управления и системы обучения, чтобы они работали вместе как единое целое. Также необходимо настроить систему мониторинга, которая будет следить за состоянием КИИ и автоматически уведомлять о возможных угрозах и воздействиях.

7. Тестирование и совершенствование. После настройки модели, необходимо провести тестирование ее работы на реальных данных и ситуациях. Тестирование поможет выявить слабые места и недостатки модели, которые могут быть исправлены и усовершенствованы. Необходимо также провести регулярное обновление модели, чтобы она была эффективной в долгосрочной перспективе.

Таким образом, модель ЭАКМ для предупреждения воздействия на критическую информационную инфраструктуру предприятия машиностроения может быть разработана и реализована в соответствии с конкретными потребностями и требованиями защиты КИИ. Она может включать в себя экспертные системы, систему принятия решений, агента управления, систему обучения и систему мониторинга, которые работают вместе для обеспечения надежной защиты КИИ от угроз и воздействий.

Машинное обучение. Использование методов машинного обучения в данной модели позволяет улучшить эффективность и точность предупреждения возможных атак на критическую информационную инфраструктуру (КИИ) предприятия машиностроения. Применение алгоритмов машинного обучения в этой модели позволяет проанализировать различные характеристики КИИ и выявить потенциальные уязвимости, которые могут быть использованы злоумышленниками для атаки.

Для обучения модели необходимо собрать и подготовить данные, включающие информацию о состоянии и уязвимостях КИИ, а также о предшествующих атаках и инцидентах безопасности. Набор данных должен быть достаточно большим и разнообразным, чтобы обеспечить достаточную точность модели.

Затем необходимо выбрать наиболее релевантные признаки КИИ, которые будут использоваться для обучения модели. Это могут быть, например, данные о состоянии сети, системе контроля доступа, защите от вредоносных программ и т. д.

После выбора признаков необходимо обучить модель на основе этих данных. В данной модели могут быть использованы различные алгоритмы машинного обучения, такие как логистическая регрессия, деревья решений, нейронные сети и другие. В процессе обучения модели параметры алгоритма настраиваются для достижения наилучшей производительности.

После обучения модели на основе набора данных можно оценить ее эффективность и точность на тестовом наборе данных. При необходимости можно настроить параметры модели для улучшения ее производительности.

Для использования модели в режиме реального времени необходимо ее интегрировать в систему мониторинга КИИ. В случае обнаружения потенциальной угрозы модель может автоматически предупредить ответственных за безопасность сотрудников о необходимости принятия соответствующих мер.

В качестве входных данных для модели могут использоваться различные характеристики системы КИИ, такие как количество подключений к сети, частота обновления системных файлов, типы источников входящих пакетов данных и т. д.

В процессе обучения модель будет становиться все точнее и точнее в предсказании возможных угроз критической информационной инфраструктуре. После успешного завершения этапа обучения, модель будет готова к использованию для анализа входящих данных.

При получении новых данных, модель будет использовать свои знания и предыдущий опыт для анализа новой информации и определения угроз. Если модель обнаружит потенциальную угрозу, она может быстро принять соответствующие меры, например, отправить уведомление ответственным сотрудникам о том, что необходимо принять меры для защиты системы.

Таким образом, использование машинного обучения в данной модели позволяет значительно повысить эффективность и точность в определении возможных угроз критической информационной инфраструктуре предприятия машиностроения.

Нейронная сеть. Нейронной сети для ЭАКМ КИИ имеет следующую архитектуру:

1. Слой входных данных: принимает входные данные, представляющие собой характеристики атаки на критическую информационную инфраструктуру. Размерность входного слоя будет зависеть от числа характеристик.

2. Скрытые слои: могут состоять из нескольких слоев, каждый из которых имеет несколько нейронов. Каждый нейрон в скрытом слое обрабатывает информацию, полученную от предыдущего слоя, с использованием весов, которые должны быть оптимизированы в процессе обучения. Для каждого слоя может использоваться функция активации, такая как ReLU или Sigmoid.

3. Выходной слой: производит классификацию атак на критическую информационную инфраструктуру на два класса — угрозы и не угрозы. В качестве функции активации выходного слоя можно использовать сигмоиду, которая преобразует выходные данные в диапазоне от 0 до 1.

4. Функция потерь: для обучения нейронной сети используется функция потерь, которая оценивает разницу между предсказанными и фактическими значениями. В данной модели можно использовать бинарную кросс-энтропию в качестве функции потерь.

5. Алгоритм оптимизации: для обучения нейронной сети можно использовать стохастический градиентный спуск (SGD) с моментом, который помогает ускорить сходимость.

6. Метрики оценки производительности: для оценки производительности нейронной сети можно использовать различные метрики, такие как точность (accuracy), полноту (recall), точность предсказания (precision) и F1-меру.

Нейронная сеть может быть обучена на большом наборе данных, содержащем различные типы атак на критическую информационную инфраструктуру. После обучения, нейронная сеть может использоваться для классификации новых данных и выявления угроз для критической информационной инфраструктуры.

Заключение. В данной статье была рассмотрена методология экспертно-агентного когнитивного моделирования предупреждения воздействия на критическую информационную инфраструктуру. Были проанализированы существующие модели, выявлены их недостатки и предложена новая модель, основанная на использовании машинного обучения и нейронных сетей.

Результаты моделирования показали, что предложенная модель может эффективно предупреждать воздействие на критическую информационную инфраструктуру и повышать устойчивость предприятий машиностроения к кибератакам.

Однако необходимо отметить, что внедрение данной модели требует значительных затрат на разработку и обучение нейронной сети, а также на подготовку и сбор данных. Тем не менее, в долгосрочной перспективе это может оказаться выгодным вложением, так как защита критической информационной инфраструктуры предприятия машиностроения является критически важной задачей.

Таким образом, экспертно-агентное когнитивное моделирование, основанное на использовании машинного обучения и нейронных сетей, представляет собой мощный инструмент для повышения устойчивости кибербезопасности предприятий и защиты критической информационной инфраструктуры.

Литература

- [1] Кондратенко Ю.В., Сидорова Н.А. Моделирование угроз кибербезопасности критических информационных инфраструктур // Моделирование и анализ информационных систем. 2019. Т. 26, № 4. С. 483–491.

- [2] Николаев Е.И., Муханов А.Н. Использование методов машинного обучения в задачах обнаружения атак на компьютерные сети // Компьютерные исследования и моделирование. 2018. Т. 10, № 3. С. 353–367.
- [3] Лавринович В.А., Кузнецов А.С. Экспертно-агентное когнитивное моделирование информационной безопасности // Информационная безопасность. 2017. Т. 3. С. 19–24.
- [4] Беляева О.Н., Степанова Е.В. Нейронные сети в задачах прогнозирования и классификации // Научно-технические ведомости Санкт-Петербургского государственного политехнического университета. 2018. Т. 3, № 275. С. 144–148.
- [5] Цибизова Т.Ю., Слепцова К.А. Автоматизированная система учета данных внутрикорпоративной сети управления информацией // Современные проблемы науки и образования. 2015. № 1-1. С. 429.
- [6] Зотов С.В., Лысенко М.А., Некрасов И.В. Методы анализа данных в задачах обнаружения вторжений // Информатика и ее применения. 2019. Т. 13, № 2. С. 17–27.
- [7] Пролетарский А.В., Скворцова М.А., Терехов В.И. Гибридная интеллектуальная система оценки рисков на основе неструктурированной информации // Нейрокомпьютеры: разработка, применение. 2017. № 1. С. 66–74.
- [8] Суханов В.А., Цибизова Т.Ю. Архитектура системы развития и поддержки профессиональной интеллектуальной деятельности // Динамика сложных систем — XXI век. 2020. Т. 14, № 1. С. 23–31.
- [9] Панилов П.А., Иванов А.М. Агентная имитационная модель и онтология финансового взаимодействия физических и юридических лиц с банками на примере банк-клиента // Молодежный научно-технический вестник. 2012. № 5. С. 39.

Methodology of Expert-Agent Cognitive Modeling for Preventing Impact on Critical Information Infrastructure

© Panilov P.A.
Tsibizova T.Yu.
Voskresensky G.A.

panilovp.a@bmstu.ru
mumc@bmstu.ru
georgii.voskresenskii@gmail.com

BMSTU, Moscow, 105005, Russia

This article discusses the methodology of expert-agent cognitive modeling to prevent the impact on the critical information infrastructure of a mechanical engineering enterprise. Existing models and their shortcomings were considered, and an improved model was proposed, which includes elements of efficiency analysis, automatic tuning, machine learning, artificial intelligence algorithms, forecasting and real-time data analysis. Such improvements will help improve the efficiency of the model and ensure the protection of the critical information infrastructure of a mechanical engineering enterprise from possible threats and impacts.

Keywords: expert-agent cognitive modeling, critical information infrastructure, cybersecurity, attack scenarios, impact prevention recommendations, multi-objective optimization

УДК 004.89

Применение алгоритмов искусственного интеллекта и нейросетевого моделирования технических систем в научно-исследовательской работе студентов

© | Панфилова Екатерина Вадимовна

panfilova.e.v@bmstu.ru

МГТУ им. Н.Э. Баумана, Москва, 105005, Россия

Представлен опыт применения алгоритмов искусственного интеллекта в научно-исследовательской работе студентов. Научная работа является обязательной частью обучения на кафедре «Электронных технологий в машиностроении» Московского государственного технического университета им. Н. Э. Баумана. Для инженеров и специалистов в области нанотехнологий нейронные сети стали мощным инструментом научных исследований. Модели нейронных сетей успешно используются в студенческих научных и исследовательских проектах и представлены в дипломных работах выпускников кафедры по направлениям подготовки «Электроника и наноэлектроника» и «Наноинженерия». В статье представлены примеры того, как нейронные сети используются в студенческих проектах и выпускных квалификационных работах.

Ключевые слова: нанотехнологии, нейросетевое моделирование, алгоритмы искусственного интеллекта, научно-исследовательская работа студентов

Введение. Прикладные инженерные задачи, возникающие при разработке и исследовании современных технических систем, могут быть успешно решены с помощью алгоритмов искусственного интеллекта. Нейронные сети могут использоваться в управлении технологическими процессами, промышленных роботах, системах распознавания изображения - машинном зрении, идентификации сигналов различной природы, интерфейсах взаимодействия для интернета вещей и т. п. Их несомненным достоинством является способность к принятию решений — обобщению, а также возможность использования данных с частично пропущенной информацией, способность бороться с «шумами» и простота в использовании [1–3]. Применение нейронных сетей в области нанотехнологий более чем обосновано. Высокотехнологичные процессы характеризуются большим количеством стохастически связанных факторов, природа которых различна, многие задачи трудно формализуемы. В этом случае на помощь приходят нейросетевые алгоритмы.

В данной работе представлен опыт использования нейронных сетей в научно-исследовательских работах магистрантов, обучающихся по направлениям подготовки «Электроника и наноэлектроника» и «Наноинженерия» в МГТУ им. Н.Э.Баумана.

Задачи и методы их решения. Реализация студентами решений, использующих алгоритмы искусственного интеллекта, стала возможна благодаря наличию в программах магистерской подготовки по названным направлени-

ям трех дисциплин: «Научно-исследовательская работа» (НИР), «Анализ и синтез технических решений» (АиСТР) и «Нейросетевое моделирование сложных технических систем» (НСМСТС).

Первые две дисциплины составляют так называемый индивидуальный лабораторный практикум. Каждый студент один-два дня в неделю в течение нескольких семестров под руководством своего научного руководителя осваивает работу на современном технологическом и аналитическом оборудовании и самостоятельно выполняет инженерные работы. В рамках выполнения заданий в каждом семестре студент имеет возможность проявить себя как конструктор, исследователь, технолог или разработчик в зависимости от тематики и направления работы научной группы, которую он выбрал. В результате к завершению магистратуры студенты накапливают определенный объем данных, требующий обработки. Это обуславливает актуальность появления дисциплины НСМСТС в программе магистерской подготовки. Причем, более чем десятилетний опыт ее преподавания показывает, что, если учащемуся будет предоставлена возможность моделирования «знакомой» по инженерной деятельности системы, эффективность и обучения студента, и создаваемой им нейронной сети будет выше. Поэтому курс имеет практический характер и напрямую связан с научно-исследовательской работой студентов.

По окончании курса студенты выполняют домашнее задание. В нем каждый из студентов создает нейросетевую модель объекта, соответствующего теме его научно-исследовательской работы — процесса, оборудования, изделия. Естественно предположить, что структура модели определяется решаемой ею задачей. В настоящее время существует большое количество разнообразных архитектур. Поскольку объемы данных постоянно увеличиваются, вычислительные мощности растут, все более востребованными становятся глубокие, содержащие больше двух промежуточных или скрытых слоев, нейросети. Однако, далеко не всегда они необходимы для решения текущей задачи. Более того, сеть со структурой, превосходящей по сложности анализируемое явление, будет использовать избыточные ресурсы на запоминание признаков, не имеющих значения для достижения стоящей перед нейросетью цели. На практике в прикладных инженерных исследованиях элементарные сети с одним-двумя скрытыми слоями обычно проявляют себя гораздо лучше, чем глубокие и сложно устроенные. Как правило, именно такие модели и используют магистранты.

Результаты. Пояснительная записка к домашнему заданию является, по сути, отчетом о выполненном инженерном исследовании. Она включает введение, описание моделируемой системы, описание процесса моделирования и полученных моделей, представление результатов моделирования и работы нейросетей с неизвестными данными, обсуждение результатов и заключение. Описание моделируемой системы содержит представление процесса, оборудования или изделия, анализ свойственных им входных и выходных параметров и представление набора обучающих данных. Посвященная именно моделированию проектная часть отчета включает в себя обоснование вы-

бора используемых в модели входных факторов и выходных параметров, анализ пригодных для решения задачи типов нейронных сетей и выбор их параметров, представляет алгоритмы обучения. Чтобы закрепить полученные знания и развить приобретаемые навыки, при выполнении исследования в рамках домашнего задания студенты должны использовать несколько типов нейронных сетей и применить как минимум два алгоритма обучения. На практике в прикладных технических исследованиях элементарные сети с одним-двумя скрытыми слоями обычно проявляют себя гораздо лучше, чем глубокие и сложно устроенные. В части представления результатов моделирования приводятся статистики обучения, контроля и тестирования нейронных сетей, анализируются графики процесса обучения и описываются результаты работы с неизвестными данными. В разделе, посвященном обсуждению результатов, анализируются полученные модели, выявляются наиболее пригодные из них числа для использования в рассматриваемой задаче. В заключении формулируются выводы и даются рекомендации относительно использования полученных моделей и их дальнейшего совершенствования при необходимости. На рис. 1–3 показаны некоторые решения, представленные студентами в отчетах.

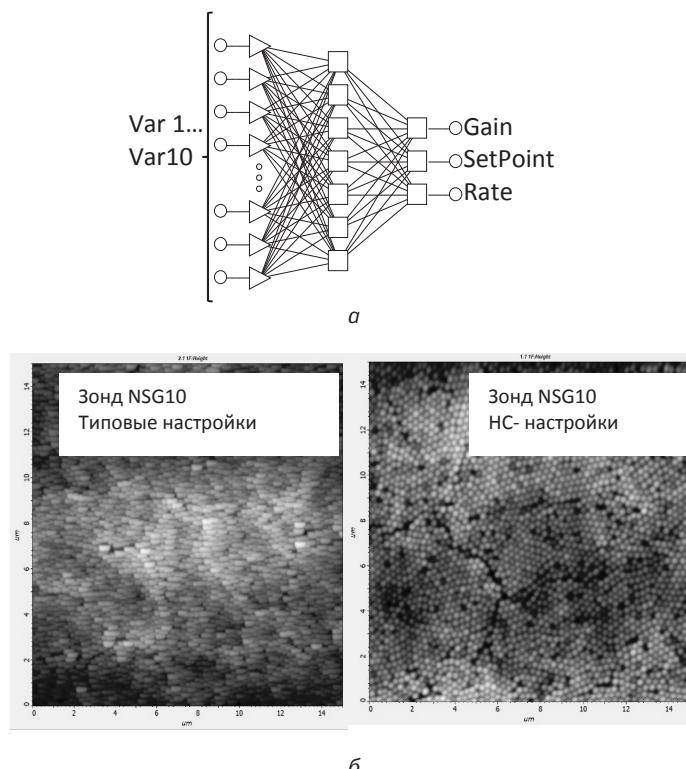
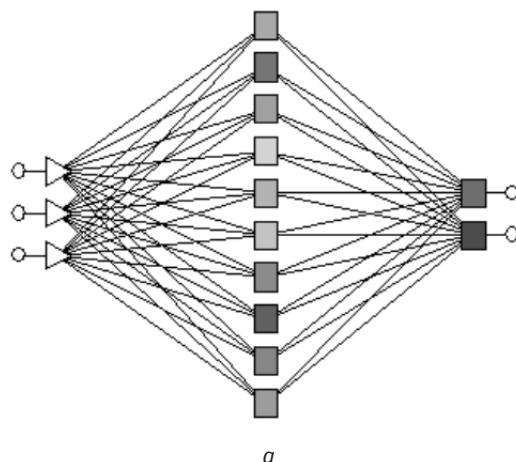


Рис. 1. Пример решения задачи настройки параметров сканирования для атомно-силового микроскопа: используемая искусственная нейронная сеть (а), результаты сканирования (б)

*a*

Напряжение (Вход), Время (Вход), Толщина (Выход)
[34.MLP 3-10-2]

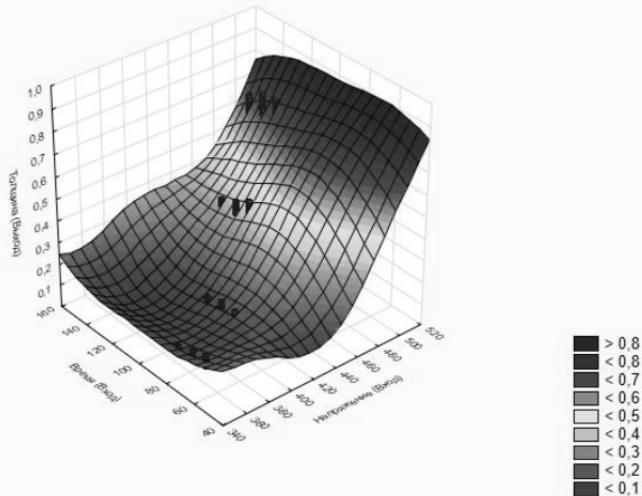
*b*

Рис. 2. Пример решения задачи выбора параметров магнетронного осаждения тонких пленок заданной толщины: используемая искусственная нейронная сеть (*a*), поверхность отклика, получаемая при использовании в качестве модели многослойного персептрона и точки из тестового множества (*b*)

Таким образом, пояснительная записка к выполненному домашнему заданию является законченной исследовательской работой, и поэтому результаты, полученные в процессе моделирования, широко используются в отчетах о научно-исследовательской работе студентов и выпускных квалификационных работах магистров, а также публикуются в научно-технических изданиях [4, 5].

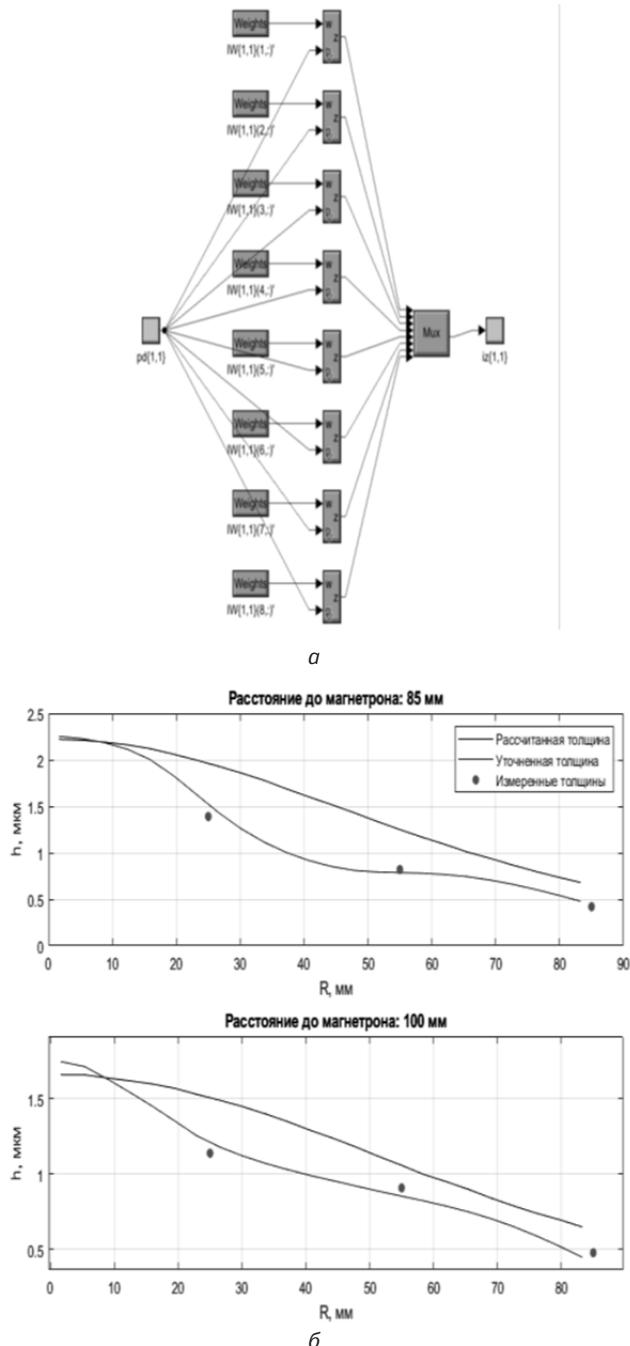


Рис. 3. Пример решения задачи определения толщины покрытия, осаждаемого на поверхность сложной конфигурации: структура используемой искусственной нейронной сети (а); сопоставление рассчитанных, уточненных с помощью нейросетевой модели и полученных в результате проведения эксперимента значений (б)

Заключение. Успешность выпускников технических вузов зависит, в том числе, от умения использовать современные методы и инструменты исследований, в частности алгоритмы искусственного интеллекта. Благодаря применению методов нейросетевого моделирования при выполнении научно-исследовательской работы, студенты кафедры «Электронные технологии в машиностроении» МГТУ им. Н.Э. Баумана на практике понимают, что нейронные сети — это не только перспективный и мощный, но и доступный инструмент современных научных исследований. Практика показывает, что такой междисциплинарный подход позволяет не только обучить будущих специалистов в области нанотехнологии нейросетевому моделированию, но и развить навыки инженерной деятельности в целом.

Литература

- [1] Abiodun O.I. et al. State-of-the-art in artificial neural network applications: A survey // Heliyon. 2018. Vol. 4, no. 11. Art. e00938.
- [2] Dimitrienko Yu.I., Gubareva E.A. Neural network model of mathematical knowledge and development of information and educational environment for mathematical training of engineers // Journal of Physics: Conference Series. IOP Publishing. 2018. Vol. 1141, no. 1. Art. 012010.
- [3] Plotnikov V.A. et al. Classical and neural network approaches to object detection in underwater robotics competitions // AIP Conference Proceedings. AIP Publishing LLC. 2022. Vol. 2383, no. 1. Art. 020021.
- [4] Panfilova E.V., Sidorova S.V., Shramko D.Yu. Application of neural network for forecasting reliability of vacuum equipment // International Russian Automation Conference (RusAutoCon). IEEE. 2019. Pp. 1–5.
- [5] Panfilova E.V., Ibragimov A.R., Mozer K.V. Neural network module for tuning an atomic force microscope in the study of photonic crystal films // Journal of Physics: Conference Series. IOP Publishing. 2020. Vol. 1571, no. 1. Art. 012004.

Application of Artificial Intelligence Algorithms and Neural Network Modeling of Technical Systems in Student Research Work

© | Panfilova E.V.

panfilova.e.v@bmstu.ru

BMSTU, Moscow, 105005, Russia

The paper presents the experience of using artificial intelligence algorithms in the research work of students. Scientific work is an obligatory part of education at the Department of Electronic Technologies in Mechanical Engineering, Bauman Moscow State Technical University. For engineers and specialists in the field of nanotechnology, neural networks began to unite scientific research. Neural network models are successfully used in student scientific and research projects and are presented in diploma theses of higher educational institutions in the areas of training “Electronics and nanoelectronics” and “Nanoengineering”. It is shown how neural networks are used in student projects and final theses.

Keywords: nanotechnologies, neural network modeling, artificial intelligence algorithms, student research work

УДК 681.586

Онтологическое моделирование предметной области как средство повышения эффективности усвоения инженерных дисциплин

© | Цветков Юрий Борисович

tsvetkov@bmstu.ru

МГТУ им. Н.Э. Баумана, Москва, 105005, Россия

Приведены результаты эксперимента по онтологическому моделированию предметной области инженерной дисциплины параллельно с ее освоением. Этапы работы включали формирование глоссария, концептуальной карты, а затем и онтологии на основе редактора Protégé. Показано, что такая работа позволяет активизировать усвоение учебного материала, реализовать в полной мере систему учебных целей в комплексе от простого к сложному: помнить, понимать, применять, анализировать, оценивать, создавать. Проработка глоссария обеспечила не только уверенное запоминание этой информации, но расширение и углубление представления об основных концептах изучаемой предметной области. Коллaborация при разработке онтологии, совместная разработка критериев оценки их качества, взаимное анонимное рецензирование обеспечили приобретение всеми студентами начальных навыков онтологического моделирования, способствовали формированию универсальных, надпредметных компетенций параллельно с освоением инженерной дисциплины и на ее основе.

Ключевые слова: концепты, концептуальная карта, глоссарий, классы, индивиды, логические связи, онтология, таксономия, универсальные компетенции

Введение. Развитие современной экономики определяется уровнем критических технологий, для которых характерен предельно высокий уровень требований к их качеству и эффективности. Поэтому наряду с термином «критические технологии» употребляют такие понятия, как высокие или научные технологии.

Изучение и практическое освоение таких технологий сопряжено с усвоением большого и постоянно расширяющегося объема научно-технической информации. При этом важным является повышение эффективности превращения информации во время обучения в знания, а затем — их применение при решении практических инженерных задач. Не менее важно повышение уровня познавательной деятельности студентов, формирование критического и творческого мышления.

Проработка учебного материала курса «Процессы и оборудование микротехнологии» [1] послужила основой для апробации одной из прорывных педагогических технологий, основанной на онтологическом моделировании изучаемой предметной области.

Цель данной статьи — рассмотрение особенностей и результатов практического применения этой технологии для активизации учебного процесса и повышения его эффективности.

Онтологии в учебном процессе. Комплекс математических, естественнонаучных, общетехнических и специальных дисциплин, изучаемых студентами в инженерных образовательных программах, ставит перед ними сложную проблему их освоения за отведенное время на заданном уровне.

Для облегчения решения этой проблемы все чаще применяют представление изучаемых предметных областей в виде их концептуальных моделей -- онтологий.

Онтологию можно определить как это формальную спецификацию основных концептов предметной области [2]:

$$O = \{C, R, A\},$$

где O — онтология; C — совокупность концептов предметной области; R — совокупность отношений между ними; A — набор аксиом (законов и правил, которые описывают законы и принципы существования концептов).

Построение онтологии предметной области обеспечивает организацию и структурирование соответствующей информации, облегчает восприятие ее как человеком, так и компьютером. Важной особенностью онтологий является расширение возможностей поиска нужной информации. Традиционные системы поиска по ключевым словам выдают либо малый, либо слишком большой результат. Онтологии позволяют получать информацию, семантически связанную с формой запроса, уточнять или обобщать запрос.

Все эти возможности онтологического моделирования широко используются в учебном процессе. Прежде всего, они применяются для формирования содержания учебных курсов, как для очного [3], так и электронного [4] обучения. Кроме того, как показано в развернутом обзоре [5], онтологии могут использоваться для установления отношений между учебными элементами [6], уточнения значения терминов [7], объединения учебной информации из нескольких открытых источников [8], точного описания и анализа учебной программы [9], формирования интеллектуальных баз знаний [10].

Анализ работ в этой области показывает безусловную важность и полезность применения онтологий в учебном процессе. При этом выявляется интересная особенность. В большинстве рассмотренных работ преподаватель выступает экспертом, носителем знаний о предметной области, а студент — потребителем этих знаний.

Важно отметить, что образовательные стандарты высшего профессионального образования предписывают освоение компетенций, относящихся к способам работы с информацией, включая поиск, извлечение и систематизацию информации, ее структурирование, обработку, анализ, синтез, обобщение и критическую оценку.

В общем плане это должно способствовать повышению уровня познавательной деятельности студентов, формированию критического и творческого мышления. При этом специалисты в области использования онтологии в качестве инструмента познания подчеркивают, что «при создании базы знаний именно эксперт вместе с инженером по знаниям получают наиболее полное

представление о предметной области, в то время как пользователи этой базы или системы получат «сухие выжимки», готовые факты без всего многообразия связей и путей их получения» [4]. Вывод из этого суждения — «лучший путь обучения — самому попытаться изложить (изобразить) материал предметной области таким образом, чтобы другие смогли получить о нем представление».

И наконец, самое важное: «Стоит еще раз подчеркнуть, что онтология не есть самоцель. В процессе построения, то есть при взаимодействии семантических связей нашей памяти с визуальной информацией, связи перестраиваются, порождая в свою очередь новые знания». Опыт показывает, что онтологическое моделирование студентами изучаемой предметной области ускоряет процесс усвоения новой учебной информации, причем уровень усвоения может быть проконтролирован также с помощью онтологий.

Для оценки применимости онтологий в качестве обучающего, дидактического средства был спланирован и проведен эксперимент по параллельному освоению инженерной дисциплины и ее онтологическому представлению. На первом этапе в качестве исходного источника информации использовалось подготовленное учебное пособие, на втором — поиск дополнительной информации и ее обработка.

Методика создания онтологии изучаемой предметной области. Процедура создания онтологии студентами напрямую соотносится с этапами изучения новой информации. При начальном ознакомлении с материалами курса формируются первичные знания о предметной области, они, как правило, поверхностны и хаотичны, не дают целостного представления об объекте изучения.

Выделение в изучаемой предметной области основных терминов и определений, их расширение и уточнение, при необходимости — визуализация, позволяют сформировать глоссарий терминов (рис. 1).

Таким образом, результатом первого этапа является набор структурных единиц изучаемой предметной области на основе выделенных терминов, называемых концептами (атрибутами).

При этом многократная углубленная проработка информации обеспечивает надежное понимание и запоминание ключевых положений.

Далее следует этап анализа, систематизации концептов и создания смысловых (семантических) связей между ним. Для этого концепты группируются в классы, выделяются их общие признаки, что обеспечивает возможность включения полученных классов в единую систематизированную базу знаний.

Проведенные анализ и систематизация информации позволяют представить ее в виде онтологии. Для этого использован свободно распространяемый, открытый редактор онтологий Protege.

Protege позволяет представить систему классов концептов, связи между ними, обеспечить анализ возможных логических противоречий, провести визуализацию полученного результата (рис. 2).

физическим и геометрическим параметрам которых предъявляются особые, часто беспредельные в технике требования.

Нанесение физических слоев реализует методы ионного ионизированного облучения, вакуумной конденсации, вспышек, атомарных и молекулярных потоков и срез создает на поверхности подложки полупроводниковые, проводящие и диэлектрические слои толщиной от нескольких нанометров до единиц микрометров. Наиболее распространены методы нанесения тонких слоев с минимальным напряжением (*ultralow voltage deposition — PVD*) и термической обработкой.

После нанесения физики (*microlithography*), которая поза гору. Для этого на поверхность пластины нанесены слои изолирующих, проводящих и диэлектрических слоев толщиной от нескольких нанометров до единиц микрометров. Наиболее распространены методы нанесения тонких слоев с минимальным напряжением (*ultralow voltage deposition — PVD*) и термической обработкой.

Микрообработка (*microlithography*) на заготовке: нанесение матрицы и ее травление. При этом для очистки заготовки от остатков предыдущих методов микрообрабатка все используются методы эпизон лазера, химическое осаждение ракемика.

Локальное легирование в смеси или ионное легирование.

Локальное травление (и жаждущее) производится в соединении с трековым.

Важной особенностью микроборки (рис. В1, 6; В2, б в Е) является формирование мыльницы в эпизоне лазера, химическое осаждение из смеси ионного легирования.

Возможность операции огромного числа элементов структуры оказалась революционной.

Микроскопия (*amplification*) и определение в изображении или в корпусе (*die placement*) для с внешними выводами (*wire bond*).

Краткое рассмотрение оси для ее реализации, используя

Далее следует процесс затирки формирования субстратного легирования ограниченной поляризации в мелких канавках. Как поликремниевый



Рис. 1.6. Области истока, стока и затвора

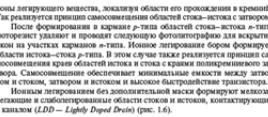


Рис. 1.6. Области истока, стока и затвора

зоны легированного вещества, лежащие в области его проекции в кремниевом. Так реализуется принцип самосовмещения областей стока–истока с затвором. После формирования и кремниевого – типа областей стока–истока и – типа фоторезиста, в дальнейшем для выделения областей истока–стока–затвора для выделения областей истока–стока–затвора. Ионное легирование бором формирует области истока–стока–затвора. В этом случае также реализуется принцип самосовмещения областей стока–истока с затвором. Самосовмещение обеспечивает минимальные ёмкости между затвором и стоком, затвором и истоком и высокое быстродействие транзистора.

Самосовмещение обеспечивает минимальные ёмкости между затвором и стоком, затвором и истоком и высокое быстродействие транзистора.

Формирование сферы и глубокое легирование

При формировании КМОП-структур применяют сферы – практические разделятели, играющие роль самосовмещения маски при имплантации ионов в области истока и стока.

Сформированная сфера покрывает слой Si₃N₄ (рис. 1.7), который затем подвергнут плазменному ионнотропному травлению с остановкой на слое SiO₂. При этом Si₃N₄ удаляется преимущественно с горизонтальных поверхностей и остается на вертикальных стенах затвора.

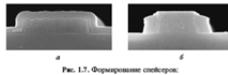


Рис. 1.7. Формирование сферы.

а – исходный слой Si₃N₄ б – ионным легированием

а

б

- **Интенсивность излучения (I)** – энергия светового потока, падающего на поверхность фотодиода в единицу времени (мВт/см²).

- **Экспозиция (E)** – доза актиничной световой энергии, воздействующая на слой фотодиода в процессе экспонирования: $E=It$ (мДж/см²). Заметим, что 1 мВт·1с=1 мДж.

- **Пороговая экспозиция (E₀)** – минимальная доза световой энергии, вызывающая изменение свойств пленки фотодиода на всю толщину.

- **(S = $\frac{1}{E} = \frac{1}{I \times t}$)**
- **Чувствительность фотодиода** – способность реагировать на излучение, определяется как величина, обратная дозе излучения, необходимой для проявления слоя определенной толщины.

Ингибитор – вещество, препятствующее растворению не экспонированного фотодиода, при добавлении ее в базовый полимер (до 20-30% от веса фотодиода) уменьшает скорость проявления не экспонированной пленки фотодиода. В качестве ингибитора чаще всего используют **нафтохинондизаид (НХД)**.

Процесс формирования изображения в фотодиоде целесообразно разделить на два этапа:

- **Экспонирование** – это оптический процесс, который вызывает в фотодиоде необратимые химические видоизменения, в частности, для позитивного резиста – разрушение светочувствительной составляющей (ингибитора)
- **Проявление** – это процесс поверхностного растворения, при котором происходит удаление фотодиода со скоростью, зависящей от степени разрушения ингибитора.

б

Рис. 1. Формирование глоссария изучаемой предметной области:
а – текст учебного пособия; б – глоссарий выделенных терминов (концептов)

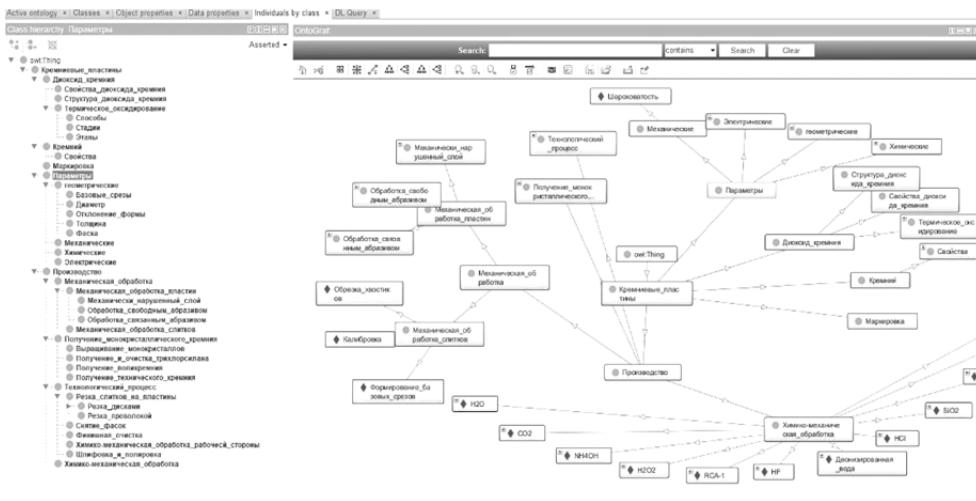


Рис. 2. Визуализация полученных результатов

Важным достоинством редактора Protégé является возможность реализации сложных по структуре запросов, что обеспечивает выявление востребованных концептов.

Работу по созданию онтологий студенты вели небольшими (до трех человек) группами, что способствовало сотрудничеству и взаимодействию, формированию партнерских отношений. Работа по созданию онтологий проводилась итерационно. Студенты анализировали начальные версии онтологий, искали и настраивали связи между объектами, соотносили понятия между собой, а также выделяли новые, более точные классы из ранее созданных. Информация представлялась триплетами, которые были структурированы и связаны между собой, при этом происходило дополнительное запоминание и усвоение материала предметной области.

При оценке качества онтологий, разработанных разными подгруппами, проводился их анонимный анализ, сравнение и рейтингование всеми студентами. Знакомство с работами своих товарищей, их сравнение и оценивание помогало не только расширить представления о предметной области, но и выявить наиболее интересные подходы при ее структурировании.

Результатом этой работы явилось участие каждого студента в создании новых, ранее не существовавших информационных объектов — онтологий.

Оценка эффективности применения онтологического моделирования. Анализ результатов эксперимента по использованию онтологического представления изучаемого учебного материала позволяет констатировать следующее.

Прежде всего, активизировался процесс усвоения новой учебной информации: понятий, определений, терминов. Проработка глоссария обеспечила не только уверенное запоминание этой информации, но и расширение

и углубление представления об основных концептах изучаемой предметной области.

Разработанный глоссарий был использован в качестве основы для формирования онтологии. Применение для этого повсеместно распространенного редактора онтологий Protege обеспечило не просто знакомство с ним, но и уверенное освоение.

Разработка онтологий небольшими подгруппами, совместная деятельность для достижения общих целей предусматривала обмен мнениями, обсуждение, достижение согласия. Эта форма сотрудничества сейчас часто называется термином коллаборация.

Для анализа и сравнительной оценки качества формируемых онтологий были разработаны критерии, по которым проводилась взаимное анонимное рейтингование выполненных работ. Дальнейшее обсуждение результатов, обеспечили, по сути — обмен опытом, приобретение всеми студентами увереных навыков онтологического моделирования.

Заключение. Онтология в образовательном процессе является одной из эффективных форм представления знаний, средством адаптации учебного процесса к росту объемов информации и необходимости их структуризации и формализации.

Разработка онтологий параллельно с освоением учебной научно-технической информации позволяет обобщать и систематизировать информацию, группировать информацию, распределенную по различным хранилищам, базам данных и знаний, использовать автоматизированный логический вывод для обеспечения поиска, получения новых знаний и анализа информации.

Этапы создания онтологий обеспечивают углубленную проработку и расширение изучаемой информации, по сути, в полной мере реализуют таксономию Блума — систему учебных целей в комплексе от простого к сложному: помнить, понимать, применять, анализировать, оценивать. Этапы создания и оценивания онтологий прививают навыки коллективной работы, анализа и оценки результатов.

Проведенный эксперимент дает основание для рекомендации внедрения онтологического моделирования в образовательный процесс при изучении инженерных дисциплин.

Литература

- [1] Цветков Ю.Б. Процессы и оборудование микротехнологии. М.: Изд-во МГТУ им. Н.Э. Баумана, 2018.
- [2] Gruber T.R. A Translation Approach to Portable Ontology Specifications // Knowledge Acquisition. 1993. No. 5/2. Pp. 199–220.
- [3] Еремин Е.А. Онтологии как средство представления учебного материала // Вестник Пермского ГГПУ. Информационные компьютерные технологии в образовании. 2007. № 3. С. 23–36.
- [4] Sosnovsky S., Gavrilova T. Development of educational ontology for C-programming // International Journal “Information Theories & Applications”. 2006. Vol. 13.

-
- [5] Stancin K., Poscic P., Jaksic D. Ontologies in education—state of the art // Education and Information Technologies. 2020. Vol. 25 (6). Pp. 5301–5320.
 - [6] Wang Y., Wang Z., Hu X., Bai T., Yang S., Huang L. A courses ontology system for computer science education // IEEE International Conference on Computer Science and Educational Informatization (CSEI). 2019, August. Pp. 251–254.
 - [7] Mosharraf M., Taghiyareh F. Automatic syllabus-oriented remixing of open educational resources using agent-based modeling // IEEE transactions on learning technologies. 2019. Vol. 13 (2). Pp. 297–311.
 - [8] Nahhas S., Bamasag O., Khemakhem M., Bajnaid N. Leveraging linked data to propel competency-based education based on labour skills // 2-nd International Conference on Computer Applications & Information Security (ICCAIS). 2019, May. Pp. 1–6.
 - [9] Piedra N., Caro E.T. LOD-CS2013: Multilearning through a semantic representation of IEEE computer science curricula // IEEE Global Engineering Education Conference (EDUCON). 2018, April. Pp. 1939–1948.
 - [10] Samia Z., Khaled R., Warda Z. Multi-agent systems and ontology for supporting management system in smart school // 3-rd International Conference on Pattern Analysis and Intelligent Systems (PAIS). 2018, October. Pp. 1–8.

Ontological Domain Modeling as a Means of Increasing the Efficiency of Mastering Engineering Disciplines

© | Tsvetkov Yu.B.

tsvetkov@bmstu.ru annotation

BMSTU, Moscow, 105005, Russia

The results of the experiment on ontological modeling of the subject area of the engineering discipline are presented in parallel with its development. The stages of work included the formation of a glossary, a conceptual map, and then an ontology based on the Protégé editor. It is shown that such work allows you to activate the assimilation of educational material, to fully implement the system of educational goals in a complex from simple to complex: remember, understand, apply, analyze, evaluate, create. The development of the glossary provided not only a confident memorization of this information, but also an expansion and deepening of the understanding of the main concepts of the studied subject area. Collaboration in the development of ontology, joint development of criteria for assessing their quality, mutual anonymous review ensured that all students acquire the initial skills of ontological modeling, contributed to the formation of universal, over-subject competencies in parallel with the development of engineering discipline and on its basis.

Keywords: concepts, conceptual map, glossary, classes, individuals, logical connections, ontology, taxonomy, universal competencies

Искусственный интеллект: от науки к инфраструктуре и практике

УУДК 004.8

Применение сверточных сетей архитектуры *yolo* для подсчета свободных парковочных мест на произвольной парковке

© Алешина Анна Евгеньевна^{1,2}
Королев Павел Александрович²
Доррер Михаил Георгиевич¹

dumooroo@gmail.com
kuronikushini@gmail.com
mdorrer@mail.ru

¹ Сибирский государственный университет науки и технологий имени М.Ф. Решетнева, Красноярск, 660037, Россия

² Сибирский федеральный университет, Красноярск, Россия

Описано решение задачи автоматической фиксации наличия свободных парковочных мест на стоянках на основании видеопотока камеры наблюдения. Задача решалась с применением комбинации модели YOLOv7 для детекции интересующих объектов типа «автомобиль», обученной на специально созданной обучающей выборке и группировке объектов с помощью алгоритма *k*-средних. Предложенное решение показало удовлетворительную точность и пригодность для практического применения в условиях существенных оптических помех — суточных перепадов освещенности и наличия осадков для подсчета свободных парковочных мест моделью без ее переобучения под различные парковки.

Ключевые слова: мониторинг парковок, компьютерное зрение, интеллектуальный транспорт, нейронные сети, наружное наблюдение

Введение. Применение инструментов компьютерного зрения для решения учетных задач в ходе управления предприятием получило в настоящее время широкое распространение. Следует также отметить важную роль в интеллектуальном транспорте и интеллектуальном обнаружении дорожных событий такой задачи, как обнаружение и отслеживание транспортных средств в видеопотоке камер наружного наблюдения. Обусловлено это требованиями снижения себестоимости учетных и контрольных операций и исключения из их выполнения субъективного фактора, влияния уровня квалификации и дисциплины человека-наблюдателя.

В данной работе будет рассмотрено решение задачи управления размещением автомобилей на открытой парковке. С целью обеспечения эффективной поддержки размещения автомобилей перед системой ставились следующие функциональные требования:

1) система должна найти все машины на парковке, соответствующей камере наблюдения;

2) система должна работать на всех высотах расположения без переобучения и перенастройки системы компьютерного зрения

3) система должна работать во всех сезонах, день и ночь, также без переобучения и перенастройки;

4) система должна выдавать количество свободных парковочных мест на парковке;

5) система должна исключать из подсчета свободных мест зоны, в которых машины не могут парковаться или не принадлежат камере.

Связанные работы. Вопрос применения инструментов компьютерного зрения к задачам обнаружения, классификации и отслеживания транспортных средств, в том числе управления парковками, в настоящее время рассматривается в большом количестве научных исследований. Подробный обзор применения систем искусственного зрения в задачах управления транспортом приведен в работе [1]. Авторы работы [2] использовали сверточные нейронные сети по технологии Google Cloud Vision, доработанная на базе изображений парковок, собранных из набора данных KhNUParking. В работе [3] рассматривается решение задачи обнаружения и отслеживание транспортных средств на основе компьютерного зрения для сценариев в реальном времени на основе метода HOG для извлечения признаков, импровизированного корреляционного фильтра для отслеживания, и модели AdaBoost для классификации объектов. Авторы статьи [4] для управления колесными роботами используют алгоритм обнаружения объектов, основанный на сочетании архитектур YOLO и GhostNet. Работа [5] описывает применение нового подхода на базе сверточных нейронных сетей к решению задачи создания аппаратно-эффективной автоматизированной системы распознавания номерных знаков для ограниченной среды с ограниченными ресурсами.

Авторы данной работы также исследовали возможности решения задач мониторинга производственных площадок и отслеживания транспортных средств с помощью инструментов компьютерного зрения в своих работах [6–8].

Таким образом, решение поставленной в работе задачи — контроль наличия на автостоянке свободных парковочных мест — важно для повышения эффективности работы стоянок и актуально с точки зрения применяющихся инструментов.

Экспериментальные материалы. Использовавшиеся для обучения и тестирования системы данные были получены с 21 различной сцены, наблюдаемых уличными камерами охранного типа с домов города Красноярск в периода с зимы 2022 по весну 2023 г. Камеры установлены на разных высотах и под разным ракурсом. Разрешение всех изображений однотипное 2560×1440 пикселей в цветовом разрешение RGB.

В процессе подготовке обучения системы компьютерного зрения было размечено 2 623 изображений. Количество образцов класса «автомобиль» («car») суммарно на этих изображениях составило 123 795. Для устойчивой работы системы в различных погодных условиях обучающая выборка накапливалась постепенно, в настоящее время система находится в стадии ожидания сбора данных летнего сезона, когда на изображениях начнет проявляться зелень.

Методы решения задачи. Составление псевдокарты. По правилам дорожного движения [9] РФ стоянка автомобиля засчитывается в случае, если

транспортное средство остановилось дольше, чем на пять минут. Псевдокарта парковки целевого дома строилась на базе суточной записи с камеры видеонаблюдения.

С целью обучения детектора машин был разработан авторский обучающий датасет, поскольку модель предварительно обученная на датасете VoCOCOv2017 [10] не смогла дать достойный результат на изображениях, получаемых с охранных камер. С помощью обученного детектора, построенного на сверточной нейронной сети архитектуры YOLOv7 [11] находятся машины и вычисляются положения их центроидов.

Затем с помощью трекера точек отбрасываются центроиды движущихся объектов с порогом 5 минут. После фильтрации движущихся объектов выполнялось усреднение ближайших центроидов методом k-средних, число кластеров принималось равным максимальному числу автомобилей, обнаруженных на видео. Данная точка являлась центром парковочного места в полученной псевдокарте целевого здания.

Для визуализации области парковочного места решалась задача отображения усредненных рамок, ограничивающих область расположения машин, полученных во время детектирования положений машин моделью детектора. Для отсеивания зон, не относящихся к целевому зданию, на котором установлена камера, была реализована возможность выбора зоны интереса. Все машины, не находящиеся в зоне парковки, отсеивались из подсчета в системе.

Подсчет свободных мест на парковке. После создания псевдокарты целевой парковки система может выполнить подсчет свободных и занятых парковочных мест. Раз в минуту система получает кадр с камеры видеонаблюдения и детектирует машины с помощью детектора. Если центроид парковочного места находится в ограничительной рамке детектируемой машины, то считается, что парковочное место занято и отмечается красной меткой. Иначе место является свободным и помечается зеленой меткой.

Результаты. Модель на архитектуре YOLOv7 обучалась на видеокарте NVIDIA GeForce 2060ti в течение 6 ч. Метрики, полученные в результате обучения, показаны в таблице. По результатам, описанным в таблице, видно, что сеть обучилась успешно и ее можно использовать на сценах с похожим расположением камеры.

Метрики точности обучения модели YOLOv7

Name class	Average precision, %	Recall	F1-Score	IoU	mAP, %
car	98,20	0,97	0,97	84,91	98,20

На графике (см. рис. 1) показаны значения метрики val loss и mAP во время обучения.

На рис. 2 показаны результаты детектирования моделью YOLOv7 всех кадров суточного видеофрагмента, записанного для построения псевдокарты. Как видно на тестовом изображении определены статичные объекты и центроиды движущихся объектов.

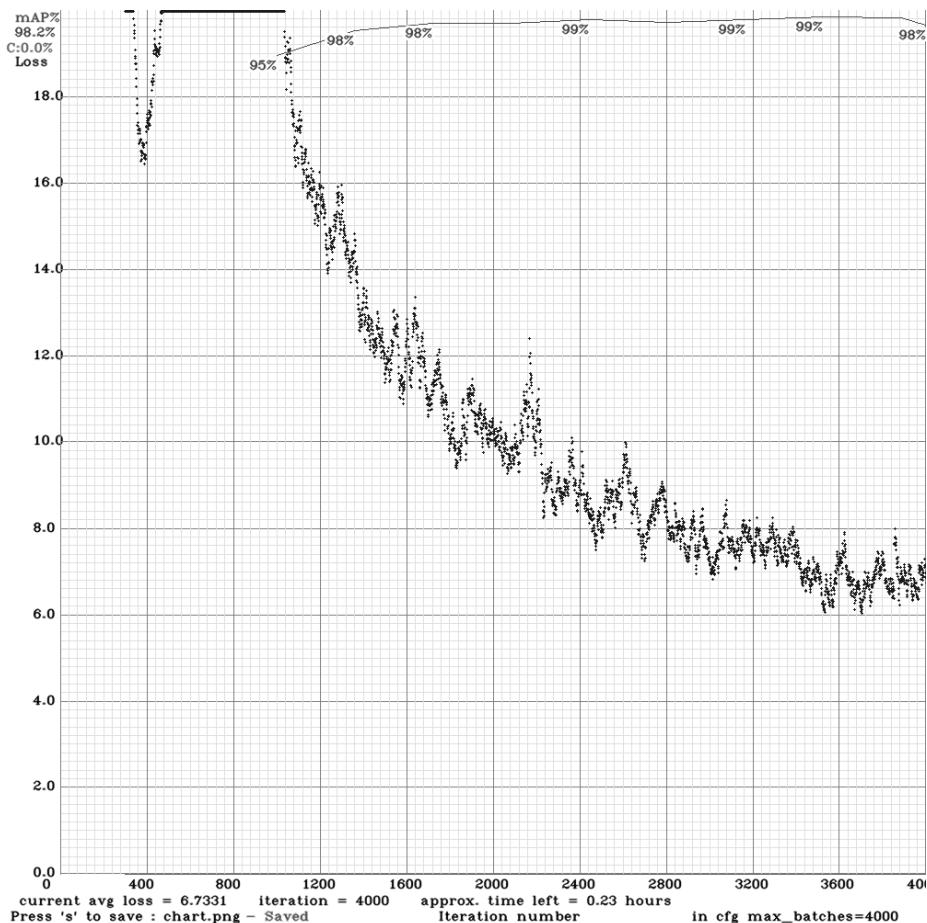


Рис. 1. График обучения YOLOv7 на собранных данных

Поскольку задача системы стоит в формировании карты пользовательской парковки с камеры, необходимо решить проблему исключения из карты центроидов тех объектов, точки которые отдалены друг от друга в промежутке 5–7 пикселей. На рис. 3 изображены отфильтрованные центроиды статичных объектов.

После применения алгоритма группировки объектов методом k-средних элементов в системе сохраняются новые координаты центроида, соответствующие позиции центров отдельных парковочных мест. На рис. 4 показан результат применения фильтра центроидов.

На следующем шаге после получения первичной псевдокарты необходимо решить задачу зонирования отдельных парковочных мест. Для этого берутся значения bounding box детектора, собранные с тестового суточного видео и далее методом k-средних усредняются значение координат рамок и определяются новые координаты X, Y bouding. На рис. 5 показаны синим

цветом усредненные границы отдельного парковочного места. Данная задача необходима для определения статуса отдельного парковочного места: свободное или занятое машиной.



Рис. 2. Получение всех центроидов класса «машина» с помощью детектора на базе архитектуры YOLOv7



Рис. 3. Центроиды статичных объектов

После получения координат всех парковочных мест алгоритм знает фиксированное количество парковок. На рис. 6–8 показаны подсчитанные парковочные места на разных камерах наружного наблюдения.



Рис. 4. Отсечение центроидов движущихся машин



Рис. 5. Пример усреднения прямоугольников, ограничивающих машины



Рис. 6. Пример подсчета парковочных мест на камере по адресу г. Красноярск, ул. Апрельская би



Рис. 7. Пример подсчета парковочных мест на камере по адресу г. Красноярск, ул. Ольховая, д.14

После получения готовой псевдокарты система получает возможность определения количества свободных и занятых парковочных мест в режиме реального времени. Для этого детектору определяется зона интереса, при этом ближайшая к парковке камера является целевой зоной. На рис. 9 синим

цветом отмечена зона парковки, относящаяся к камере «Апельская 6, фасад». В этой зоне система не должна выдавать ошибок.



Рис. 8. Пример подсчета парковочных мест на камере по адресу г. Красноярск, ул. Матросова, д.32



Рис. 9. Карта ответственности камеры по адресу г. Красноярск, ул. Апельская 6

После фиксации целевой зоны для текущей камеры система получает возможность определения статуса отдельного парковочного места. Для этого раз в пять минут на вход алгоритма подается изображение с камеры и детек-

тор фиксирует центроиды и ограничивающие рамки объекты типа «машина». Если рамка или центр пересекает ограничивающую рамку отдельного парковочного места, то система считает, что это место является недоступным. На рис. 10 и 11 показаны итоговые результаты работы системы.



Рис. 10. Подсчет и визуализация свободных и занятых парковочных мест на камере видеонаблюдения по адресу г. Красноярск, ул. Апрельская, д. 6б



Рис. 11. Подсчет и визуализация свободных и занятых парковочных мест на камере видеонаблюдения по адресу г. Красноярск, ул. Апрельская, д. 6б (во дворе)

Вывод. Во время разработки нам удалось решить все поставленные задачи и успешно запустить в работу систему отслеживания свободных мест на изображениях, полученных с камер, расположенных на разных высотах и под различными углами, а также в разных естественных условиях, включающие в себя снег и ночные съемки с различными оптическими дефектами.

Перспективой развития данной работы является решение обратной задачи, а именно поиск оставленной машины в незаконном месте и уведомления об этом соответствующих служб.

Литература

- [1] Postolit A.V. Prospects for the use of artificial intelligence and computer vision in transport systems and connected cars // World Transp. 2021. Vol. 19, no. 1. Pp. 74–90.
- [2] Radiuk P. et al. Convolutional neural network for parking slots detection // 3rd International Workshop on Intelligent Information Technologies & Systems of Information Security. Khmelnytskyi, Ukraine, 2022. Vol. 3156.
- [3] Senthil Murugan A. et al. Computer vision-based vehicle detection and tracking // Advances in Automation, Signal Processing, Instrumentation, and Control, Select Proceedings of i-CASIC 2020. 2021. Pp. 2899–2906. https://doi.org/10.1007/978-981-15-8221-9_271
- [4] Hu Y. et al. Object Detection Algorithm for Wheeled Mobile Robot Based on an Improved YOLOv4 // Appl Sci. 2022. Vol. 12, no. 9. Art. 4769.
- [5] Padmasiri H. et al. Automated License Plate recognition for resource-constrained environments // Sensors. 2022. Vol. 22, no. 4. Art. 1434.
- [6] Alekhina A., Gurenko A., Dorrer M. Application of computer vision tools to create a system for monitoring the work of ground equipment in open pits of gold mining Enterprises // Cyber-Physical Systems: Intelligent Models and Algorithms. 2022. Pp. 203–218.
- [7] Dorrer M.G., Tolmacheva A.E. Comparison of the YOLOv3 and Mask R-CNN architectures' efficiency in the smart refrigerator's computer vision // J Phys Conf Ser. 2020. Vol. 1679. Art. 042022.
- [8] Dorrer M.G., Popov A.A., Tolmacheva A.E. Building an artificial vision system of an agricultural robot based on the DarkNet system // IOP Conf Ser Earth Environ Sci. 2020. Vol. 548. Art. 032032.
- [9] Правила дорожного движения ПДД-2023 [Electronic resource]. 2023. URL: <https://www.pdd24.com/>.
- [10] COCO 2017 Dataset // Kaggle. 2017. Available at: <https://www.kaggle.com/datasets/awsaif49/coco-2017-dataset> (accessed March 15, 2023).
- [11] YOLOv7: The Most Powerful Object Detection Algorithm (2023 Guide) // viso.ai. 2023. Available at: <https://viso.ai/deep-learning/yolov7-guide/> (accessed March 15, 2023).

Application of Yolo Architecture Convolutional Networks for Counting Free Parking Spaces in Random Parking

✉ Alekhina A.E.^{1,2}

Korolev P.A.¹

Dorrer M.G.¹

dumooroo@gmail.com

kuronikushini@gmail.com

mdorrer@mail.ru

¹ Siberian State University of Science and Technology M.F. Reshetnev, Krasnoyarsk, 660037, Russia

² Siberian Federal University, Krasnoyarsk, Russia

The paper describes the solution to the problem of automatically fixing the presence of free parking spaces in parking lots based on the video stream of a surveillance camera. The problem was solved using a combination of the YOLOv7 model for detecting objects of interest of the «car» type, trained on a specially created training set and grouping objects using the k-means algorithm. The proposed solution showed satisfactory accuracy and suitability for practical use in conditions of significant optical interference - daily changes in illumination and the presence of precipitation for calculating free parking spaces by the model without retraining it for various parking lots.

Keywords: parking monitoring, computer vision, intelligent transport, neural networks, outdoor surveillance

УДК 351

Тенденции применения технологий искусственного интеллекта и когнитивных технологий в государственном управлении

© Вареник Мария Сергеевна varenik_ms@mail.ru
Самсонов Роман Олегович roman@samsonov.org
Воронина Марина Анатольевна km29@bk.ru

Высшая школа государственного администрирования МГУ, Москва, 119991, Россия

Представлены результаты исследования авторов, которые легли в основу создания образовательной программы Высшей школы государственного администрирования МГУ «Искусственный интеллект и когнитивные технологии в менеджменте». Исследованию предшествовал анализ основных методов управления на базе информационных технологий, применяемых в процессе трансформации государственного администрирования, существовавшей в СССР централизованной и плановой системы до рыночной экономики Российской Федерации современного этапа. Кроме того, выделены основные проблемы и сложности развития, а также проведен анализ основных тенденций в технологиях управления, формирующихся под влиянием бурного развития информатизации, появления больших данных и современных вычислительных систем большой производительности. При этом исследователи систематизировали наиболее доступные прогрессивные технологии, в том числе уже реализованные и практически используемые в текущем управлении государством, способные обеспечить планомерное и динамичное развитие государства и его основных функций даже под влиянием внешних экономических санкций и геополитического противостояния. Рассмотрены примеры применения когнитивных технологий и искусственного интеллекта в Российской практике государственного управления, позволяющие уже сегодня добиваться реальных результатов управления 86 субъектами и внедрять методы государственного стратегического планирования, государственной поддержки и рыночные механизмы.

Ключевые слова: искусственный интеллект, когнитивные технологии, когнитивные системы, государственное управление, машинное обучение, цифровизация, информатизация

В современной практике управления представители менеджмента всех уровней начинают использование самых передовых технологий искусственного интеллекта значительно быстрее, чем это успевают обосновать теоретики и консультанты. Искусственный интеллект, используемый маркетологами и разработчиками технологий, позволяет на порядки сократить время для появления на рынке новых устройств коммуникационных систем, а технологии цифрового инжиниринга и производства позволяют практически с самого начала выхода на рынок добиваться комфортного ценообразования и увлекать потребителя совершенным дизайном и удобством. Масштабность и скорость внедрения еще вчера не существовавших алгоритмов искусственного интеллекта и человекоподобных технологий, связана со стремительным раз-

витием коммуникационных технологий и проникновением мобильных гаджетов и систем практически во все виды деятельности и быта всех социальных слоев населения и по всему миру. Сетевые коммуникационные сообщества бедных слоев общества по интенсивности и объему трафика могут даже превосходить объемы мобильного трафика более состоятельных сограждан. Нет ни одного вида технологий в истории человечества, которая бы имела аналогичные темпы распространения в управлении деятельности, от бизнеса и производства до государственного администрирования. Мы не успеваем осмыслить уровень влияния мобильных и информационных цифровых систем на нашу жизнь, а уже находимся большую часть сознательного состояния под управлением алгоритмами наших мобильных телефонов и информационных сервисов.

Попытки противостоять и как-то управлять этим влиянием редко базируются на глубоких аналитических исследованиях, учитывающих риски и вред подобного влияния. Рекомендации, доступные всем в виде «лейфхаков» редко основываются на профессиональной экспертизе и междисциплинарных исследованиях и позволяют в лучшем случае, борясь с информационным и цифровым мусором и не более.

Если подобная ситуация еще допустима в быту, личной жизни, то в менеджменте, ставящем цели и задачи перед другими объектами и субъектами управления, «идти на поводу» непонятно как упрощенных или оптимизированных алгоритмов, недопустимо. Тем более, это становится важно для особо ответственных производств, сервисов и бизнесов, где внешнее или стороннее управление влияние может не только остановить движение к целям, но и привести к нарушению требований безопасности. В этом смысле, государственное управление, работа с большими объемами информации, касающихся большего количества разных людей, обеспечением точных управлений действий и координации разных систем и служб, обеспечивающих безопасную жизни и работу граждан общества, становится одним из важнейших элементов существования государства и общества. Поэтому применение аналитических и новых высокотехнологичных методов исследований в области влияния технологий искусственного интеллекта и когнитивных технологий становится одним из важнейших научных приоритетов все большего количества специалистов и исследователей.

Далее раскроем некоторые результаты исследований, проведенных в последние годы совместно со студентами и аспирантами, которые позволили приступить к разработке программы учебной дисциплины, ставшей основой для создания магистерской образовательной программы Высшей школы государственного администрирования МГУ «Искусственный интеллект и когнитивные технологии в менеджменте». Основной целью создания магистерской программы является подготовка высококвалифицированных специалистов в области государственного управления, готовых к работе в условиях цифровизации всех сфер общества, развития искусственного интеллекта и смарт-технологий.

В качестве основных целей государственного управления выделяют:

- социально-экономические, включающие в себя организацию общественной жизни, достижение экономического благосостояния и стабильности, организацию и руководство системой экономических отношений;
- политические, включающие вовлечение в процессы управления политических сил, с целью развития государственных и общественных структур, а также каждого индивида в отдельности;
- обеспечительные, включающие обеспечение законности общества, соблюдения прав и свобод граждан, правопорядка и высокого уровня благосостояния;
- организационно-правовые, включающие формирование механизмов правового государства [1].

На основании обозначенных целей можно обозначить следующие задачи государственного управления:

- обеспечение благосостояния граждан;
- удовлетворение социальных потребностей и интересов населения;
- защита прав и свобод жителей страны;
- обеспечение общественного правопорядка и безопасности;
- регулирование социальной сферы жизни общества;
- регулирование экономической сферы жизни общества;
- регулирование налогообложения;
- создание кадрового потенциала обеспечения управления.

Несомненно, применение технологий искусственного интеллекта позволяет наиболее эффективно реализовывать задачи государственного управления, так как с их помощью уже сейчас можно решить многие задачи, стоящие перед государственными служащими, в том числе упростить выполнение рутинных операций. Возможные сферы применения искусственного интеллекта представлены на рис. 1.

В качестве одного из передовых технологий искусственного интеллекта можно назвать агент-ориентированное моделирование, которое позволяет смоделировать с помощью логико-математических моделей, любую заданную условиями и статистическими данными ситуацию: ход развития болезни, моделирование краш-тестов в автомобильной промышленность, можно даже создать искусственное общество, реагирующее направленческие решения.

Искусственный интеллект и машинное обучение обеспечивают корректность математических моделей, помогающих лучше понять явления, связанные с миграцией, различными способами. Например, проект Jetson Управления Верховного комиссара Организации Объединенных Наций вычисляет индекс миграционного перемещения с помощью ИИ, который позволяет делать краткосрочные прогнозы ожидаемых миграционных потоков в Африке на основе ключевых переменных, таких как цены на рынке товаров, количество осадков и насилиственные конфликты. Кроме того, ИИ может дополнять и расширять опыт человека в интерпретации спутниковых изображений для выявления внутренних перемещений или повреждений инфраструктуры после стихийных бедствий.



Рис. 1. Возможные сферы применения искусственного интеллекта в процессе государственного управления

Для сбора данных, управления программами и оценки различных результатов деятельности и процессов в государственном управлении активно применяются технологии географических информационных систем (ГИС). С помощью ГИС сотрудники и руководители агентств интегрируют различные типы данных, чтобы получить понимание, реализовать решения, поделиться идеями и привлечь заинтересованные стороны и общественность.

Использование ГИС для включения информации о местоположении в процесс принятия решений на высоком уровне обеспечивает глубокое понимание важнейших проблем, с которыми сталкивается страна, и поддерживает разработку государственных программ любого уровня на основе научных и аналитических данных.

Наряду с федеральными и государственными организациями использование ГИС для местных органов власти, может быть очень полезным. Анализ геопространственных данных для государственных учреждений может решить множество важных задач (рис. 2).

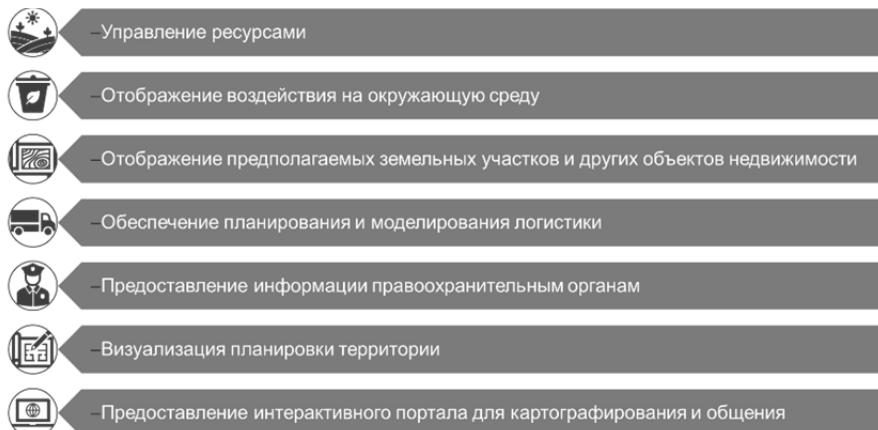


Рис. 2. Задачи, которые могут решить геопространственные данные для государственных учреждений

От обеспечения национальной безопасности в защищенной базе данных до карт сельскохозяйственных площадей, которые помогают фермерам составить план урожая — картографические и геопространственные данные предлагают множество преимуществ для государства. Рассмотрим более подробно возможности применения ГИС для решения различных задач эффективного государственного управления (рис. 3):

- анализ преступности;
- реагирование в условиях ЧС;
- оказание финансовых услуг;
- решение вопросов национальной безопасности;
- применение технологий в туристической сфере;
- решение вопросов водоснабжения и водоотведения.



Рис. 3. Возможности применения ГИС для решения различных задач эффективного государственного управления

Правительства многих зарубежных стран активно внедряют технологии искусственного интеллекта в процессы государственного управления. Начиная с 2017 года, с целью развития области искусственного интеллекта, происходит активная разработка и утверждение национальных стратегий искусственного интеллекта в различных странах. Свои национальные стратегии Искусственного интеллекта выпустили многие страны Европейского союза (Франция, Германия, Италия и др.), а также США, Великобритания, Канада, Китай, Индия, Япония, Мексика, ОАЭ и др. Кроме того, в 2018 году Европейский союз разработал Скоординированный план по искусственному интеллекту, основными целями которого являются реализация согласованной всеми странами Европейского союза политики в области искусственного интеллекта, координация действий всех стран — членов Европейского союза в соответствии с утвержденными стратегиями и программами, увеличение объема инвестиций в исследования, разработки и развитие искусственного интеллекта.

В 2022 г. Европейская комиссия представила технический отчет, в котором проведен сравнительный анализ утвержденных национальных стратегий искусственного интеллекта стран — членов Европейского союза с целью выявления соответствия национальных стратегий Скоординированному плану Европейского союза по искусственному интеллекту, который был обновлен в 2021 г. В отчете отмечается необходимость непрерывной оценки прогресса исполнения Национальных стратегий, а также их обновления. Основной вывод экспертов заключается в том, что все утвержденные стратегии соответствуют целям Скоординированного плана по искусственному интеллекту.

Кроме того, во всех рассмотренных Национальных стратегиях отмечается важность данных, а также необходимость создания политики открытых данных. В результате — многие страны предложили создать национальные

пространства данных с целью предоставления доступа к статистическим данным и данным в режиме реального времени.

Стоит отметить, что указом Президента Российской Федерации 10 октября 2019 г. № 490 «О развитии искусственного интеллекта в Российской Федерации» была утверждена Национальная стратегия развития искусственного интеллекта на период до 2030 г. Согласно Национальной стратегии развития искусственного интеллекта Российской Федерации использование технологий искусственного интеллекта будет способствовать повышению «эффективности процессов планирования, прогнозирования и принятия управлеченческих решений» [3].

Таким образом официальное использование искусственного интеллекта в государственном управлении как части системы управления началась всего 3 года назад. Что удалось за это время?

С целью активного взаимодействия с гражданами во всех регионах Российской Федерации были созданы Центры управления регионами. Центр управления регионом (ЦУР) — координационный центр по мониторингу и обработке всех видов обращений и сообщений граждан. На основе поступающих в ЦУРы данных будут формироваться аналитические материалы, характеризующие социально-экономическую ситуацию в каждом регионе, и вырабатываться предложения по дальнейшему развитию. Таким образом, в деятельности ЦУРов активно используются различные платформы, разработанные с технологиями искусственного интеллекта, позволяющие выполнять их основные функции.

Ведущие эксперты Российских вузов предлагают правительству идею системы «Цифровой Госплан», которая бы контролировала реализацию стратегических документов в режиме реального времени. Такая система могла бы стать эффективным механизмом реализации государственной политики в области стратегического планирования. Однако, несмотря на активное повсеместное развитие технологий искусственного интеллекта, их внедрение в процессы государственного управления проходит недостаточно активно.

Использование искусственного интеллекта для анализа и сортировки входящей корреспонденции в менеджменте, крупных корпораций начался значительно раньше и постепенно стал востребован и в государственном документообороте. Эффект из-за роста корреспонденции, в частности электронной, и технологической возможности для этого в несколько раз, — это сотни тысяч ежемесячных обращений, на обработку которых тратятся существенные средства. В государственном управлении подобные алгоритмы стали активно использоваться в обработке обращений и жалоб граждан. По разным оценкам до 40 % обращений могут обрабатываться без привлечения человека. А вот назначение ответственного исполнителя или подготовка основ текстов резолюций уже имеет больший процент.

Виртуальные помощники и чат-боты, в частности HR-боты или FAQ-боты уже является основным методом обработки внутренних запросов и коммуникаций большинства крупных и средних компаний.

Обеспечение безопасности системы поддержки и принятия решений является одним из ключевых целей реализации стратегии искусственного интеллекта. Стоит также учитывать и фактор того, что искусственный интеллект сегодня еще не является сильным, хотя какие-то отдельные решения или удачно адаптированные элементы могут оказывать вполне реальное давление на характер управлеченческих процессов, особенно в части интеграции с бизнесом, занимающимся инфраструктурным или сервисным развитием.

Предстоит еще немало сделать, в секторе деятельности малого и среднего предпринимательства, самозанятого предпринимателя, который по численности уже достиг почти 30 миллионов человек и обладает при правильной поддержке со стороны государства большим потенциалом.

Еще предстоит освоить технологии «сквозного» проектирования управлеченческих решений, в том числе создания «цифровых двойников» отдельных субъектов и объектов. Хотя для бизнеса использование искусственного интеллекта в техническом применении — это уже активно развивающаяся практика, которая несомненно начинает оказывать влияние на рост эффективности некоторых отраслей промышленности и производства.

Идеи «Цифрового Госплана» с разработкой ключевых ориентиров — планов экономического развития на базе индикативных показателей и прогнозных значений единых сквозных цифровых показателей, являются очень передовыми и перспективными, однако не принимаются, на данном этапе, общественностью как перспективный элемент развития государства. Стоит только отметить появления новых уникальных технологических возможностей обработки массивов больших данных, которые раньше были просто невозможны, что должно сделать привычным не только стратегическое планирования с сотнями вариантами и сценариями, что уже делается в ряде отраслей, в частности нефтяной и газовой, но краткосрочную, среднесрочную и долгосрочную перспективы. Отдельно предстоит проведение целой серии исследований с китайскими студентами и аспирантами по применению технологий искусственного интеллекта и новых вычислительных возможностей для внедрения механизмов государственного планирования и администрирования в Китайская Народная Республика.

Литература

- [1] Борисова Е.К. Цели и задачи государственного управления // Проблемы науки. 2019. № 12 (48). URL: <https://cyberleninka.ru/article/n/tseli-i-zadachi-gosudarstvennogo-upravleniya> (дата обращения 30.03.2023).
- [2] Косоруков А.А., Кшеменецкая М.М. Цифровое управление как современный этап развития государственного управления (на примере открытых данных) // Тренды и управление. 2019. № 1. С. 27–34.
- [3] Указ Президента Российской Федерации от 10.10.2019 № 490 «О развитии искусственного интеллекта в Российской Федерации». URL: <http://publication.pravo.gov.ru/Document/View/0001201910110003?index=0&rangeSize=1> (дата обращения 11.04.2023).
- [4] Постановление Правительства РФ от 3 апреля 2021 г. № 542 «Об утверждении методик расчета показателей для оценки эффективности деятельности высших должностных лиц

(руководителей высших исполнительных органов государственной власти) субъектов Российской Федерации и деятельности органов исполнительной власти субъектов Российской Федерации». URL: <https://www.garant.ru/products/ipo/prime/doc/400484539/> (дата обращения 11.04.2023).

Trends in the Use of Artificial Intelligence and Cognitive Technologies in Public Administration

© Varenik M.S.

varenik_ms@mail.ru

Samsonov R.O.

roman@samsonov.org

Voronina M.A.

km29@bk.ru

Higher School of Public Administration, Moscow State University, Moscow, 119991, Russia

The results of the authors' research, which formed the basis for the creation of the educational program of the Higher School of Public Administration of Moscow State University "Artificial Intelligence and cognitive technologies in management", are presented. The study was preceded by an analysis of the main management methods based on information technologies used in the process of transformation of public administration, the centralized and planned system that existed in the USSR before the market economy of the Russian Federation of the modern stage. In addition, the main problems and complexities of development are highlighted, as well as an analysis of the main trends in management technologies that are being formed under the influence of the rapid development of informatization, the emergence of big data and modern high-performance computing systems. At the same time, the researchers systematized the most accessible progressive technologies, including those already implemented and practically used in the current management of the state, capable of ensuring the systematic and dynamic development of the state and its main functions even under the influence of external economic sanctions and geopolitical confrontation. Examples of the use of cognitive technologies and artificial intelligence in the Russian practice of public administration are considered, which allow today to achieve real results of managing 86 subjects and introduce methods of state strategic planning, state support and market mechanisms.

Keywords: *artificial intelligence, cognitive technologies, cognitive systems, public administration, machine learning, digitalization, informatization*

УДК 004.5

Человеко-компьютерное взаимодействие на основе преобразования движения произвольных объектов в видеопотоке

© | Пересунько Павел Викторович
Пересунько Евгения Олеговна

pvreresunko@yandex.ru
eperesunko@sfu-kras.ru

Сибирский федеральный университет, Красноярск, 660041, Россия

Данная работа посвящена задаче управления курсором компьютера. Несмотря на большое количество способов позиционирования курсора, системы с использованием компьютерного зрения позволяют повысить количество способов взаимодействия человек-компьютер. В качестве маркера, с помощью которого перемещается курсор, может быть любой объект, который можно распознать на видео. Особен-но остро стоит вопрос управления курсором при ограничениях, в частности, при невозможности совершения человеком определенных действий. Предложенные в работе способы управления курсором могут позволить людям с ограниченными возможностями взаимодействовать с компьютером. Кроме этого, возможность наделять движения способностью управления курсором позволяет мотивировать человека разрабатывать это движение, что, в свою очередь, позволяет геймифицировать процесс реабилитации. Поэтому данная работа посвящена увеличению способов управления курсором компьютера. Для достижения этой цели была предложена система показателей, которая позволяет считывать движения маркеров и переводить их в сигнал для компьютера, в данном случае — в управление курсором. Для примера в предложенной системе в качестве показателя используется угол между векторами. Была представлена схема работы программы. В результате проведен эксперимент, в котором участникам необходимо было решить задачу взаимного постукивания с помощью предложенной программной системы. Опыты показали работоспособность системы. Участники адаптировались к новому варианту управления курсором, постепенно уменьшая время, которое необходимо для решения задачи. Данный эксперимент доказал возможность управления курсором с помощью системы показателей.

Ключевые слова: управление курсором, вспомогательные технологии, человеко-компьютерное взаимодействие, взаимодействие человек–машина, компьютерное зрение

При построении человека-компьютерного взаимодействия важной частью является управление курсором. С помощью курсора компьютера человек может взаимодействовать с виртуальными объектами. Имея виртуальную клавиатуру, адаптированную под ввод текста с помощью курсора, человек может быстрее осуществлять набор текста [1]. Как правило, управление курсора происходит с помощью компьютерной мыши, однако у нее есть ограничения в применении — ее сложно настроить на движение какой-то частью тела, отличной от руки пользователя, что не позволяет использовать данный вид манипуляторов при работе с персональным компьютером людьми, не имеющими

ми возможности перемещать мышь вышеописанным способом. Во-первых, необходимо настроить контакт между мышью и заданной частью тела. Во-вторых, требуется обеспечить движение мыши по поверхности.

Ярким примером необходимости альтернативного варианта управления курсора является геймификация процесса реабилитации пациентов с неврологическими нарушениями и адаптация ввода под управление с ограничениями. Существуют различные способы управления — на основе голосового ввода [2, 3], датчиков [4], компьютерного зрения [5, 6] и другие.

В абсолютном способе позиционирования курсора оператор устанавливает область перемещения маркера m с помощью прямоугольника. Далее положение координат курсора устанавливается пропорционально положению маркера в этом прямоугольнике. Прямоугольник задается левым верхним и нижним правым углом с координатами (x_1, y_1) и (x_2, y_2) . В этих случаях можно выделить показатель для перемещения курсора по каждой из осей. Например, значение показателя для установки положения курсора по оси абсцисс может вычисляться по формуле

$$x_c(t) = \frac{x_m(t) - x_1}{x_2 - x_1}.$$

Подобные варианты позиционирования происходят во многих исследованиях, например, в программном продукте Camera Mouse [7]. Размер активной области задается с помощью установки чувствительности к перемещению маркера по оси абсцисс и ординат. В работе [8] авторы также предлагают использовать абсолютное позиционирование курсора, так как при медленной обработке кадров у пользователя получалось позиционировать курсор с заданной точностью. В [9] авторы использовали абсолютное перемещения курсора в зависимости от угла поворота головы.

Такой способ позиционирования является понятным для пользователя, так как устанавливает позицию курсора «как есть». Однако шумы в распознавании положения маркера сильно влияют на положение курсора, что затрудняет манипуляции с мелкими объектами (ярлыки, кнопки и так далее) и повышает число нежелательных нажатий.

В относительном способе управления курсором новое положение устанавливается относительно позиции курсора на прошлом такте. Например, при изменении координаты курсора по оси абсцисс, положение курсора $x_c(t+1)$ можно задать с помощью формулы

$$x_c(t+1) = x_c(t) + u(t),$$

где $x_c(t)$ — положение курсора в момент времени t , $u(t)$ — управляющий сигнал, который устанавливает сдвиг.

Значение управляющего сигнала рассчитывается с помощью показателя $p_c(t)$. В работах, где курсор равномерно движется, размер показателя определяется ступенчатой функцией. В работах [10, 11] происходит относительное движение курсора.

К преимуществам системы с относительным управлением можно отнести низкие требования к количеству уровней сигнала. В ряде ранее упомянутых исследований пользователи изменяли положение курсора с помощью перемещения курсора в четыре стороны с одинаковой скоростью. В абсолютном позиционировании количество уровней сигнала должно быть равно количеству пикселей монитора по соответствующей оси. Кроме того, на систему не так сильно влияют шумы: если курсор уже движется в какую-то сторону, то незначительный шум может изменить скорость передвижения, не меняя направление.

Ввод в систему показателя позволяет описать разные способы взаимодействия человека и компьютера. Показатель может быть равен положению маркера относительно активной области, расстоянию до точки, расстоянию между подвижными точками, координате курсора на мониторе и так далее. В данной работе предлагается использовать угол между векторами как показатель. Ввод данного показателя значительно увеличивает количество вариантов использования системы.

Управление углом может быть использовано не только для обычного использования, но и для игр. Настраивая такое взаимодействие, можно мотивировать человека двигать заданной частью тела.

Например, если пациенту необходимо разработать отодвигание большого пальца правой руки, то можно использовать угол отклонения большого пальца для перемещения курсора по оси абсцисс. Тогда в качестве векторов могут быть использованы проксимальные фаланги большого и указательного пальца. С помощью показателя можно построить систему с возможностью переключения между абсолютным и относительным перемещением.

В данной работе была предложена система, которая перемещает курсор в режиме реального времени с помощью отодвигания больших пальцев левой и правой руки. Левая рука отвечает за перемещение курсора по оси абсцисс, правая — по оси ордината. Вектора v_1 и v_2 , с помощью которых вычислялся угол отклонения большого пальца, можно увидеть на рис. 1.

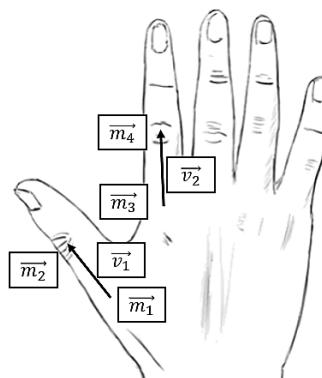


Рис. 1. Проксимальные фаланги, которые задают угол между большим и указательным пальцем

Программа реализована на языке программирования Python. Для определения ключевых точек руки используется библиотека MediaPipe. Пользователь может настраивать максимальный и минимальный угол отклонения большого пальца правой и левой руки. Также пользователь может настраивать максимальную скорость, с которой будет перемещаться курсор по каждой оси, и границы угла, в котором изменения показателя игнорируются. Схему применения показателя к перемещению курсора в данной системе можно увидеть на рис. 2.

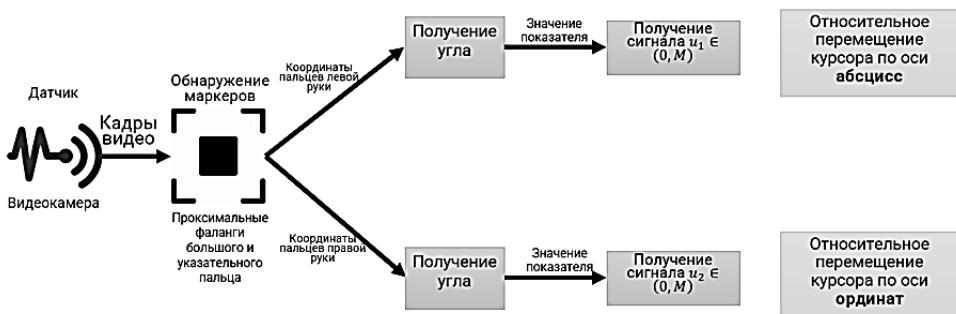


Рис. 2. Схема получения показателя и его применения в задаче позиционирования курсора

В данной работе был проведен эксперимент, цель которого — проверка работоспособности управления курсором с помощью угла между векторами. Фокус-группа состояла из восьми опытных пользователей ПК в возрасте от 20 до 25 лет. Участникам необходимо решить двумерную задачу взаимного постукивания, т. е. в заданном порядке нажать на объекты. Каждый участник выполнял задачу 50 раз. Камера располагается сверху и направлена на плоскость стола. Левая рука отвечает за перемещение курсора по оси ординат, правая — по оси абсцисс. Использовалось относительное позиционирование курсора. Эксперимент проводился с помощью компьютера с экраном с разрешением 1920 на 1080 пикселей. Радиус каждого круга в решаемой задаче равен 30 пикселей, расстояние между центрами противоположных кругов — 400 пикселей.

В результате было получен ряд из 50 измерений для каждого из 8 участников. В качестве меры адаптации пользователей к новому варианту позиционирования курсора используется время, которое необходимо для решения задачи. Для каждой по номеру попытки рассчитывалось среднее время, за которое участники решали задачу. Таким образом был получен ряд из 50 величин. Таким же образом было посчитано среднее расстояние положения курсора до оптимальной траектории. В качестве оптимальной траектории используется отрезок, который соединяет центр круга, на который пользователь уже нажал с центром круга, на который пользователю необходимо нажать. Запись положения курсора проходила раз в 30 секунд. В качестве расстояния используется длина перпендикуляра на оптимальную траекторию.

Если проекция не попадает на оптимальную траекторию, то берется расстояние до ближайшего конца отрезка.

Для определения тренда изменения времени и расстояния использовалась кусочно-линейная регрессия. Количество точек перегиба определялось с помощью байесовского информационного критерия. На рисунке 3 показана модель времени выполнения задания, где точками изображено среднее время. Точки перегиба равны 2,69 и 9,81. После десятой попытки началась постепенная адаптация к управлению курсором с помощью углов. На 50-й попытке участники решали задачу в среднем за 36,65 с.

Аналогично была построена модель для расстояния между положением курсора и точки проекции на оптимальную траекторию, что показано на рис. 4.

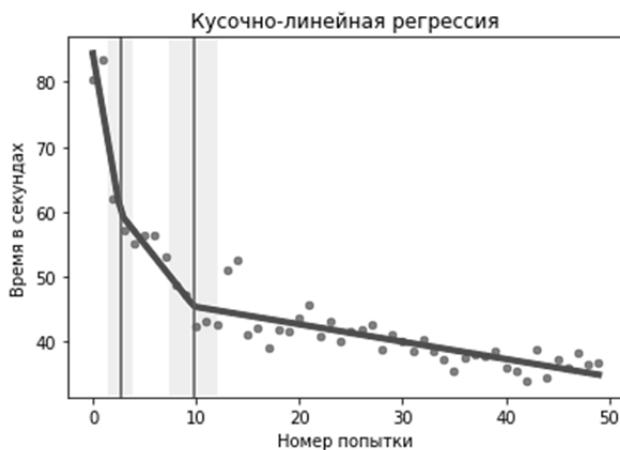


Рис. 3. Модель для времени, необходимого для решения задачи

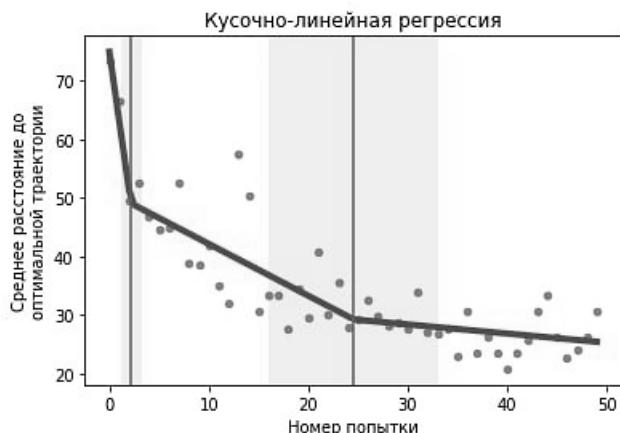


Рис. 4. Модель расстояния до оптимальной траектории

С помощью кусочно-линейной регрессии было рассчитано, что оптимальное количество точек разрыва для байесовского критерия было равно 2. Точки перегиба, они были равны 2,17 и 24,58. Полученные результаты показывают, что наблюдается существенное улучшение качества управления в ходе адаптации к решению задачи, что позволяет использовать данное решение для управления курсором с помощью произвольных частей тела. Даный подход способен расширить область применения компьютерного зрения при решении задач человека-компьютерного взаимодействия.

В данной статье были рассмотрены разные варианты позиционирования курсора: абсолютный и относительный. Предложен новый способ управления курсора — управление на основе угла между произвольными векторами. В данной статье в качестве прямых использовались проксимальные фаланги большого и указательного пальца. В ходе эксперимента были получены выводы о возможности управления курсором с помощью углов между векторами.

Литература

- [1] Бородыня М.А., Дойчев В., Цыренжапов А.З., Пересунько П.В. Implementation of the simulated annealing algorithm for selecting the optimal key layout on a hex keyboard // MIP: Engineering-IV-2022: сб. мат. IV междунар. науч. конф. Красноярск: ККДНиТ, 2022.
- [2] Dai L., Goldman R., Sears A., Lozier J. Speech-based cursor control: a study of grid-based solutions // Proceedings of the ACM SIGACCESS Conference on Computers and Accessibility. USA, Atlanta, 2004. Iss. 77–78. Pp. 94–101.
- [3] Harada S., Landay James A., Malkin Jonathan, Xiao Bing Li, Bilmes Jeff A. The vocal joystick: evaluation of voice-based cursor control techniques for assistive technology // Disability and Rehabilitation: Assistive Technology. 2008. Vol. 3, no. 1. Pp. 22–34.
- [4] Перчатки VR Senso Glove DK3. VR Space. URL: <https://virtualityspace.com/product/taktilnye-perchatki-vr-senso-glove-dk3/> (дата обращения 29.03.2023).
- [5] Ying Liu, Lei Tang, Ke Song, Suihe Wang, Jiangli Lin. A multicolored vision-based gesture interaction system // 3rd International Conference on Advanced Computer Theory and Engineering (ICACTE). China, Chengdu, 2010. Pp. 281–284.
- [6] Gupta A., Sharma N. A real time controlling computer through color vision based touchless mouse // Parishodh Journal. 2020. Vol. 8, no. 1. Pp. 123–128.
- [7] Betke M., Gips J., Bharadwaj K., Fleming P. The Camera mouse: visual tracking of body features to provide computer access for people with severe disabilities // IEEE Transactions on Neural Systems and Rehabilitation Engineering. 2012. Vol. 10, no. 1. Pp. 1534–1543.
- [8] Niyazi K., Kumar V., Mahe S., Vyawahare S. Mouse simulation using two coloured tapes // International Journal of Information Sciences and Techniques. 2012. Vol. 2, no. 2. Pp. 57–63.
- [9] Nabati M., Behrad A. 3D head pose estimation and camera mouse implementation using a monocular video camera // Signal, Image and Video Processing. 2015. Vol. 9. Pp. 39–44.
- [10] Khan F., Halim B., Rahman A. Computer vision based mouse control using object detection and marker motion tracking // International Journal of Computer Science and Mobile Computing. 2020. Vol. 9, iss. 5. Pp. 35–45.
- [11] Salvi M., Kegade Sh., Shinde A., Tekwani B. Cursor manipulation with hand recognition using computer vision // IT in Industry. 2021. Vol. 9, no. 1. Pp. 1455–1456.

Human-Computer Interaction Based on the Transformation of the Movement of Arbitrary Objects in the Video Stream

© Peresunko P.V.

pvpresunko@yandex.ru

Peresunko E.O.

eperesunko@sfu-kras.ru

Siberian Federal University, Krasnoyarsk, 660041 Russia

The present paper focuses on the challenging task of cursor control. It emphasizes the use of computer vision systems to augment the ways of human-computer interaction. The versatility of these systems lies in their ability to leverage any recognizable object in a video as a marker to move the cursor. The pressing need for cursor control arises particularly in situations where people face certain restrictions in performing motor actions. The proposed cursor control methods hold remarkable potential to facilitate computer engagement for people with disabilities. Furthermore, imbuing movements with cursor-controlled functionality can incentivize individuals to improve motor skills, thereby gamifying the rehabilitation process. The objective of this work is to expand the modes of cursor control. To this end, a marker-based system of indicators was proposed that interprets movement signals to enable cursor control. The system employs the angle between vectors as an indicator, and its scheme was detailed. An experiment was performed to examine whether participants could solve a mutual tapping problem using the proposed software system. The experiment results attested to the system's efficacy, as participants adapted to the new cursor control option, progressively reducing the needed solution time. Overall, the experiment validated the feasibility of cursor control by a system of indicators.

Keywords: cursor control, assistive technologies, human-computer interaction, human-machine interaction, computer vision

УДК 004.89

Имитационная нейросетевая модель прогнозирования течения и исходов инфаркта миокарда

©	Русин Дмитрий Сергеевич	drusin@sfu-kras.ru
	Сопов Евгений Александрович	ESopov@sfu-kras.ru
	Михалев Антон Сергеевич	asmikhalev@yandex.ru
	Антамошкин Олеслав Александрович	oleslav24@gmail.com
	Брюханова Евгения Романовна	erbryukhanova@sfu-kras.ru

Сибирский федеральный университет, Красноярск, 660041, Россия

Отображается эффективность применения метода машинного обучения для решения задачи прогнозирования инфарктов миокарда

Ключевые слова: машинное обучение, эволюционные алгоритмы, инфаркт миокарда многослойные нейронные сети, задачи классификации

Бурное распространение инфаркта миокарда за последние полвека сделало его одной из наиболее острых проблем современной медицины. Заболеваемость инфарктом миокарда (ИМ) остается высокой во всех странах. Особенно это касается городского населения высокоразвитых стран, испытывающего стремительный ритм современной жизни и подвергающегося хроническому воздействию стрессовых факторов, нерегулярного и не всегда сбалансированного питания. В США ежегодно около 1,5 миллионов человек заболевают инфарктом миокарда

Наше решение представляет собой систему с возможностью прогнозирования болезни пациента и определения рекомендаций по лечению, что позволяет подобрать более эффективный курс лечения, и снизить трудовую нагрузку на работников медицинской сферы

В данной работе были задействованы эволюционные алгоритмы для настройки нейронной сети. Функционал алгоритмы был следующий:

- выбор количества нейронов в каждом скрытом слое методом ГА;
- формирование и корректировка весов НН с использованием дифференциальной эволюции в совокупности с методом прореживания;
- наилучшие значения, найденные с использованием ДЕ, используются в качестве отправной точки для метода обратного распространения ошибки.

Использование эволюционных алгоритмов обусловлено тем что они позволяют не застрять на локальных минимумах/максимумах во время обучения и способны использовать как для обучения самой нейронной сети, так и для получения выходных значений из сконфигурированной НН.

Предпосылка ЭА довольно проста, и очень схожа с процессом естественного отбора. ЭА содержит четыре основных этапа: инициализация, выбор, генетические операторы и завершение. Каждый из этих шагов примерно со-

отвечает определенному аспекту естественного отбора и предоставляет простые способы модульной реализации этой категории алгоритмов. Проще говоря, в ЭА, более приспособленные члены выживут и размножатся, в то время как непригодные участники умрут и не внесут свой вклад в генофонд последующих поколений, как в естественном отборе [2].

Для начала работы алгоритма необходимо создать начальную выборку. Выборка будет содержать произвольное количество возможных решений проблемы, часто называемых популяцией. В основном популяция создается случайным образом. Необходимо, чтобы популяция охватывала широкий спектр решений, поскольку она по существу представляет собой генофонд; следовательно, нужно исследовать множество различных возможностей в течение алгоритма, следовательно, стремиться иметь много разных генов.

После того как популяция создана, ее члены должны теперь оцениваться в соответствии с функцией пригодности. Фитнес-функция — это функция, которая принимает характеристики члена и выводит численное представление о том, насколько оно жизнеспособно. Теперь нужно рассчитать пригодность всех участников и выбрать часть наиболее результативных участников.

Далее идет шаг, включающий в себя два подэтапа: скрещивание и мутацию. После выбора лучших членов, эти члены теперь используются для создания следующего поколения в алгоритме. Используя характеристики отобранных родителей, создаются новые дети, которые представляют собой смесь качеств родителей. Теперь необходимо ввести новый генетический материал в поколение. Если не сделать этот важный шаг, можно очень быстро застрять в локальных экстремумах и не получить оптимальных результатов. Этот шаг является мутацией, и делается довольно просто, изменяя небольшую часть детей таким образом, чтобы они больше не отражали подмножество генов родителей. Мутация обычно происходит вероятностно, поскольку вероятность того, что ребенок получит мутацию, а также серьезность мутации, определяются распределением вероятности.

Необходимо предусмотреть критерий останова. Обычно это происходит в двух случаях: либо алгоритм достиг некоторого максимального времени выполнения, либо алгоритм достиг некоторого порога производительности. На этом этапе формируется окончательное решение.

Набор данных представляет из себя 1700 записей больных ИМ, проходивших лечение в Кардиологическом центре городской больницы. Информация получена из историй болезни пациентов и сконцентрирована в 128 полях электронной таблицы. База данных содержит сведения о данных анамнеза каждого больного, клинике настоящего ИМ, электрокардиографических, лабораторных показателях, лекарственной терапии и особенностях течения заболевания в первые дни ИМ.

Информация получена из историй болезни пациентов и содержит сведения:

- личные данные больного (пол, возраст);
- анамнез больного;
- клиника настоящего инфаркта миокарда;
- электрокардиографические показатели;

- лабораторные показатели;
- лекарственная терапия;
- особенности течения заболевания в первые дни инфаркта миокарда.

Изначальная база данных была подвергнута предварительной обработке. Предобработка заключает в себе нормализацию данных. Нормализация данных представляет из себя операцию преобразования признаков которая выполняется при их генерации на этапе подготовки данных. В случае машинного обучения, нормализация — это процедура предобработки входной информации, при которой значения признаков во входном векторе приводятся к некоторому заданному диапазону, например, от 0 до 1 [1, 4]. В данном случае приведение данных к единичному масштабу обеспечивается нормировкой каждой переменной на диапазон разброса ее значений. В результате были убраны шумы, задвоения, пустые данные, база немножко уменьшилась до 1610 записей, и было выявлено, что порядка 30 столбцов являются не особо информативными.

Формирование выборок, как известно, разделяет наши данные на два подмножества: данные обучения и данные тестирования и подгоняем нашу модель к тренировочным данным, чтобы делать прогнозы для тестовых данных. Когда выборка разделена и модель обучена, может произойти одно из двух: модель переобучается или модель недообучается

Основные метриками для определения качества модели являются *accuracy*, *precision*, *recall* и *F-score*, так как была проблема прогнозирования случаев осложнения [3].

Для сравнения были задействованы различные классические алгоритмы для сравнения нашего метода (такие как деревья решений, метод опорных векторов и линейная регрессия методом наименьших квадратов), видно, что буквально все модели имеют низкий результат по *recall*. В данном случае решалась задача классификации, а именно выживет ли пациент при таких условиях или нет. Результаты представлены в табл. 1 и 2.

Таблица 1. Результат работы моделей на Class 0

Method	Recall	Precision	F-score
Random forest	0.88	0.99	0.93
Multilayer neural network	0.88	0.95	0.91
Linear regression	0.87	0.97	0.92
SVM	0.90	0.96	0.95

Таблица 2. Результат работы моделей на Class 1

Method	Recall	Precision	F-score
Random forest	0.82	0.27	0.41
Multilayer neural network	0.76	0.53	0.63
Linear regression	0.63	0.24	0.34
SVM	0.69	0.43	0.53

В результатах табл. 3 мы уже задействовали только нейронные сети, для прогнозирования 11 отдельных осложнений, основной порог в 75 % был выполнен почти по всем осложнениям, за исключением пары осложнений.

Таблица 3. Результат работы модели по осложнению

Осложнение	Recall	Precision	Accuracy	F-score
Фибрилляция предсердий	0.81	0.81	0.81	0.81
Суправентрикулярная тахикардия	0.71	0.71	0.71	0.71
Желудочковая тахикардия	0.83	0.75	0.75	0.73
Фибрилляция желудочек	0.84	0.81	0.81	0.82
Полная а-в блокада	0.83	0.81	0.81	0.81
Отек легких	0.88	0.83	0.83	0.83
Разрыв сердца	0.84	0.77	0.77	0.76
Синдром Дресслера	0.81	0.76	0.76	0.76
Хроническая сердечная недостаточность	0.82	0.82	0.82	0.81
Рецидив инфаркта миокарда	0.76	0.72	0.72	0.73
Постинфарктная стенокардия	0.77	0.76	0.76	0.76

Показан результат работы разных комплексов алгоритмов, проведено сравнение с классическими алгоритмами машинного обучения. Представлены таблицы, позволяющие оценить точность разных моделей.

В результате данных исследований можно предположить, что ЭА в совокупности с НС позволяют эффективно решать задачи анализа данных. Предложенный подход является более эффективным для данных задач по сравнению с традиционным.

Литература

- [1] Русин Д.С., Сопов Е.А. Гибридный метод обучения нейронной сети на основе дифференциальной эволюции // Решетневские чтения. 2019. № 2. С. 211–213.
- [2] Горбань А.Н. и др. Нейроинформатика: науч. изд. Новосибирск: Сибирское предприятие РАН, 1998. 296 с.
- [3] Srivastava N., Hinton G., Krizhevsky A., Sutskever I., Salakhutdinov R. Dropout: a simple way to prevent neural networks from overfitting // Journal of Machine Learning Research. 2014. No. 15. Pp. 1929–1958.
- [4] UCI machine learning repository University of California, Irvine, School of Information and Computer Sciences. Available at: <https://archive.ics.uci.edu/ml/index.php> (accessed March 10, 2023).

Simulation Neural Network Model for Predicting the Course and Outcomes of Myocardial Infarction

©	Rusin D.S.	drusin@sfu-kras.ru
	Sopov E.A.	ESopov@sfu-kras.ru
	Mikhalev A.S.	asmikhalev@yandex.ru
	Antamoshkin O.A.	oleslav24@gmail.com
	Bryukhanova E.R.	erbryukhanova@sfu-kras.ru

Siberian Federal University, Krasnoyarsk, 660041 Russia

This paper shows the effectiveness of using the machine learning method for solving the problem of predicting myocardial infarction

Keywords: *machine learning, evolutionary algorithms, myocardial infarction, multilayer neural networks, classification problems*

УДК 616-073.75

Инфузионное извлечение и измерение на КТ-изображениях на основе компьютерного зрения и нейронной сети

© Хамад Юсиф Ахмед^{1,2}
Алехина Анна Евгеньевна^{1,3}
Плешкова Татьяна Сергеевна¹

y.albayati8@gmail.com
dumooroo@gmail.com
tpleshkova@sfu-kras.ru

¹ Сибирский федеральный университет, Красноярск, 660074, Россия

² Факультет компьютерных наук, Колледж компьютерных наук и информационных технологий, Киркукский университет, Киркук, Ирак

³ Сибирский государственный университет науки и технологий имени М.Ф. Решетнева, Красноярск, 660037, Россия

Автоматическое обнаружение и количественная оценка эмфиземы легких с использованием изображений компьютерной томографии (КТ) является решающим шагом в точной диагностике и мониторинге этого хронического обструктивного заболевания легких (ХОБЛ). Такой подход потенциально может повысить точность и скорость диагностики легких и мониторинга изменений при эмфиземе, что приведет к улучшению результатов лечения пациентов. Кроме того, использование компьютерного зрения и алгоритмов нейронных сетей может дать представление о сложных закономерностях развития и прогрессирования эмфиземы легких, что может послужить основой для разработки новых вариантов лечения.

Ключевые слова: компьютерная томография, нейронные сети, компьютерное зрение, сегментация, поиск аномалий

Введение. Хроническая обструктивная болезнь легких (ХОБЛ) — прогрессирующее респираторное заболевание, которым страдают миллионы людей во всем мире и которое является основной причиной заболеваемости и смертности. ХОБЛ — это изнурительное заболевание, которое может значительно снизить качество жизни тех, кто от него страдает. Несмотря на значительный прогресс, достигнутый в понимании ХОБЛ, остается много проблем в ее эффективном ведении и лечении. Следовательно, необходимы новые методы для улучшения диагностики и мониторинга ХОБЛ, особенно эмфиземы легких, которая является одним из видов ХОБЛ, характеризующимся разрушением альвеол в легких.

Связанные работы. Хроническая обструктивная болезнь легких, широко известная как ХОБЛ, является прогрессирующим респираторным заболеванием, которым страдают миллионы людей во всем мире. Это ведущая причина заболеваемости и смертности во всем мире, а курение является основным фактором риска развития этого заболевания. ХОБЛ — это изнурительное заболевание, которое может значительно снизить качество жизни тех, кто от него страдает. На протяжении многих лет было проведено множе-

ство исследований ХОБЛ, посвященных различным аспектам заболевания, включая его патогенез, диагностику, лечение и профилактику [1]. Обзор литературы по существующим исследованиям ХОБЛ показывает, что был достигнут значительный прогресс в понимании этого заболевания, но остается много проблем в его эффективном ведении и лечении [2].

Было проведено несколько исследований для оценки различных методов выявления ХОБЛ, начиная от спирометрии и визуализации и заканчивая биомаркерами крови и анкетированием. В этом сравнении мы рассмотрим некоторые ключевые выводы и ограничения этих исследований.

Многие международные рекомендации рекомендуют использовать спирометрию в качестве наиболее распространенного инструмента диагностики ХОБЛ. Одно исследование, опубликованное в Международном журнале ХОБЛ, показало, что спирометрия обладает высокой чувствительностью и специфичностью для выявления ХОБЛ в учреждениях первичной медико-санитарной помощи, что позволяет предположить, что она может быть эффективным инструментом для выявления пациентов с этим заболеванием [3]. Однако для проведения спирометрии требуется специализированное оборудование и обученный технический персонал, что может ограничить ее доступность и осуществимость в условиях ограниченных ресурсов.

Методы визуализации, такие как рентген грудной клетки и компьютерная томография (КТ), также были изучены для выявления ХОБЛ. Систематический обзор и мета-анализ, опубликованные в Европейском респираторном журнале, показали, что рентгенография грудной клетки обладает ограниченной чувствительностью и специфичностью для выявления ХОБЛ по сравнению со спирометрией. С другой стороны, было обнаружено, что компьютерная томография более точно выявляет эмфизему и ремоделирование дыхательных путей, которые являются характерными признаками ХОБЛ. Эмфизема — это тип хронического обструктивного заболевания легких, характеризующийся разрушением альвеол в легких, что приводит к задержке воздуха и затруднению дыхания. Методы визуализации, такие как рентген грудной клетки и компьютерная томография (КТ), являются важными инструментами для диагностики и мониторинга эмфиземы легких [4].

Рентген грудной клетки часто является первым визуализирующим тестом, используемым для обследования пациентов с подозрением на эмфизему. Они могут выявить признаки гиперинфляции легких, такие как уплощение диафрагмы и увеличение объема грудной клетки. Однако рентгенография грудной клетки обладает ограниченной чувствительностью и специфичностью для выявления ранней эмфиземы.

Компьютерная томография, с другой стороны, может предоставить более подробную информацию о степени и тяжести эмфиземы легких. Компьютерная томография может выявить незначительные изменения в структуре и функциях легких, такие как наличие воздушных пробок и потеря легочной ткани. Компьютерная томография также позволяет различать различные типы эмфиземы, такие как центролобулярная и панлобулярная эмфизема.

Пневмокониоз — это заболевание легких, которое также развивается при ХОБЛ и характеризуется накоплением фиброзной ткани в легких, приводящим к образованию рубцов и утолщению легочной ткани. Компьютерная томография помогает выявить наличие непрозрачных стекол, сетчатых узоров, ячеистых образований и тракционных бронхэкстазов, которые характерны для пневмокониоза. Компьютерная томография также позволяет различать различные типы пневмокониоза, такие как распространенная интерстициальная пневмония (UIP) и неспецифическая интерстициальная пневмония (NSIP).

Недавние исследования были сосредоточены на использовании компьютерного зрения и алгоритмов нейронных сетей для автоматического обнаружения и измерения эмфиземы легких и выявления пневмокониоза при компьютерной томографии. Такой подход потенциально может повысить точность и эффективность диагностики и мониторинга эмфиземы легких, а также дать представление о лежащих в основе заболевания механизмах.

Сегментация и измерение медицинских изображений являются важнейшими шагами в точной идентификации интересующей области, особенно в случаях диагностики легких и эмфиземы легких. В статье [5] Голамианха и соавт. описывают метод автоматической сегментации легких на КТ-изображениях как нормальных пациентов, так и пациентов с пневмонией, вызванной COVID-19. Они использовали алгоритм глубокого обучения, основанный на архитектуре U-Net, который был обучен на наборе данных аннотированных изображений компьютерной томографии. Авторы сообщают о высокой точности своего метода сегментации областей легких, с коэффициентами подобия Dice (DSC), равными 0,973 и 0,955 для пациентов с нормальной пневмонией и COVID-19, соответственно. Они предполагают, что их метод мог бы стать ценным инструментом для диагностики и мониторинга пневмонии, вызванной COVID-19 [6]. В статье [7] Ванг и соавт. предлагают автоматизированный метод сегментации легких на КТ-изображениях пациентов с тяжелым интерстициальным заболеванием легких (ILD). Они использовали гибридный подход, сочетающий алгоритмы увеличения области и активного контура, который был применен к набору данных из 20 КТ-изображений пациентов с тяжелой формой ILD. Авторы сообщают о высокой точности их метода сегментации областей легких со средним коэффициентом перекрытия 93,2%. Они предполагают, что их метод может быть полезен при клиническом обследовании пациентов с тяжелой формой ILD. В целом, эти статьи демонстрируют важность точной сегментации медицинских изображений при диагностике и лечении заболеваний легких.

Наше исследование направлено на анализ существующих подходов и разработку нового подхода к автоматизированному выявлению и количественной оценке эмфиземы легких с использованием изображений компьютерной томографии. Такой подход потенциально может повысить точность и скорость диагностики легких и мониторинга эмфиземы, а также новизну измерений изменений эмфиземы, что в конечном итоге может привести к улучшению результатов лечения пациентов. Кроме того, использование ком-

пьютерного зрения и алгоритмов нейронных сетей может дать представление о сложных закономерностях развития и прогрессирования эмфиземы легких, что может послужить основой для разработки новых стратегий лечения.

Экспериментальные материалы. В 2022 г. мы получили материалы компьютерной томографии (КТ) от Федерального медико-биологического агентства (ФМБА) в Красноярске, чтобы помочь в обучении и тестировании нашей модели. Эти материалы были собраны у пациентов, у которых была диагностирована хроническая обструктивная болезнь легких (ХОБЛ) после сбора анамнеза и анализа. Чтобы убедиться в точности наших диагнозов, мы проконсультировались со специалистами Федерального медико-биологического агентства.

В дополнение к консультациям мы поручили специалистам по ультразвуковому исследованию сегментировать участки поражения легких на компьютерной томографии. Специалисты принимают во внимание различные типы эмфиземы легких и пневмокониозной сетки. Сегментируя изображения, мы могли бы выделить пораженные участки и получить более точные и надежные результаты.

Перед выполнением сегментации мы провели предварительную обработку компьютерных снимков. Это включало удаление с изображений нежелательных элементов, таких как мясо, жир и кости, а также компонентов бронхиальной системы. Это было сделано для создания бинарных масок из сетки пневмокониоза, которая была необходима для процесса сегментации.

Методы решения задачи. Для повышения точности обнаружения аномалии используется многоступенчатый подход. На шаге 1 изображение делится на два поддиапазона: поддомен LL, содержащий фильтры низкого уровня, и поддомен HH, содержащий фильтры более высокого уровня. Метод дискретного вейвлет-преобразования (DWT) применяется для определения соответствующего порога усиления границ с использованием фильтров как нижних, так и верхних частот. На шаге 2 генерируется фильтр верхних частот путем преобразования оставшихся поддиапазонов с использованием обратных вейвлет-преобразований в горизонтальном, вертикальном и диагональном направлениях. Наконец, шаг 3 включает в себя разделение изображения на два блока пикселей и использование локальной балансировки контрастности для усиления внутреннего контраста между черным и белым.

Результаты. В ходе экспериментов было показано, что этот подход эффективен, прямолинеен и прост в реализации. Использование методов обнаружения на основе сегментации изображения при обнаружении дыма также может помочь уменьшить шумовые помехи, что приводит к более надежным результатам. Используя эти методы, можно повысить точность обнаружения дыма, что делает его ценным инструментом для таких применений, как обнаружение и предотвращение пожаров. На рис. 1 представлены результаты сегментации эмфиземы у разных пациентов.

На рис. 1 показана сегментация эмфиземы и измерения у трех разных пациентов. Экспертная оценка нашего метода показала высокую точность из-

влечения эмфиземы и измерения размеров, поскольку эмфизема видна на компьютерной томографии, что затрудняет радиологу составление отчета о состоянии пациента, как представлено на рисунке. На рис. 1 выделенная эмфизема у первых пациентов составляет 14 %, у второго пациента — 19 %, а у третьего пациента — 23 % (выделено красным цветом).

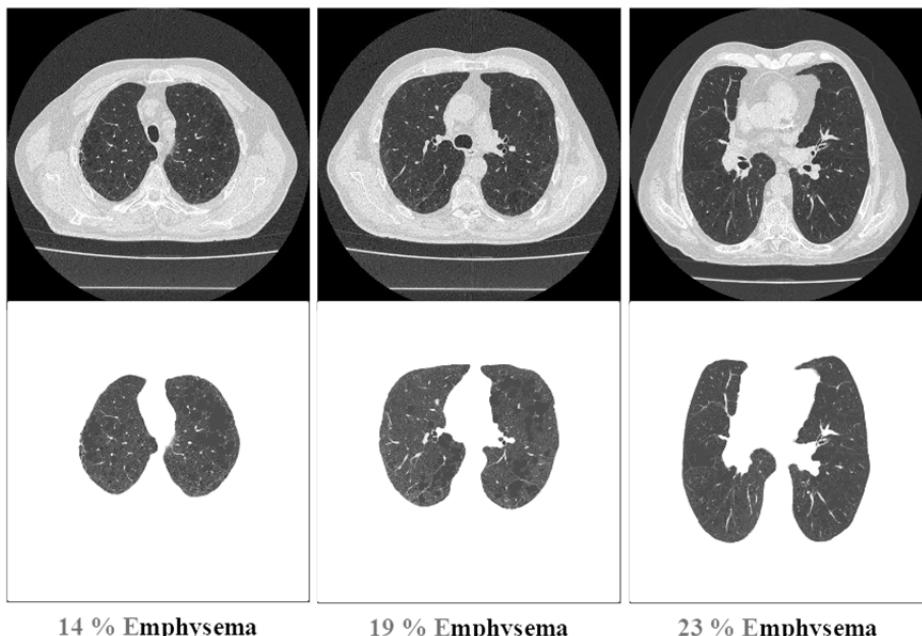


Рис. 1. Сегментация эмфиземы с использованием различных значений ETV

На рис. 2 показана сегментация сетки пневмосклероза, полученная после использования цветовой сегментации в цветовом пространстве HSV.

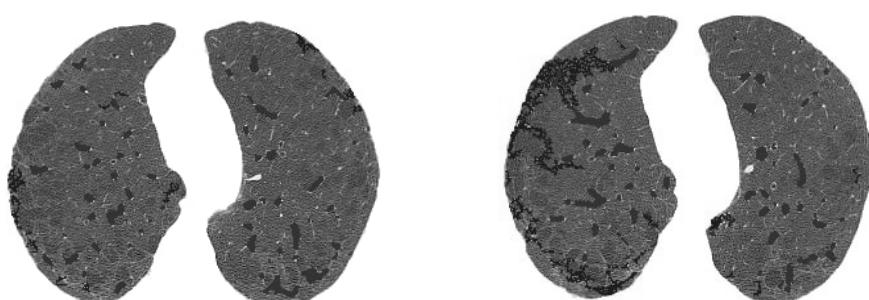


Рис. 2. Детектированная область пневмосклероза

Успешная сегментация эмфиземы и пневмосклероза с использованием методов сегментации представляет собой значительный шаг вперед в автоматизированном выявлении хронической обструктивной болезни легких (ХОБЛ) в больницах. Точная идентификация этих патологий легких имеет решающее значение для диагностики и лечения ХОБЛ, и результаты этого исследования демонстрируют потенциал автоматизированных процессов, которые помогут в этой работе. При дальнейшем развитии и усовершенствовании эти методы могут быть интегрированы в рабочие процессы больниц, что позволит быстрее и точнее диагностировать ХОБЛ и улучшить результаты лечения пациентов.

Вывод. Медицинская визуализация является важным инструментом в диагностике и лечении различных заболеваний, но точное сегментирование и измерение медицинских изображений может оказаться непростой задачей. В этом исследовании предлагается новый метод экстракции легких, сегментации эмфиземы и измерения объема с использованием комбинации улучшения изображения, морфологических операций и метода порогового значения эмфиземы (ETV). Предложенный метод привел к более точной и надежной сегментации легких и эмфиземы, что привело к улучшению диагностики и исходов лечения пациентов.

Экспериментальные результаты показали, что предложенный подход является эффективным, четким и простым в использовании. Этот метод потенциально может значительно повысить точность сегментации медицинских изображений, особенно при выявлении и диагностике таких заболеваний, как эмфизема легких и COVID-19. Успешная сегментация пневмосклероза была также достигнута в этом исследовании путем реализации цветовой сегментации в цветовом пространстве HSV. В целом это исследование вносит вклад в продолжающиеся усилия по разработке новых и усовершенствованных методов анализа и интерпретации медицинских изображений.

Литература

- [1] Vestbo J., Hurd S.S., Agusti A.G., Jones, P.W., Vogelmeier C., Anzueto A., Barnes P.J., Fabbri L.M. et al. Global strategy for the diagnosis, management, and prevention of chronic obstructive pulmonary disease: GOLD executive summary // American Journal of Respiratory and Critical care Medicine. 2013. Vol. 187 (4). Pp. 347–365. <https://doi.org/10.1164/rccm.201204-0596PP>
- [2] Agusti A., Calverley P.M.A., Celli B., Coxson H.O., Edwards L.D., Lomas D.A. et al. Characterisation of COPD heterogeneity in the ECLIPSE cohort // Respiratory Research. 2011. Vol. 12 (1). Pp. 1–12. <https://doi.org/10.1186/1465-9921-12-1>
- [3] Jones R.C., Price D., Ryan D., Sims E.J., von Ziegenweidt J., Mascarenhas L., Burden A., Halpin D.M., Winter R., Hill S., Kearney M., Holton K., Moger A., Freeman D., Chisholm A., Bateman E.D. Respiratory Effectiveness Group. Opportunities to diagnose chronic obstructive pulmonary disease in routine care in the UK: a retrospective study of a clinical cohort // Lancet Respir Med. 2014. Vol. 2 (4). Pp. 267–276. [https://doi.org/10.1016/S2213-2600\(14\)70008-6](https://doi.org/10.1016/S2213-2600(14)70008-6)
- [4] Kerpel-Fronius A., Tammemägi M., Cavic M., Henschke C., Jiang L., Kazerooni E., Lee C.T., Ventura L., Yang D., Lam S., Huber R.M. Screening for lung cancer in individuals who never smoked: an international association for the study of lung cancer early detection and screening committee report // J Thorac Oncol. 2022. Vol. 17 (1). Pp. 56–66. <https://doi.org/10.1016/j.jtho.2021.07.031>

-
- [5] Gholamiankhah F., Mostafapour S., Abdi Goushbolagh N., Shojaerazavi S., Layegh P., Tabatabaei S.M., Arabi H. Automated lung segmentation from computed tomography images of normal and covid-19 pneumonia patients // Iran J Med Sci. 2022. Vol. 47 (5). Pp. 440–449. <https://doi.org/10.30476/IJMS.2022.90791.2178>
 - [6] Hamad Y.A., Seno M.E. et al. Segmentation and measurement of lung pathological changes for covid-19 diagnosis based on computed tomography // Periodicals of Engineering and Natural Sciences (PEN). 2021. Vol. 9, no. 3. Art. 29. <https://doi.org/10.21533/pen.v9i3.2086>
 - [7] Wang J., Li F., Li Q. Automated segmentation of lungs with severe interstitial lung disease in CT // Med Phys. 2009. Vol. 36 (10). Art. 4592-9. <https://doi.org/10.1111/1.3222872>
 - [8] Zotin A., Hamad Y., Simonov K., Kurako M., Kents A. Processing of CT Lung Images as a Part of Radiomics // Czarnowski I., Howlett R., Jain L. (eds). Intelligent Decision Technologies. IDT 2020. Smart Innovation, Systems and Technologies. 2020. Vol 193. Springer, Singapore. https://doi.org/10.1007/978-981-15-5925-9_21
 - [9] Zotin A. et al. Processing of CT Lung Images as a Part of Radiomics // Intelligent Decision Technologies. Springer, Singapore, 2020. Pp. 243–252. https://doi.org/10.1007/978-981-15-5925-9_21
 - [10] Wang X., Chen L. Contrast enhancement using feature-preserving bi-histogram equalization // SIVIP. 2018. Vol. 12. Pp. 685–692. <https://doi.org/10.1007/s11760-017-1208-2>

Infusion Extraction and Measurement on CT Images Based on Computer Vision and Neural Network

© Hamad Yousif Ahmed^{1,2} y.albayati8@gmail.com
Alyokhina Anna Evgenievna^{1,3} dumooroo@gmail.com
Pleshkova Tatiana Sergeevna¹ tpleshkova@sfu-kras.ru

¹ Siberian Federal University, Krasnoyarsk, 660074, Russia

² Faculty of Computer Science, College of Computer Science and Information Technology, Kirkuk University, Kirkuk, Iraq

³ Siberian State University of Science and Technology named after M.F. Reshetnev, Krasnoyarsk, 660037, Russia

Automatic detection and quantification of pulmonary emphysema using computed tomography (CT) images is a crucial step in the accurate diagnosis and monitoring of this chronic obstructive pulmonary disease (COPD). This approach can potentially improve the accuracy and speed of lung diagnosis and monitoring of changes in emphysema, which will lead to improve the results of treatment of patients. In addition, the use of computer vision and neural network algorithms can give an idea of the complex patterns of development and progression of emphysema of the lungs, which can serve as a basis for the development of new treatment options.

Keywords: computed tomography, neural networks, computer vision, segmentation, anomaly search

СОДЕРЖАНИЕ

Baum AI: передовые решения в области искусственного интеллекта	3
<i>Агеев Д.А., Суханов Д.А., Кудрявцев А.А., Тынченко Я.А.</i> Концепция фреймворка реализации генетического алгоритма многопараметрической оптимизации	5
<i>Евсюков Д.Ю., Бухтояров В.В., Бородулин А.С., Ломазов В.А.</i> Интеллектуальный анализ данных по материалам, полученным по технологии SLM	10
<i>Загитов А.А., Чеботарева Э.В., Магид Е.А.</i> Оптимизация моделей сверточных нейронных сетей для решения задач распознавания объектов в контексте образовательной робототехники	17
<i>Коноплева А.А., Анфимов Д.Р., Голяк И.С., Фуфурин И.Л.</i> Применение машинного обучения для медицинской диагностики заболеваний по инфракрасным спектрам выдыхаемого человеком воздуха	22
<i>Масич И.С., Суханов Д.А., Медведев А.В., Строганов П.А.</i> Выявление групп спроса на станочное оборудование посредством интеллектуального анализа и обоснованной кластеризации данных из таможенных документов ...	28
<i>Соколов Г.В., Шучалин Г.В., Гантимуров А.П.</i> Исследование возможности нахождения аномалий в сетевом трафике с помощью алгоритмов кластеризации, валидации и применения метода косинусной близости	37
<i>Соколов Г.В., Шучалин Г.В., Гантимуров А.П.</i> Прогнозирование времени заполнения хранилища данных с помощью модели полиномиальной регрессии	44
<i>Тынченко В.С., Курашкун С.О., Нелюб В.А.</i> Применение нейронной сети архитектуры EfficientNetB0 для задачи анализа видеопотока из зоны индукционной пайки волноводных трактов	48
<i>Тынченко В.С., Суханов Д.А., Кудрявцев А.А., Агеев Д.А.</i> Применение архитектуры нейронной сети U-Net для сегментации клеток мозга по трипановым синим изображениям	54
Искусственный интеллект как объект изучения в инженерном образовании	61
<i>Бутенко Ю.И.</i> Роль мультидисциплинарных исследований в автоматической обработке научно-технических текстов	63
<i>Гузева Т.А., Цибизова Т.Ю.</i> Технология информационного сопровождения формирования образовательных программ с элементами искусственного интеллекта	68
<i>Карпенко А.П.</i> Методика преподавания алгоритмов роботового интеллекта	78

<i>Ляпунцова Е.В., Ноговицын М.А.</i> Практика применения искусственного интеллекта и нейронных сетей в задачах управления в образовании: методология, кейсы, деловые игры	84
<i>Панилов П.А., Рыжова Н.В., Цибизова Т.Ю.</i> Кarta компетенций выпускника технического вуза для когнитивного моделирования: разработка и оценка навыков	90
<i>Панилов П.А., Цибизова Т.Ю., Воскресенский Г.А.</i> Методология экспертно-агентного когнитивного моделирования предупреждения воздействия на критическую информационную инфраструктуру	98
<i>Панфилова Е.В.</i> Применение алгоритмов искусственного интеллекта и нейросетевого моделирования технических систем в научно-исследовательской работе студентов	105
<i>Цветков Ю.Б.</i> Онтологическое моделирование предметной области как средство повышения эффективности усвоения инженерных дисциплин	111
Искусственный интеллект: от науки к инфраструктуре и практике	119
<i>Алехина А.Е., Королев П.А., Доррер М.Г.</i> Применение сверточных сетей архитектуры yolo для подсчета свободных парковочных мест на произвольной парковке	121
<i>Вареник М.С., Самсонов Р.О., Воронина М.А.</i> Тенденции применения технологий искусственного интеллекта и когнитивных технологий в государственном управлении	132
<i>Пересунько П.В., Пересунько Е.О.</i> Человеко-компьютерное взаимодействие на основе преобразования движения произвольных объектов в видеопотоке ...	141
<i>Русин Д.С., Сопов Е.А., Михалев А.С., Антамошкин О.А., Брюханова Е.Р.</i> Имитационная нейросетевая модель прогнозирования течения и исходов инфаркта миокарда	148
<i>Хамад Ю.А., Алехина А.Е., Плешикова Т.С.</i> Инфузионное извлечение и измерение на КТ-изображениях на основе компьютерного зрения и нейронной сети	153

Научное издание

Ключевые тренды развития
искусственного интеллекта:
наука и технологии

Международная ИТ-конференция

(Москва, 21 апреля 2023 г.)

Сборник трудов

Художник *Я.М. Асинкристова*
Компьютерная верстка *С.А. Серебряковой*

Оригинал-макет подготовлен
в Издательстве МГТУ им. Н.Э. Баумана.

В оформлении использованы шрифты
Студии Артемия Лебедева.

Подписано в печать 12.10.2023. Формат 70×100/16.
Усл. печ. л. 13,16. Тираж 300 экз.

Издательство МГТУ им. Н.Э. Баумана.
105005, г. Москва, улица 2-я Бауманская, д. 5, стр. 1.
press@bmstu.ru
<https://press.bmstu.ru>

Отпечатано в типографии МГТУ им. Н.Э. Баумана.
105005, г. Москва, улица 2-я Бауманская, д. 5, стр. 1.
baumanprint@gmail.com